UNIVERSITE DE KINSHASA

FACULTE POLYTECHNIQUE
DEPARTEMENT DE GENIE ELECTRIQUE ET INFORMATIQUE
B.P. 127 KIN XI

Optimisation de l'intégration d'un système photovoltaïque dans un réseau électrique à l'aide du Machine Learning : Cas du réseau SNEL (Sous-station Campus)

Par : **MBUSU Parfait**
Gradué en Sciences appliquées

Mémoire présenté en vue de l'obtention du grade d'ingénieur Civil Électricien.
Orientation : **Électro-énergétique**.

Directeur : Prof. Dr. Ir. **KYAMAKYA**
Co-directeur 1 : Assistant Ir. Civil. **MUBIKAYI Matthieu**
Co-directeur 2 : Ir. Civil **NTWALI Samuel**

ANNEE ACADEMIQUE : 2024-2025

Je dédie ce travail à mes parents,

pour leur amour, leurs sacrifices

et leur soutien constant tout au long de mon parcours académique.

Liste des sigles et abréviations

AC : Alternating Current (Courant alternatif)

AIST : Advanced Industrial Science and Technology

APFB : Active Power Filter Bandpass

BT : Basse Tension

CPV : Concentrated Photovoltaics

CSV : Comma Separated Values

CSI : Current Source Inverter

DC : Direct Current (Courant continu)

DER : Distributed Energy Resources

DOD : Depth of Discharge

ELM : Extreme Learning Machine

GPV : Générateur Photovoltaïque

HT : Haute Tension

IEEE : Institute of Electrical and Electronics Engineers

IRC : Joint Research Centre

I–V : Courant – Tension

MAE : Mean Absolute Error

MPP : Maximum Power Point

MPPT : Maximum Power Point Tracking

MT : Moyenne Tension

MW : Mégawatt

MVA : Mégavoltampère

NREL : National Renewable Energy Laboratory

ORPD : Optimal Reactive Power Dispatch

P_loss : Pertes de puissance active dans le réseau

P_pv :Puissance active générée par le système photovoltaïque

PCC : Point of Common Coupling (Point de Couplage Commun)

PLL : Phase Locked Loop

PV : Photovoltaïque

P–V : Puissance – Tension

Q_load : Puissance réactive de la charge

Q_opt : Puissance réactive optimale

RDC : République Démocratique du Congo

RMSE : Root Mean Square Error

SCADA : Supervisory Control and Data Acquisition

SCR : Short Circuit Ratio

SEMI : Semiconductor Equipment and Materials International

SLFN : Single Layer Feedforward Network

SNEL : Société Nationale d'Électricité

SOC : State of Charge

UNIKIN : Université de Kinshasa

USA : United States of America

V_pcc : Tension au point de couplage commun

VSI : Voltage Source Inverter

WECC : Western Electricity Coordinating Council

Résumé

L'intégration croissante des sources d'énergie renouvelables dans les réseaux électriques de distribution représente aujourd'hui un enjeu majeur pour les systèmes énergétiques modernes. Parmi ces sources, l'énergie photovoltaïque occupe une place importante en raison de son potentiel élevé et de son caractère durable. Cependant, l'injection de la production photovoltaïque dans les réseaux électriques peut engendrer certaines contraintes techniques, notamment des variations de tension, des surcharges de lignes et une augmentation des pertes électriques. Dans ce contexte, la gestion optimale de la puissance réactive des centrales photovoltaïques constitue un levier essentiel pour améliorer les performances du réseau.

Le présent travail propose une approche basée sur l'intelligence artificielle pour l'optimisation de l'injection de puissance réactive dans un réseau de distribution intégrant une centrale photovoltaïque. L'étude est réalisée sur un modèle du réseau Kinshasa 30 kV, développé dans l'environnement de simulation DIgSILENT PowerFactory. L'objectif principal consiste à déterminer la puissance réactive optimale à injecter par la centrale photovoltaïque afin d'améliorer les performances du réseau, notamment en termes de régulation de tension, de chargement des lignes et de réduction des pertes électriques.

Pour atteindre cet objectif, un ensemble de données représentatif du fonctionnement du réseau a été généré à partir de simulations réalisées dans PowerFactory. Les variables utilisées comme entrées du modèle comprennent la puissance photovoltaïque produite, la puissance active et réactive de la charge, la tension au point de couplage commun, le taux de chargement de la ligne critique ainsi que les pertes actives du réseau. Ces données ont été utilisées pour entraîner un modèle d'apprentissage automatique basé sur l'algorithme Extreme Learning Machine (ELM), permettant d'estimer la puissance réactive optimale à injecter par la centrale photovoltaïque.

Les performances de cette approche ont été évaluées à travers une analyse comparative de trois scénarios de fonctionnement : un fonctionnement sans contrôle de la puissance réactive, un contrôle classique basé sur une loi $Q(P)$ et un contrôle intelligent basé sur le modèle ELM. Les

simulations statiques et quasi-dynamiques réalisées sur une période de 24 heures ont permis d'analyser l'évolution de la tension au point de couplage commun, le chargement des lignes ainsi que les pertes actives dans le réseau.

Les résultats obtenus montrent que l'utilisation du modèle ELM permet d'améliorer le comportement global du réseau. En particulier, cette approche contribue à une meilleure régulation de la tension au point de couplage commun, à une réduction du chargement de la ligne critique et à une diminution des pertes actives par rapport aux stratégies de contrôle classiques. La réduction des pertes obtenue, bien que modérée à l'échelle instantanée, confirme le potentiel de l'intelligence artificielle pour l'optimisation de l'exploitation des réseaux de distribution modernes.

Ce travail met ainsi en évidence l'intérêt de l'utilisation des techniques d'apprentissage automatique pour la gestion intelligente de la puissance réactive dans les réseaux électriques intégrant des sources d'énergie renouvelables. Les résultats obtenus ouvrent également des perspectives intéressantes pour l'intégration de telles approches dans les systèmes de contrôle en temps réel des réseaux électriques intelligents.

Abstract

The increasing integration of renewable energy sources into electrical distribution networks has become a major challenge for modern power systems. Among these sources, photovoltaic energy plays a significant role due to its high potential and sustainable nature. However, the injection of photovoltaic power into electrical networks may generate several technical constraints, including voltage fluctuations, line overloads, and increased electrical losses. In this context, the optimal management of reactive power from photovoltaic power plants represents an essential lever for improving network performance.

This work proposes an approach based on artificial intelligence for optimizing reactive power injection in a distribution network integrating a photovoltaic power plant. The study is carried out on a model of the Kinshasa 30 kV network, developed within the simulation environment DIgSILENT PowerFactory. The main objective is to determine the optimal reactive power to be injected by the photovoltaic power plant in order to improve network performance, particularly in terms of voltage regulation, line loading, and reduction of electrical losses.

To achieve this objective, a representative dataset describing the operating conditions of the network was generated from simulations performed in PowerFactory. The input variables of the model include the generated photovoltaic power, the active and reactive power of the load, the voltage at the point of common coupling, the loading rate of the critical line, as well as the active power losses in the network. These data were used to train a machine learning model based on the Extreme Learning Machine algorithm, which estimates the optimal reactive power to be injected by the photovoltaic plant.

The performance of the proposed approach was evaluated through a comparative analysis of three operating scenarios : operation without reactive power control, conventional control based on a $Q(P)$ law, and intelligent control based on the ELM model. Static and quasi-dynamic simulations performed over a 24-hour period allowed the analysis of the evolution of the voltage at the point of common coupling, the loading of the lines, and the active power losses in the network.

The obtained results show that the use of the ELM model improves the overall behavior of the network. In particular, this approach contributes to better voltage regulation at the point of common coupling, a reduction in the loading of the critical line, and a decrease in active power losses compared with conventional control strategies. Although the loss reduction remains moderate at an instantaneous scale, it confirms the potential of artificial intelligence for optimizing the operation of modern distribution networks.

This work therefore highlights the relevance of machine learning techniques for the intelligent management of reactive power in electrical networks integrating renewable energy sources. The obtained results also open interesting perspectives for the integration of such approaches into real-time control systems of smart electrical grids.

DEDICACE

« Nous te louons Père, Seigneur du Ciel et de la Terre, de ce que tu as gardé nos âmes et nous a permis de voir ce jour ; car tu connais le projet que tu as formé sur nous, projet de paix et non de malheur afin de nous donner un avenir et de l'espérance. » Jérémie 29 :11.

A mon papa **MBUSU Lum Innocent** , source de mon existence et artiste de personnalité. Mon plus grand bonheur, c'est d'avoir hérité le meilleur de vous-même. Ce travail constitue le résultat de vos efforts, encouragement et sacrifices, merci beaucoup papa.

A ma très chère maman **MUNGULU Andok Mireille**, l'occasion est enfin là pour t'honorer de tant de peines et sacrifices endurés pour moi depuis l'enfance. Tes prières et tes supplications, larmes aux yeux, sont couronnées de succès. Ce travail constitue le fruit de tes efforts et de tes privatisations ; savoure-le chère mère.

A mon oncle maternel **PENGE Aby**, à mes grands frères **Baptiste NGHO** et **MBUSU PATER**, à mon petit frère **MBUSU Bienvenu**, à ma petite sœur **MBUSU Filia**, pour vos soutiens tant financiers qu'émotionnel consentis avec joie tout au long de mon parcours, pour avoir facilité grandement mon devenir. Sans la volonté de Dieu en vous, l'amour ainsi que des liens forts que nous partageons, je ne pourrais jamais vous offrir ce diplôme de 1er Cycle en Polytechnique. Que ce travail demeure pour vous un réel signe de fierté et de gratitude. Merci.

En mémoire de mon regretté oncle paternel **MBUSU Bruno**, que l'Eternel l'appelle auprès de lui. Mon plus grand regret c'est de ne pas avoir vécu ensemble. Repose-toi dans la paix céleste.

Aux grand-frères, confrères et sœurs, **Maman Dorcas**, **prof. KAPE Van**, **prof. NKU Jeremy**, **Mme SONA Ange**, **PALUKU Christian**, **Prof. MANGALA**, **Prof. MUNGWELE**, **Mme Sylvie** goûtez les fruits de vos sacrifices sans lesquels mon séjour loin de vous serait très pénible.

A mes très grandes familles **Maman Eugide MUNGULU**, **Oncle Alias MUNGULU**, **Oncle SEKELE**, **Oncle Molière**, **ISUNGU Urvine**, **NGAMUNA Glody**, à tout le reste de la famille élargie, à qui je dédie ce travail.

A mes ami(e)s et connaissances : **Siméon MABONDO**, **Delka KATANGA**, **Trésor MUNGANGA**, **Sacré MBUKE**, **NGULABWI Jordy**, **Don KULONGESA**, **AMISI Lucien**, **MBIDE MBENZA**, **KINGOMA Eric**, **ONKAN Mputu**, **MUNOKO Mputu**, **Samuel MWAMBA** et plus particulièrement **Ruth KALAMBAYI** pour le soutien émotionnel ces dernières années, à qui je dédie ce travail.

MBUSU Parfait

Gradué en Sciences appliquées

Remerciements

Au terme de ce travail, qui marque la fin de notre Deuxième Cycle d'Etudes Universitaires, qu'il nous soit permis d'exprimer notre sincère et profonde reconnaissance envers tous ceux qui ont honorablement contribué, de près ou de loin, aux corps scientifique de la faculté polytechnique, professeurs, chefs de travaux, et assistants en général et ceux du département de génie électrique et informatique en particulier de trouver l'expression de notre gratitude pour leurs dévouements pendant notre formation intellectuelle.

Nos remerciements s'adressent avant tout aux professeurs **KYAMAKYA KYANDOGERE**, Directeur et promoteur de ce passionnant travail. Nous remercions également l'assistants **Ir. Civil MUBIKAYI Mathieu** et **Ir. Civil NTWALI Samuel** pour leur assistance dans ce travail et aussi aux **Ir. Civils LUZOLO Ketsia** et **KWETE Dinovic** pour leurs orientations fructueuses, échanges, remarques et conseils tout au long des recherches. C'est avec ardeur, compétence et dévouement qu'ils nous ont suivis et guidés tout au long de notre travail.

Nos sentiments de gratitude s'adressent également aux collègues ingénieurs civils compagnons de notre parcours universitaire : **NZUZI Félix**, **KINKONDO Marien**, **NTOMPA Patrick**, **KAPINGA Tabitha**, **MADIDI Abel**, **KIAKU Clevery**, **IYA BOSSAWA**, **MABANZA Daniel**, **ENYUNGU Lidya** et autres.

Nos sentiments de gratitude s'adressent spécialement à mes collègues, amis d'option Electro-énergétique avec qui nous avions passé de très bons moments d'échange et de renforcement des connaissances : **MALELI Jordy**, **NTUMBA Jean-Rich**, **KIMBENI Jortay**, **NGOYA Camille**, **ZIBERA Christian**, **BAU Veda**, **MURHULA Samuel**, **SIBI Trésor**, **KWON MPOMA**, **KALANG Peniel**, **TSHUNZA Dévinci**, **Dan CILOMBO**, **MAKAMBU René** et **BOFUKA Jean**.

Enfin, à tous présents et à venir.

MBUSU Parfait

Table des matières

Liste des sigles et abréviations **i**

Résumé **iii**

Abstract **v**

Dédicace **vii**

Remerciements **ix**

INTRODUCTION GÉNÉRALE **1**

1. Contexte et justification de l'étude 1
2. Problématique 2
3. Hypothèses de recherche 2
4. Objectif général 5
5. Objectifs spécifiques 5
6. Méthodologie adoptée 5
7. Structure du mémoire 7

1 GÉNÉRALITÉS SUR LES SYSTÈMES PHOTOVOLTAÏQUES ET EXIGENCES NORMATIVES **8**

1.1 Introduction 8

1.2 Principe de fonctionnement d'une centrale photovoltaïque 9

1.2.1 Le rayonnement solaire 9

1.2.2 La cellule solaire : 11

1.3 Les différents types de systèmes photovoltaïques 22

1.3.1 Installations photovoltaïques autonomes 22

1.3.2 Systèmes photovoltaïques raccordés au réseau (On-Grid) 23

1.3.3 Installations photovoltaïques hybrides 24
1.3.4 Composants d'un système raccordé au réseau 25
1.4 Onduleurs et stratégies de commande classiques 28
1.4.1 Gestion des échanges de puissance entre la centrale PV et le réseau . . 28
1.4.2 Stratégies de commande classiques 30
1.5 Codes réseaux et normes 32
1.5.1 Le grid code égyptien 32
1.6 Limites des stratégies classiques d'injection réactive 37

2 Modélisation du Réseau et Approche Traditionnelle d'Intégration 41
2.1 Présentation du réseau 41
2.1.1 Sous-station Campus 43
2.1.2 Le réseau UNIKIN 44
2.2 Modélisation du réseau d'étude dans DIgSILENT PowerFactory 45
2.2.1 Présentation du logiciel DIgSILENT PowerFactory 45
2.2.2 Modélisation du réseau d'étude 45
2.2.3 Modélisation de la centrale photovoltaïque 46
2.2.4 Prise en compte de la variabilité de la production photovoltaïque 51
2.3 Caractéristiques du réseau avant injection (Load Flow) 52
2.3.1 Contexte technique du calcul de flux de puissance 52
2.3.2 Intégration de la centrale photovoltaïque à la sous-station CAMPUS . . 57
2.3.3 Intégration de la centrale photovoltaïque à la sous-station 59
2.3.4 Raccordement de la centrale photovoltaïque au PCC 60
2.4 Simulation quasi-dynamique 61
2.4.1 Principe de la simulation quasi-dynamique 61
2.4.2 Analyse des grandeurs électriques 62
2.5 Analyse critique des résultats 65
2.5.1 Évolution de la puissance de charge et de la production photovoltaïque 65
2.5.2 Analyse de la tension au PCC 65
2.5.3 Analyse du chargement de la ligne Makala–Campus 66
2.5.4 Analyse des pertes actives du réseau 66
2.5.5 Portée et limites du fonctionnement en mode $Q(P)$ 67
2.5.6 Synthèse critique 67

3 Optimisation par Machine Learning (ELM) 71

Introduction 71

3.1 Fondements théoriques du Machine Learning 73

3.1.1 Apprentissage supervisé 74

3.1.2 Quelques algorithmes utilisés en Machine Learning 75

3.1.3 Intérêt du Machine Learning dans les systèmes électriques 75

3.2 Principe du modèle Extreme Learning Machine (ELM) 75

3.2.1 Introduction 75

3.2.2 L'Extreme Learning Machine (ELM) 77

3.2.3 Choix du modèle pour ce travail de fin d'étude 79

3.3 Formulation mathématique de la puissance réactive optimale 79

3.3.1 Fonction coût utilisée dans le script 79

3.4 Construction du Dataset 82

3.4.1 Principe de génération des données 83

3.4.2 Scénarios de fonctionnement du réseau 83

3.4.3 Génération temporelle des données 84

3.5 Entraînement et validation du modèle ELM 87

3.5.1 Préparation des données 87

3.5.2 Normalisation des données 88

3.5.3 Division des données d'apprentissage et de test 88

3.5.4 Principe de l'apprentissage ELM 89

3.5.5 Division du dataset 90

3.5.6 Évaluation des performances du modèle 91

3.5.7 Présentation des résultats de performance du modèle ELM 92

3.5.8 Interprétation des métriques MAE, RMSE et R^2 94

3.5.9 Justification d'un coefficient $R^2 = 1$ 95

3.6 Intégration du contrôleur ELM dans PowerFactory 96

Conclusion du chapitre 98

4 Validation et Analyse des Performances 100

4.1 Analyse statique comparative 100

4.1.1 Cas 1 : Fonctionnement sans contrôle optimal de la puissance réactive . 101

4.1.2 Cas 2 : Contrôle classique basé sur la loi $Q(P)$ 102

4.1.3 Cas 3 : Contrôle basé sur le modèle ELM 103

4.1.4 Résultats de l'analyse statique comparative 103
4.1.5 Conclusion de l'analyse statique 104
4.2 Analyse quasi-dynamique comparative 104
4.2.1 Méthodologie d'évaluation des stratégies de contrôle 105
4.2.2 Cas 1 : Fonctionnement sans contrôle de la puissance réactive 105
4.2.3 Cas 2 : Contrôle classique basé sur la loi $Q(P)$ 106
4.2.4 Cas 3 : Détermination de la puissance réactive optimale à l'aide du modèle ELM 106
4.3 Analyse comparative des résultats 108
4.3.1 Évolution de la tension au point de couplage commun 108
4.3.2 Analyse comparative de l'évolution de la tension au PCC 112
4.3.3 Analyse technique des courbes de *Line Loading* 113
4.3.4 Analyse comparative du chargement de la ligne 115
4.3.5 Évolution des pertes actives du réseau 115
4.3.6 Analyse comparative des pertes actives 116
4.4 Impact global sur les performances du réseau 117
4.4.1 Analyse globale des résultats 118
4.5 Discussion des résultats 119

Conclusion générale et perspectives **121**

A Dataset utilisé pour l'entraînement **126**

B Scripts Python pour l'entraînement du modèle ELM **127**

C Caractéristiques des transformateurs Kinshasa 30 kV **131**

Table des figures

1.1 Spectre du rayonnement solaire et notion de masse d'air (AM) 9
1.2 Composantes du rayonnement solaire : direct, diffus et réfléchi 10
1.3 Principe de fonctionnement d'une cellule photovoltaïque 13
1.4 Schéma équivalent d'une cellule photovoltaïque(1) 14
1.5 Schéma équivalent de la cellule photovoltaïque idéale 15
1.6 Caractéristique courant-tension (I-V) et puissance-tension (P-V) d'une cellule photovoltaïque montrant le point de puissance maximale (MPP) 16
1.7 Association des modules photovoltaïques en série et en parallèle pour former un générateur photovoltaïque(2) 17
1.8 Association série et parallèle des modules photovoltaïques pour constituer un générateur photovoltaïque (GPV). 18
1.9 Influence de la température sur les caractéristiques électriques d'un module photovoltaïque(3) 20
1.10 Influence de l'irradiation solaire sur les caractéristiques électriques d'un module photovoltaïque(4) 22
1.11 Schéma de principe d'un système photovoltaïque autonome comprenant les panneaux photovoltaïques, le régulateur de charge, les batteries de stockage et l'onduleur.(5) 23
1.12 Schéma de principe d'un système photovoltaïque raccordé au réseau (On-Grid). 24
1.13 Schéma de principe d'un système photovoltaïque hybride combinant production solaire, éolienne, stockage par batteries et groupe électrogène.(6) 25
1.14 Architecture simplifiée d'un système photovoltaïque raccordé au réseau comprenant le générateur photovoltaïque, l'onduleur DC/AC, le transformateur élévateur et le réseau électrique. 26

1.15 Exigences du grid code pour les centrales photovoltaïques : (a) plage tension–fréquence admissible, (b) réduction de la puissance active en fonction de la fréquence, (c) capacité d'injection de puissance réactive en fonction de la puissance active pour les centrales MSSP et LSSP.(7) 36

2.1 Schéma unifilaire du réseau étudié autour de la sous-station Campus modélisé dans DIgSILENT PowerFactory. 44
2.2 Profils journaliers de charge du réseau étudié (8) 46
2.3 Paramétrage du bloc PV System (ElmPvsys) dans DIgSILENT PowerFactory 2021 50
2.4 Mode d'entrée puissance imposée dans le bloc PV System (ElmPvsys) dans DIgSILENT PowerFactory 2021 51
2.5 Puissances et pertes du réseau d'étude Kinshasa 30 kV 55
2.6 Rapport des tensions et puissances aux différents nœuds du réseau 56
2.7 Rapport des puissances et chargement des lignes du réseau 56
2.8 Courbe de capabilité P–Q de l'onduleur de la centrale photovoltaïque dans DIgSILENT PowerFactory 60
2.9 Caractéristique $Q(P)$ et profil de production photovoltaïque 64
2.10 Variation de la charge et de la tension au PCC 64
2.11 Évolution des pertes et du chargement des lignes 64
2.12 Schéma unifilaire du réseau d'étude Kinshasa 30 kV avec intégration de la centrale photovoltaïque 70

3.1 Structure d'un neurone biologique : dendrites, corps cellulaire, axone et synapses. 76
3.2 Architecture d'un réseau de neurones à propagation avant utilisé dans le modèle Extreme Learning Machine (ELM). 78
3.3 Lecture du dataset et affichage des premières lignes dans l'environnement Python à l'aide de la bibliothèque *Pandas*. 89
3.4 Résumé de la structure du dataset et de la division des données en ensembles d'entraînement et de test dans l'environnement Python. 91
3.5 Résultats de l'évaluation du modèle ELM sur l'ensemble de test montrant les indicateurs statistiques MAE, RMSE et R^2. 93
3.6 Principe du contrôle classique basé sur l'optimisation de la puissance réactive . 97
3.7 Principe du contrôleur basé sur le modèle Extreme Learning Machine pour l'estimation de la puissance réactive optimale. 98

4.1 Évolution de la tension au point de couplage commun (PCC) sur 24 heures dans le cas sans contrôle de la puissance réactive. 109
4.2 Évolution de la tension au point de couplage commun (PCC) sur 24 heures avec la stratégie de contrôle classique basée sur la loi $Q(P)$. 111
4.3 Évolution de la tension au point de couplage commun (PCC) sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM). 112
4.4 Comparaison de l'évolution du taux de chargement de la ligne Makala–Campus pour les scénarios sans contrôle et avec contrôle classique $Q(P)$. 113
4.5 Évolution du taux de chargement de la ligne Makala–Campus sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM). . . . 114
4.6 Évolution des pertes actives du réseau sur 24 h sans contrôle de la puissance réactive. 116
4.7 Évolution des pertes actives du réseau sur 24 h avec contrôle classique Q(P). . . 116
4.8 Évolution des pertes actives du réseau Kinshasa 30 kV sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM). 116
4.9 Comparaison des performances du réseau pour les trois stratégies de contrôle de la puissance réactive. 117

Liste des tableaux

1.1 Limites de distorsion harmonique de tension selon la norme IEEE 519 36
1.2 Limites de distorsion harmonique du courant pour les systèmes 69 kV 37

3.1 Aperçu du dataset utilisé pour l'entraînement du modèle ELM 86
3.2 Aperçu des résultats de prédiction du modèle ELM 93

4.1 Comparaison des performances du réseau selon la stratégie de contrôle de la puissance réactive 102
4.2 Comparaison des performances du réseau pour différentes stratégies de contrôle 102
4.3 Comparaison des performances du réseau pour différentes stratégies de contrôle de la puissance réactive 104

A.1 Extrait du dataset généré pour l'entraînement du modèle ELM 126

C.1 Caractéristiques des cabines et transformateurs du réseau étudié 131

INTRODUCTION GÉNÉRALE

1. Contexte et justification de l'étude

La transition énergétique mondiale s'oriente progressivement vers une diversification des sources de production électrique, avec une place de plus en plus importante accordée aux énergies renouvelables. Parmi celles-ci, l'énergie solaire photovoltaïque occupe une position stratégique en raison de son caractère durable, de son abondance et de la diminution progressive de ses coûts d'installation. Dans les pays en développement, et particulièrement en République Démocratique du Congo, le recours aux systèmes photovoltaïques constitue une solution prometteuse pour renforcer la sécurité énergétique et améliorer l'accès à l'électricité. Dans ce contexte, plusieurs travaux de recherche ont été menés afin d'étudier les possibilités d'intégration des systèmes photovoltaïques dans les réseaux électriques existants. Le présent travail s'inscrit dans la continuité des recherches réalisées par Luzolo Ketsia, dont le travail de fin d'études portait sur « Intégration d'une centrale photovoltaïque dans un réseau de distribution : cas de la sous-station Campus ». Dans son étude, l'auteur a analysé la faisabilité technique de l'injection d'une centrale photovoltaïque dans le réseau de distribution alimentant la sous-station Campus de l'Université de Kinshasa, en mettant en évidence les impacts de cette intégration sur les profils de tension, les flux de puissance et le fonctionnement global du réseau. Toutefois, bien que cette étude ait permis de démontrer la faisabilité technique de l'intégration d'une centrale photovoltaïque dans le réseau étudié, la question de l'optimisation de l'exploitation de cette centrale et de son interaction dynamique avec le réseau reste ouverte. En particulier, la gestion de la puissance réactive injectée par l'onduleur photovoltaïque représente un enjeu important pour améliorer la régulation de la tension, réduire les pertes électriques et limiter le chargement des lignes du réseau. Dans cette perspective, le présent travail intitulé « Optimisation de l'intégration d'un système photovoltaïque dans un réseau électrique intelligent à l'aide du Machine Learning : Cas du réseau SNEL (Sous-station Campus) » propose une approche basée sur l'intelligence artificielle pour améliorer l'exploitation du système photovoltaïque intégré au réseau.

Plus précisément, l'étude consiste à développer un modèle d'apprentissage automatique basé sur l'algorithme Extreme Learning Machine (ELM) capable de déterminer la puissance réactive optimale à injecter par la centrale photovoltaïque en fonction de l'état du réseau. Pour ce faire, le réseau étudié est modélisé dans le logiciel DIgSILENT PowerFactory, à partir duquel un ensemble de données représentatif des conditions de fonctionnement du réseau est généré. Ces données sont ensuite utilisées pour entraîner le modèle ELM afin de prédire la consigne optimale de puissance réactive. Les performances de cette stratégie intelligente sont finalement comparées aux méthodes classiques de contrôle afin d'évaluer son impact sur la régulation de la tension, le chargement des lignes et les pertes actives du réseau. Ainsi, ce travail vise à contribuer au développement de méthodes de gestion intelligente des réseaux électriques intégrant des sources d'énergie renouvelables, en montrant l'intérêt de l'utilisation du Machine Learning dans l'optimisation de l'exploitation des systèmes photovoltaïques connectés au réseau.

2. Problématique

L'intégration d'une centrale photovoltaïque dans un réseau de distribution tel que celui alimentant la sous-station Campus pose plusieurs défis techniques :

— Comment maintenir la tension au point de couplage commun dans les limites réglementaires malgré la variabilité de la production solaire et des charges ?

— Comment réduire les surcharges des lignes critiques du réseau ?

— Comment minimiser les pertes actives tout en respectant les limites physiques de l'onduleur ?

Les stratégies classiques de commande de la puissance réactive ne permettent pas toujours d'obtenir une réponse optimale pour l'ensemble de ces critères simultanément. Elles ne s'adaptent pas dynamiquement aux conditions instantanées du réseau.

Dès lors, la question centrale de ce mémoire peut être formulée comme suit :

> Comment optimiser l'injection d'un système photovoltaïque dans un réseau de distribution en utilisant un modèle d'apprentissage automatique capable de prédire dynamiquement la consigne optimale de puissance réactive ?

3. Hypothèses de recherche

Dans le cadre de cette étude, certaines hypothèses sont formulées afin de simplifier la modélisation du système et de concentrer l'analyse sur les aspects essentiels liés à l'optimisation

de l'injection de puissance réactive dans le réseau de distribution. La modélisation et les simulations du système sont réalisées à l'aide du logiciel PowerFactory de DIgSILENT, qui est un outil largement utilisé dans l'ingénierie des systèmes électriques pour l'analyse, la simulation et l'optimisation des réseaux électriques.

Dans cet environnement, les différents constituants du système étudié — notamment le générateur photovoltaïque, l'onduleur, les lignes électriques et les charges — sont représentés sous forme d'objets interconnectés permettant de reproduire le comportement du réseau dans différentes conditions de fonctionnement. Dans cette étude, l'accent est principalement mis sur l'interaction entre le système photovoltaïque et le réseau électrique du côté AC, c'est-à-dire au niveau du point de couplage commun (PCC).

Par conséquent, la partie interne du générateur photovoltaïque située entre les panneaux solaires et l'entrée DC de l'onduleur n'est pas modélisée en détail. Cette partie est considérée comme une boîte noire, dans laquelle les phénomènes de conversion énergétique et de régulation interne sont supposés correctement gérés par les dispositifs électroniques de puissance.

Plus précisément, on suppose que le régulateur MPPT (Maximum Power Point Tracking) intégré à l'onduleur assure efficacement l'adaptation de l'impédance d'entrée afin d'extraire en permanence la puissance maximale disponible des panneaux photovoltaïques. De plus, ce régulateur maintient une tension stable au niveau du bus DC de l'onduleur, garantissant ainsi des conditions adéquates pour la conversion DC/AC.

En conséquence, la puissance active injectée dans le réseau est considérée comme une variable d'entrée connue, déterminée par les conditions d'irradiation solaire et les caractéristiques du champ photovoltaïque. Pour cette raison, le modèle de générateur photovoltaïque utilisé dans PowerFactory est configuré selon l'option *Active Power Input*. Ce choix permet de représenter directement la puissance active produite par le système photovoltaïque sans modéliser explicitement les phénomènes internes liés aux cellules photovoltaïques ou aux algorithmes MPPT.

Ainsi, la puissance active injectée dans le réseau est imposée au modèle en fonction des profils de production solaire, tandis que l'étude se concentre sur l'optimisation de la puissance réactive fournie ou absorbée par l'onduleur.

Cette approche présente l'avantage de réduire la complexité du modèle tout en conservant les éléments nécessaires à l'analyse du comportement du réseau de distribution. Elle permet également de se focaliser sur la problématique principale de ce travail, qui consiste à déterminer la consigne optimale de puissance réactive permettant d'améliorer les performances du réseau en termes de profil de tension, de pertes de puissance et de taux de chargement des lignes.

Enfin, il est supposé que les onduleurs photovoltaïques sont capables de fournir ou d'ab-

sorber de la puissance réactive dans la limite de leur courbe de capacité apparente, définie par la relation entre la puissance active injectée et la puissance apparente nominale de l'onduleur. Cette contrainte est prise en compte lors de l'optimisation de la puissance réactive, afin de garantir que les solutions obtenues restent physiquement réalisables.

4. Objectif général

L'objectif général de ce travail est :

D'optimiser l'injection d'un système photovoltaïque dans un réseau électrique de distribution à l'aide d'un algorithme *Extreme Learning Machine (ELM)*, afin de permettre une gestion adaptative et intelligente de la puissance réactive.

5. Objectifs spécifiques

Pour atteindre cet objectif général, les objectifs spécifiques suivants sont poursuivis :

— Analyser les stratégies classiques d'injection de puissance réactive des centrales photovoltaïques ;

— Modéliser le réseau d'étude et la centrale photovoltaïque sous DIgSILENT PowerFactory ;

— Définir une fonction objectif multi-critères intégrant la régulation de tension, la limitation des surcharges et la réduction des pertes ;

— Construire un dataset représentatif à partir de simulations quasi-dynamiques du réseau ;

— Développer et entraîner un modèle Extreme Learning Machine capable de prédire la consigne optimale de puissance réactive ;

— Comparer les performances de la stratégie intelligente proposée avec les méthodes classiques.

6. Méthodologie adoptée

La méthodologie suivie dans ce mémoire repose sur une approche combinant modélisation électrique et apprentissage automatique :

— Modélisation du réseau d'étude et de la centrale photovoltaïque dans PowerFactory ;

— Simulation quasi-dynamique pour générer différents états du réseau ;

— Formulation mathématique d'un problème d'optimisation de la puissance réactive ;

— Génération d'un dataset associant chaque état du réseau à une valeur optimale de puissance réactive ;

— Entraînement d'un modèle ELM sous Python pour prédire ;

— Intégration des consignes issues du modèle ELM dans PowerFactory sous forme de profils temporels ;

— Analyse comparative des performances.

7. Structure du mémoire

Le présent mémoire est structuré comme suit :

Le Chapitre 1 présente les centrales photovoltaïques, les stratégies classiques de commande et les exigences normatives relatives à leur intégration au réseau.

Le Chapitre 2 décrit le réseau d'étude, sa modélisation dans PowerFactory et l'analyse des méthodes traditionnellement d'injection.

Le Chapitre 3 développe le modèle d'optimisation basé sur l'Extreme Learning Machine et décrit la construction du dataset ainsi que l'entraînement du modèle.

Le Chapitre 4 présente l'analyse comparative des performances entre la stratégie ELM proposée et les méthodes classiques.

Enfin, une conclusion générale synthétise les résultats obtenus et propose des perspectives futures.

Chapitre 1

GÉNÉRALITÉS SUR LES SYSTÈMES PHOTOVOLTAÏQUES ET EXIGENCES NORMATIVES

1.1 Introduction

L'énergie qui a pour mode de transférer le travail ou la chaleur, joue un rôle essentiel dans la vie d'un individu.

Elle est définie par Max Planck (Physicien allemand et prix Nobel de la Physique) comme la capacité qu'a un corps de produire du travail (9). L'énergie se manifeste sous diverses formes entre autres : énergie mécanique, électrique, etc. Les sources d'énergie primaire sont des formes d'énergie disponibles dans la nature avant toute transformation ou conversion par l'homme comme le soleil, l'eau, etc. Elles sont classifiées en deux grandes catégories :

Les sources d'énergie non renouvelables dites sources épuisables à l'usage comme : pétrole, gaz naturel etc. Les sources d'énergie renouvelables, celles dites inépuisables à l'échelle humaine telles que : énergie hydraulique, énergie éolienne, énergie solaire photovoltaïque, etc.

Le photovoltaïque : Ayant pour source primaire le soleil, est la conversion de la lumière solaire en électricité.

1.2 Principe de fonctionnement d'une centrale photovoltaïque

1.2.1 Le rayonnement solaire

Le rayonnement solaire est constitué des photons dont la longueur d'onde s'étend de l'ultraviolet (0.2 μm) à l'infrarouge lointain (2.5 μm). On utilise la notion AM pour Air Mass afin de caractériser le spectre solaire en termes d'énergie émise.

L'énergie totale transportée par le rayonnement solaire sur la distance soleil-terre est de l'ordre de 1350 W/m^2 (AM0) dans l'espace hors atmosphère terrestre (Figure 1.1). Lorsque le rayonnement solaire traverse l'atmosphère, il subit une atténuation et une modification de son spectre, à la suite des phénomènes d'absorption et de diffusion dans les gaz, l'eau et les poussières. Ainsi, la couche d'ozone absorbe une partie du spectre lumineux provenant du soleil, et en particulier une partie des ultraviolets dangereux pour la santé.

Le rayonnement solaire direct reçu au niveau du sol (à 90° d'inclinaison) atteint environ 1000 W/m^2 du fait de l'absorption dans l'atmosphère (AM1). Cette valeur change en fonction de l'inclinaison des rayons lumineux par rapport au sol. Plus l'angle de pénétration θ est faible, plus l'épaisseur atmosphérique que les rayons auront à traverser sera grande, d'où une perte d'énergie conséquente. Par exemple, l'énergie directe transportée par le rayonnement solaire atteignant le sol avec un angle de 48° avoisine les 833 W/m^2 (AM1.5).(3)

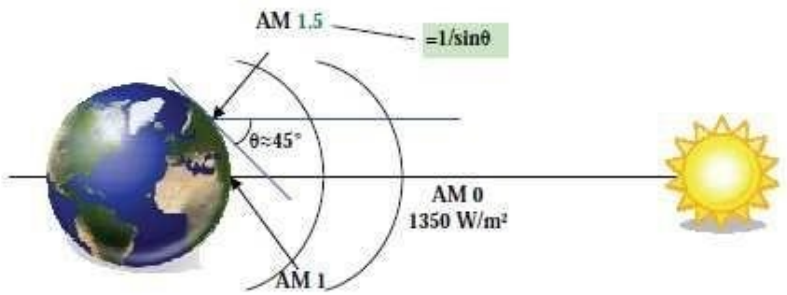

FIGURE 1.1. Spectre du rayonnement solaire et notion de masse d'air (AM)

Au niveau du sol, le rayonnement global reçu par une surface plane d'inclinaison quelconque est constitué de trois composantes principales :

Rayonnement direct :

C'est le flux solaire sous forme de rayons parallèles provenant du disque solaire sans avoir été dispersé par l'atmosphère.

Rayonnement diffus :

C'est la partie du rayonnement provenant du soleil ayant subi de multiples réflexions (dispersions) dans l'atmosphère.

Rayonnement réfléchi :

C'est la partie de l'éclairement solaire réfléchi par le sol, ce rayonnement dépend directement de la nature du sol (nuage, sable...). Il se caractérise par un coefficient propre de la nature du lien appelé Albédo $0 \leq \varepsilon \leq 1$.

Rayonnement global

Un plan reçoit de la part du sol un rayonnement global qui est le résultat de la superposition des trois compositions direct, diffus et réfléchi.

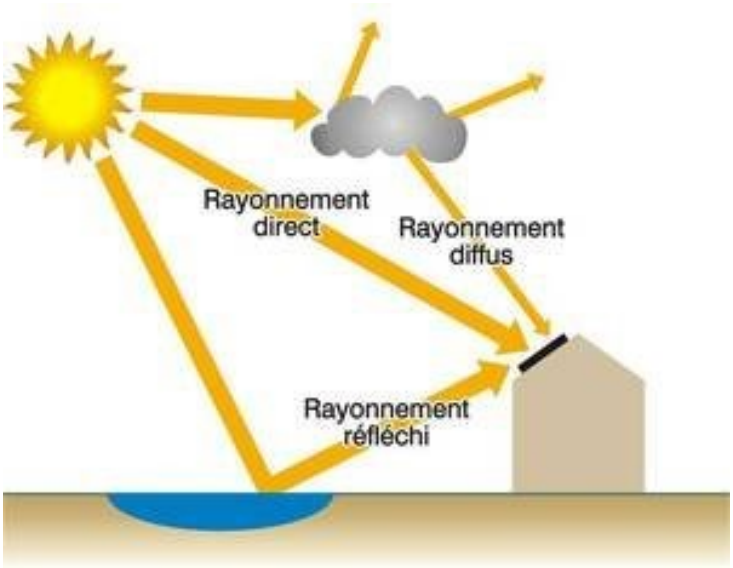

FIGURE 1.2. Composantes du rayonnement solaire : direct, diffus et réfléchi

1.2.2 La cellule solaire :

Les cellules photovoltaïques ou les plaques solaires sont des composants optoélectroniques composés de matériaux semi-conducteurs qui transforment directement la lumière solaire en électricité par un processus appelé « effet photovoltaïque ». Ce phénomène a été découvert par E. Becquerel (physicien français) en 1839.(10)

La structure d'une cellule solaire :

Une cellule photovoltaïque est basée sur le phénomène physique appelé effet photovoltaïque. Ce dernier est la conséquence de la conversion de l'énergie solaire en énergie électrique. Il se manifeste lors de l'interaction du rayonnement solaire avec les électrons du corps solide. La tension générée peut varier de 0.3 V à 0.7 V, en fonction du matériau utilisé, des dispositions ainsi que de la température de la cellule et de son vieillissement.

La cellule photovoltaïque est composée d'un matériau semi-conducteur généralement à base de silicium, capable à la fois de permettre le transfert d'énergie du photon absorbé à un électron et la collecte de cet électron de plus haute énergie par un circuit extérieur.

La taille de chaque cellule varie de quelques centimètres carrés jusqu'à 100 cm^2 ou plus. Sa forme peut être circulaire, carrée ou dérivée de ces deux géométries.

Type de cellules :

Les cellules monocristallines : Elles sont issues d'un seul bloc de silicium fondu, donc très "pures", mais aussi plus chères à la production, donc à la vente. Ces cellules sont en générale octogonales et d'une couleur uniforme foncée (bleu marine ou gris).

- C'est la première génération des photopiles ;
- Un taux de rendement excellent (12–16%) (23% en laboratoire) ;
- Une méthode de fabrication laborieuse et difficile, donc très chère ;
- Il faut une grande quantité d'énergie pour obtenir du cristal pur.

Les cellules poly-cristallines : Elles sont élaborées à partir d'un bloc de silicium cristallisé en forme de cristaux multiples. Vues de près, on peut voir les orientations différentes des cristaux. Les cellules sont en générale de forme rectangulaire et sont bleu nuit avec des reflets.

- Coût de production moins élevé ;
- Procédé nécessitant moins d'énergie ;
- Rendement 11–13% (18% en laboratoire).

Les cellules amorphes :

Les cellules amorphes Elles sont produites à partir d'un "gaz de silicium" qui est projeté sur du verre, du plastique souple ou du métal, par un procédé de vaporisation sous vide.

La cellule est grise très foncé. C'est la cellule des calculatrices et des montres dites solaires, car ce type de cellule est bon marché et la technologie est utilisable sur de nombreux supports, notamment des supports souples.

— Coût de production bien plus bas ;
— Rendement plus bas : 8–10% (13% en laboratoire) ;
— Durée de vie plus faible.

C'est le silicium amorphe que l'on trouve le plus souvent dans les produits de consommation comme les calculatrices, les montres, etc. Toutefois, ils réagissent mieux à des températures élevées ou à une lumière diffuse.

De plus, les cellules mono et poly-cristallines sont les types de cellules les plus répandues sur le marché du photovoltaïque (environ 60% de la production).

Les cellules nanocristallines

— Une des dernières générations de photopiles ;
— Fonctionnent selon un principe qui différencie les fonctions d'absorption de la lumière et de séparation des charges électriques ;
— Rendement global de 10.4 %, confirmé par des mesures au laboratoire ;
— Procédé et coût de production encore plus bas.

Principe de fonctionnement d'une cellule photovoltaïque

Jonction PN L'effet photovoltaïque utilisé dans les cellules solaires permet de convertir directement l'énergie lumineuse des rayons solaires en électricité via la production et le transport dans un matériau semi-conducteur de charges électriques positives et négatives sous l'effet de la lumière.

Ce matériau comporte deux parties, l'une présentant un excès d'électrons (type n) et l'autre un déficit en électrons (type p) créant ainsi une jonction PN avec une barrière de potentiel. Lorsque la première est mise en contact avec la seconde, les électrons en excès dans le matériau diffusent. dans le matériau p. La zone initialement dopée n devient chargée positivement, et la zone initialement dopée p chargée négativement. Il se crée par conséquent un champ électrique

entre elles qui tend à repousser les électrons dans la zone n et les trous vers la zone p. Une jonction (dite p-n) a été formée.(11)

En ajoutant des contacts métalliques sur les zones n et p, une diode est obtenue. Lorsque la jonction est éclairée, les photons d'énergie égale ou supérieure à la largeur de la bande interdite communiquent leur énergie aux atomes, chacun fait passer un électron de la bande de valence dans la bande de conduction et laisse ainsi un trou capable de se mouvoir, engendrant ainsi une paire électron-trou. Si une charge est reliée aux bornes de la cellule, les électrons de la zone n rejoindront les trous de la zone p en passant par la connexion extérieure, donnant naissance à la circulation du courant électrique étant donné l'existence d'une différence de potentiel aux bornes de la cellule.

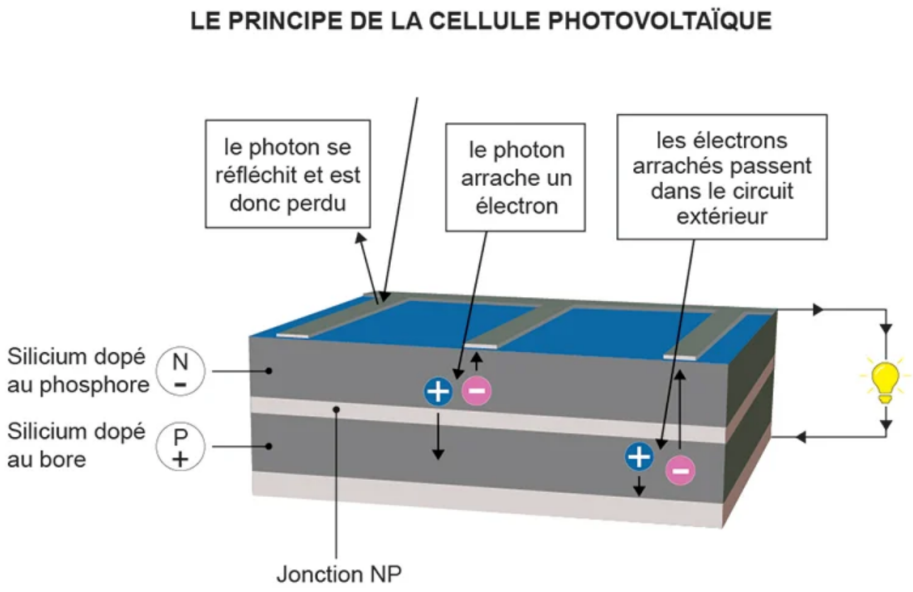

FIGURE 1.3. Principe de fonctionnement d'une cellule photovoltaïque

Principe de la conversion photovoltaïque Le principe de la conversion photovoltaïque est résumé comme par :

— Absorption de la lumière et création de paire électron/trou ;

— Séparation des paires électron/trous sous l'effet d'un champ induit ;

— Transport des charges vers les électrodes ; collection des charges.

Modèle équivalent d'une cellule photovoltaïque

Le modèle mathématique associé à une cellule se trouve à partir de celui d'une jonction P–N. On y ajoute le courant I_{ph}, proportionnel à l'éclairement, ainsi qu'un terme qui modélise les phénomènes externes. Le courant I issu de la cellule s'écrira alors :

$$I = I_{ph} - I_{od}\left(e^{\frac{q(U+R_sI)}{kT}} - 1\right) - \frac{U + R_sI}{R_{sh}} \tag{1.1}$$

$$I_d = I_{od}\left(e^{\frac{q(U+R_sI)}{kT}} - 1\right) \tag{1.2}$$

Donc, l'expression (1.1) est celle de la caractéristique $I(V)$.

Avec :

— I_{ph} : photo courant ou courant produit par l'éclairement (A)

— I_{od} : courant de saturation de la diode (A)

— R_s : résistance série (Ohm)

— R_{sh} : résistance shunt (Ohm)

— k : constante de Boltzmann $(k = 1.38 \times 10^{-23})$

— q : charge de l'électron $(q = 1.602 \times 10^{-19} C)$

— T : température de la cellule (K)

De l'équation (1.1), on peut déduire un schéma équivalent, comme le montre la figure 1.4.

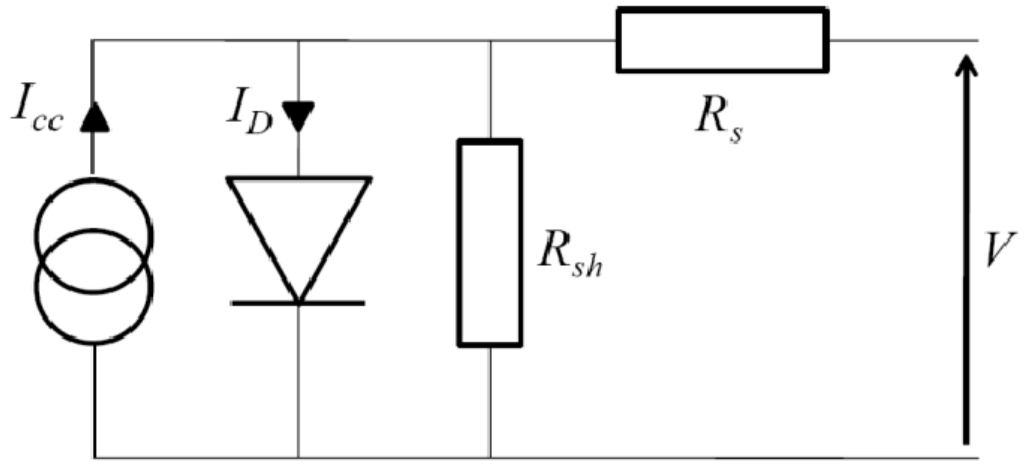

FIGURE 1.4. Schéma équivalent d'une cellule photovoltaïque(1)

La diode sur la figure ci-dessus modélise le comportement de la cellule dans l'obscurité. Le générateur de courant modélise le courant I_{ph} produit par un éclairement.

Enfin, les deux résistances modélisent les pertes internes :

— R_s : résistance série modélisant les pertes ohmiques du matériau ;

— R_{sh} : résistance shunt modélisant les courants parasites qui traversent la cellule.

Idéalement, on peut toutefois négliger R_s et I devant U, puis travailler avec un modèle simplifié :

$$I = I_{ph} - I_{od}\left(e^{\frac{qU}{kT}} - 1\right) - \frac{U}{R_{sh}} \tag{1.3}$$

Le fait que la résistance shunt est très élevée par rapport à la résistance série, on peut de nouveau négliger le courant dévié dans la branche R_{sh}. On aura :

$$I = I_{ph} - I_{od}\left(e^{\frac{qU}{kT}} - 1\right) \tag{1.4}$$

Le schéma équivalent de la fig. 1.4 deviendra celui de la cellule idéale comme suit :

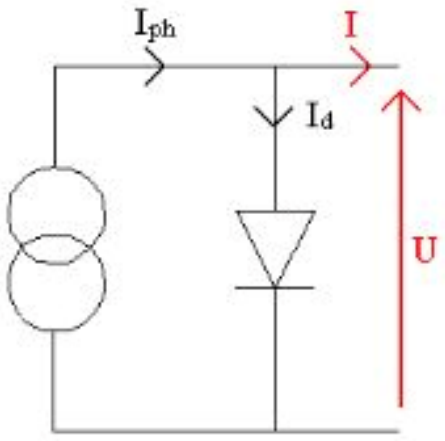

FIGURE 1.5. Schéma équivalent de la cellule photovoltaïque idéale

Caractéristique courant-tension d'une cellule photovoltaïque

Sous un éclairement donné, toute cellule photovoltaïque est caractérisée par une courbe courant-tension $(I\text{-}V)$ représentant l'ensemble des configurations électriques que peut prendre la cellule. Trois grandeurs physiques définissent cette courbe :

— Sa tension à vide V_{oc} : cette valeur représente la tension générée par une cellule éclairée non raccordée (c'est-à-dire pour $I = 0$).

— Son courant de court-circuit I_{cc} : cette valeur représente le courant généré par une cellule lorsque la tension à ses bornes est nulle $(V = 0)$.

— éclairée raccordée à elle-même (c'est-à-dire pour $U = 0$).

— Son point de puissance maximal : MPP (en anglais : *Maximum Power Point*) obtenu pour une tension et un courant optimaux V_{opt} et I_{opt} (parfois aussi appelés V_{mpp} et I_{mpp}).(12)

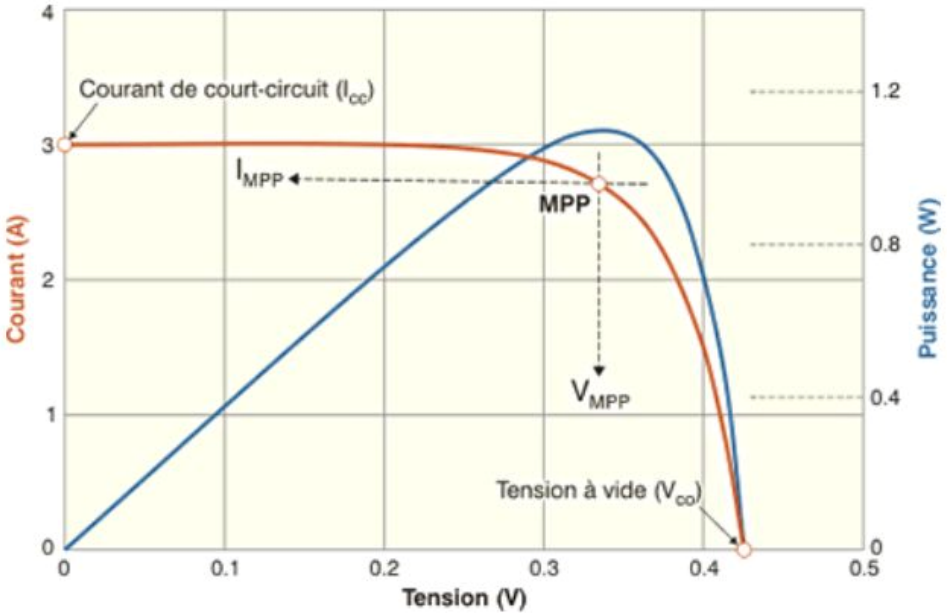

FIGURE 1.6. Caractéristique courant-tension (I-V) et puissance-tension (P-V) d'une cellule photovoltaïque montrant le point de puissance maximale (MPP)

photovoltaïque (GPV) sur toute l'étendue de la caractéristique courant-tension. D'où, le GPV est considéré comme une source de puissance avec un point P_{max} où la puissance se trouve maximale. Il est donc intéressant de se placer sur ce point pour tirer le maximum d'énergie et ainsi exploiter au mieux la puissance crête installée.

Il est important de noter que certains régulateurs solaires (tels que les régulateurs MPPT) réalisent une adaptation d'impédance afin de faire travailler à chaque instant le GPV à son point correspondant à P_{max}.

Constitution d'un générateur photovoltaïque

De la cellule au système complet, une cellule photovoltaïque isolée ne produit qu'une puissance très limitée, environ 2 à 3 Wc avec une tension proche de 0,5 V (mesurée dans les conditions standards de 1000 W/m^2 à 25°C). Cette performance est insuffisante pour répondre aux besoins électriques domestiques ou industriels.(3)

Pour augmenter la capacité énergétique, on procède à des associations stratégiques :

— **Les modules :** créés en reliant plusieurs cellules en série ou en parallèle afin d'atteindre les caractéristiques électriques voulues.

— **Le générateur photovoltaïque (GPV) :** formé par l'assemblage de ces modules (ou panneaux) en série et/ou en parallèle afin de délivrer la puissance totale requise par l'installation.

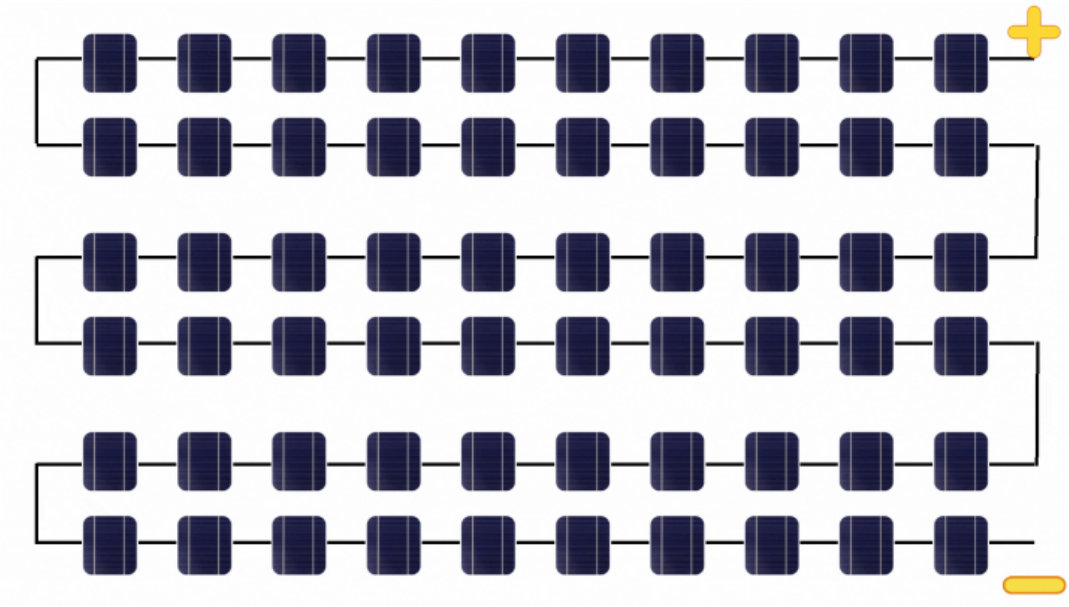

FIGURE 1.7. Association des modules photovoltaïques en série et en parallèle pour former un générateur photovoltaïque(2)

Le passage du module au panneau complet nécessite l'intégration de composants de sécurité afin de garantir la fiabilité du système :

— **La diode de série :** elle est installée pour bloquer les courants inverses qui pourraient endommager l'équipement ou vider les batteries durant la nuit.

— **La diode de dérivation (By-pass) :** placée en parallèle, elle est cruciale en cas de déséquilibre (comme l'ombrage partiel d'une cellule). Elle permet de contourner les cellules défaillantes, limitant ainsi l'échauffement dû à la tension inverse et réduisant au maximum les pertes de production globale.

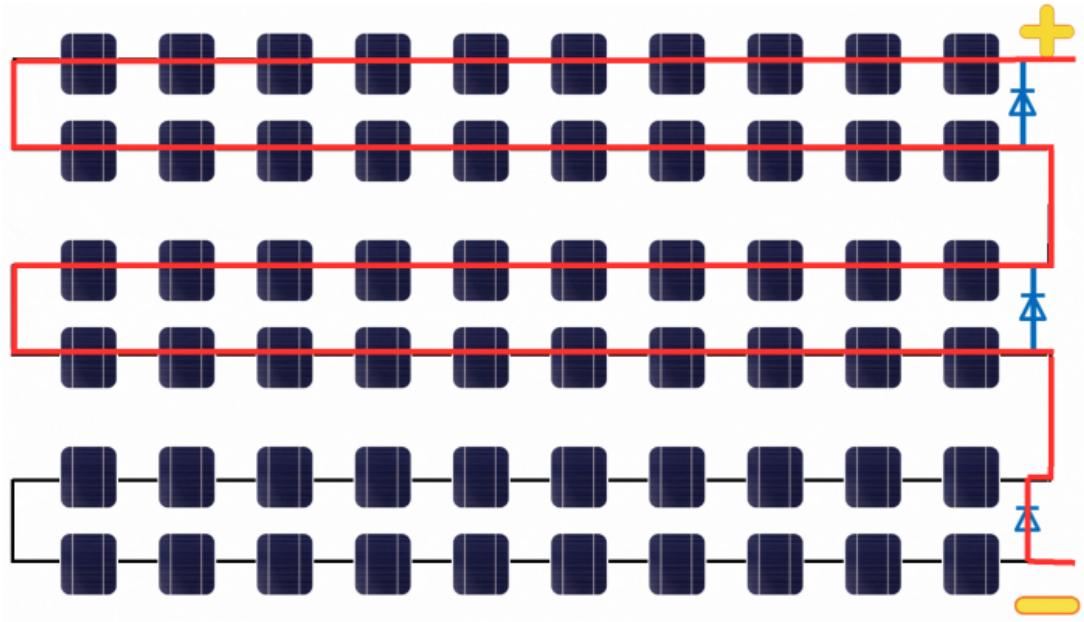

FIGURE 1.8. Association série et parallèle des modules photovoltaïques pour constituer un générateur photovoltaïque (GPV).

Facteurs influençant le comportement d'un générateur photovoltaïque

Le comportement d'un générateur photovoltaïque dépend de plusieurs paramètres physiques et environnementaux qui influencent directement sa production d'énergie électrique. Les principaux facteurs sont l'irradiation solaire, la température des cellules, l'orientation et l'inclinaison des modules, les pertes dans les composants du système ainsi que les conditions atmosphériques.

Un générateur photovoltaïque convertit l'énergie solaire en énergie électrique grâce à l'effet photovoltaïque observé dans les matériaux semi-conducteurs. Les caractéristiques électriques d'un module photovoltaïque sont généralement représentées par la courbe courant-tension (I–V) et la courbe puissance-tension (P–V). Ces caractéristiques varient en fonction des conditions climatiques.

Parmi les paramètres les plus influents, l'éclairement solaire et la température jouent un rôle fondamental. L'irradiation détermine la quantité de courant générée par la cellule, tandis que la température influence principalement la tension et donc le rendement global du module photovoltaïque.

De plus, d'autres facteurs peuvent également modifier les performances d'un système photovoltaïque, notamment :

— l'ombrage partiel des modules ;

— la résistance interne des cellules ;

— la qualité de l'onduleur et du système de conversion ;

— les pertes dans les câbles et les transformateurs ;

— le vieillissement des matériaux.

Ces paramètres doivent être pris en compte lors de la modélisation et de la simulation des systèmes photovoltaïques afin d'obtenir une estimation réaliste de leur production énergétique.

Influence de la température

La température des cellules photovoltaïques a un impact significatif sur les performances du générateur photovoltaïque. Lorsque la température augmente, la tension de sortie de la cellule diminue tandis que le courant augmente légèrement. Cependant, la diminution de la tension est généralement plus importante que l'augmentation du courant, ce qui entraîne une réduction de la puissance maximale délivrée par le module.

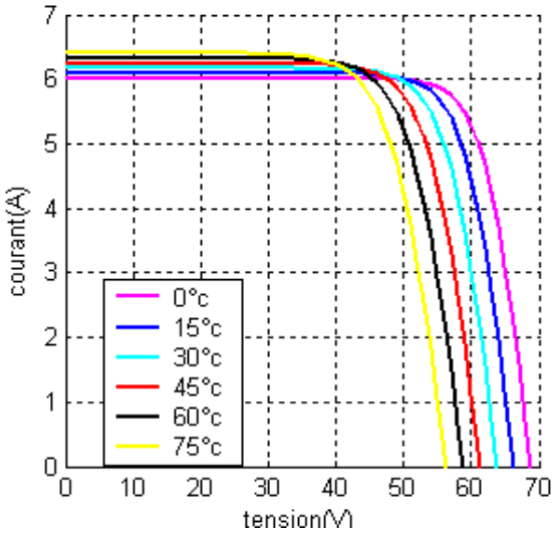

(a) Influence de la température sur la caractéristique courant–tension (I–V)

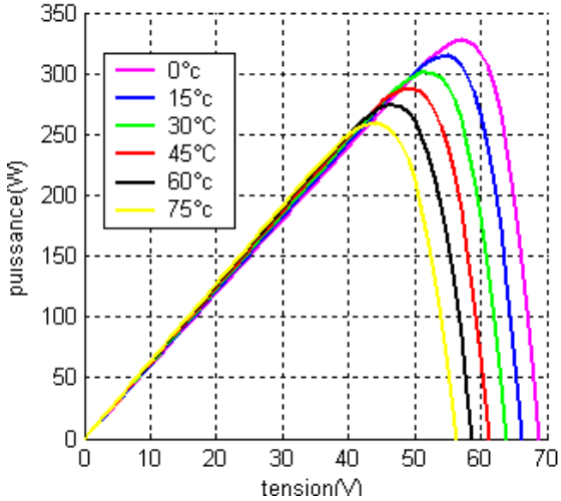

(b) Influence de la température sur la caractéristique puissance–tension (P–V)

FIGURE 1.9. Influence de la température sur les caractéristiques électriques d'un module photovoltaïque(3)

Ce phénomène s'explique par l'augmentation de l'énergie thermique dans les matériaux semi-conducteurs, ce qui modifie les propriétés électriques de la jonction PN. En pratique, l'augmentation de la température provoque une diminution de la tension en circuit ouvert et une légère augmentation du courant de court-circuit. La puissance maximale produite par le module diminue généralement d'environ 0,3 % à 0,5 % par degré Celsius au-dessus de la température standard de test (25°C).

Par conséquent, dans les régions chaudes, la performance des systèmes photovoltaïques peut être affectée si la ventilation et la dissipation thermique ne sont pas correctement assurées.

La température des cellules dépend elle-même de plusieurs facteurs, notamment :

— l'irradiation solaire ;

— la température ambiante ;

— la vitesse du vent ;

— le type de montage du module.

Ces éléments doivent être pris en compte dans les modèles de simulation des systèmes photovoltaïques.

Influence de l'éclairement solaire

L'éclairement solaire, ou irradiance, représente la puissance du rayonnement solaire reçue par unité de surface, généralement exprimée en W/m^2. Il constitue le facteur principal déterminant la production d'énergie d'un système photovoltaïque.

Lorsque l'éclairement augmente, le courant généré par la cellule photovoltaïque augmente proportionnellement. En effet, une intensité lumineuse plus élevée entraîne une génération plus importante de paires électron-trou dans le semi-conducteur, ce qui augmente le courant de sortie.

Contrairement à la température, l'éclairement a une influence relativement faible sur la tension de la cellule, mais une influence très importante sur le courant et donc sur la puissance produite. La puissance maximale du module photovoltaïque est donc fortement corrélée au niveau d'irradiation. Dans des conditions d'irradiation standard (1000 W/m^2), les modules atteignent leur puissance nominale.

En revanche, lorsque l'irradiation diminue, la puissance produite diminue presque proportionnellement. Les variations d'éclairement sont généralement causées par :

— les conditions météorologiques (nuages, brouillard) ;

— l'angle d'incidence du rayonnement solaire.

Ces variations rendent nécessaire l'utilisation de systèmes de suivi du point de puissance maximale (MPPT – Maximum Power Point Tracking) afin d'extraire en permanence la puissance maximale disponible du générateur photovoltaïque.(12)

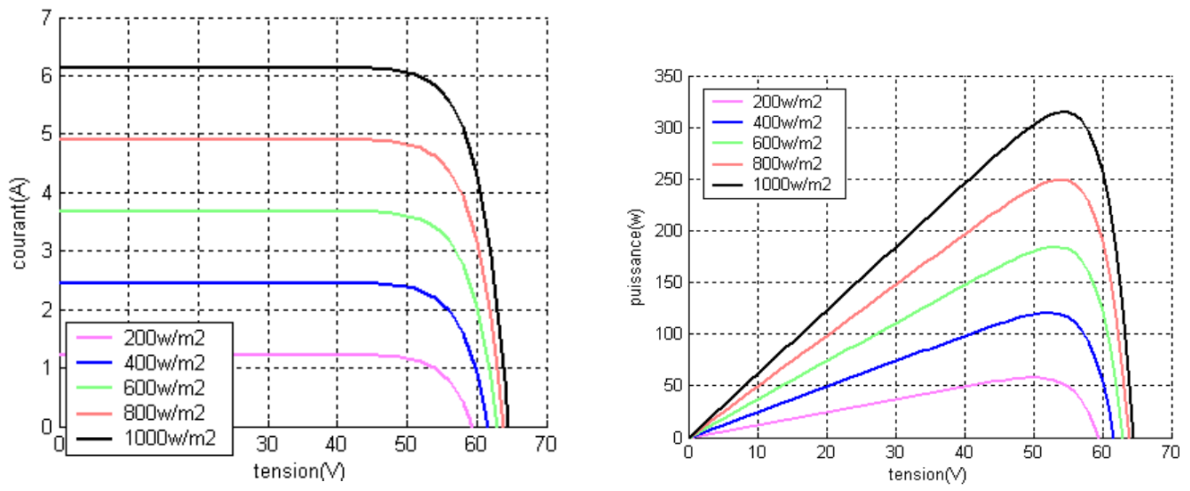

(a) Influence de l'irradiation sur la caractéristique courant–tension (I–V)

(b) Influence de l'irradiation sur la caractéristique puissance–tension (P–V)

FIGURE 1.10. Influence de l'irradiation solaire sur les caractéristiques électriques d'un module photovoltaïque(4)

1.3 Les différents types de systèmes photovoltaïques

1.3.1 Installations photovoltaïques autonomes

Une installation photovoltaïque autonome (aussi appelée système en *site isolé*) est un dispositif de production d'électricité conçu pour fonctionner de manière totalement indépendante du réseau électrique public.

Le but premier d'une installation autonome est de rendre possible l'électrification de sites hors réseau. Le générateur photovoltaïque produit l'énergie nécessaire aux besoins courants tels que l'alimentation des appareils électriques et l'éclairage.

Afin de pallier l'absence de soleil, l'énergie produite est généralement stockée dans des batteries. Un élément clé du système est le régulateur de charge, dont le rôle est de protéger les batteries contre les usures prématurées liées aux variations de charge et de décharge.

Si l'utilisateur souhaite alimenter des équipements standards fonctionnant en courant alternatif, un onduleur doit être ajouté au système afin de transformer le courant continu produit par les panneaux photovoltaïques en courant alternatif utilisable par les appareils électriques.

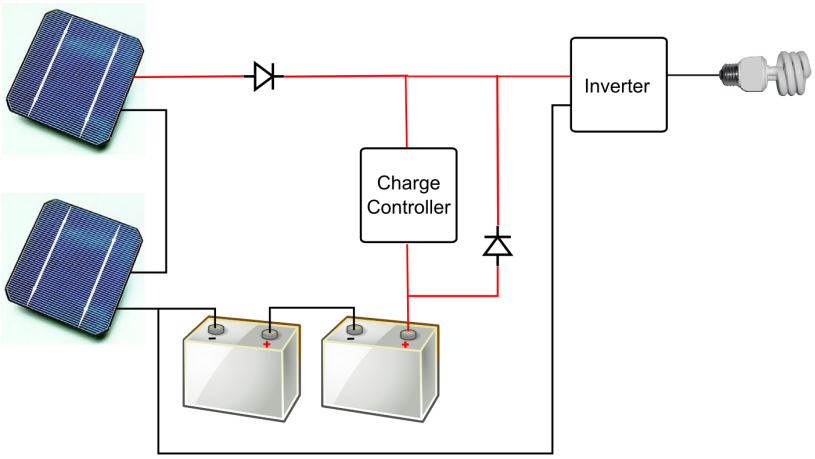

FIGURE 1.11. Schéma de principe d'un système photovoltaïque autonome comprenant les panneaux photovoltaïques, le régulateur de charge, les batteries de stockage et l'onduleur.(5)

1.3.2 Systèmes photovoltaïques raccordés au réseau (On-Grid)

Un système photovoltaïque raccordé au réseau (ou *On-Grid*) est une installation solaire reliée directement au réseau électrique public. Contrairement aux systèmes autonomes, il ne nécessite généralement pas de batteries car le réseau sert de « réservoir » pour absorber ou fournir de l'énergie selon les besoins.

Il s'adresse principalement aux particuliers et aux entreprises souhaitant intégrer une source d'énergie renouvelable dans des régions bénéficiant d'un fort ensoleillement. L'avantage majeur de cette configuration est la suppression du stockage par batteries — le composant le plus coûteux et complexe — puisque le réseau électrique national fait office de réservoir d'énergie virtuel.

Deux modes d'exploitation sont généralement possibles :

— **L'injection totale :** l'intégralité de la production solaire est envoyée sur le réseau électrique.

— **L'injection de surplus :** seule la part d'énergie non consommée par le bâtiment est injectée dans le réseau.

La gestion des flux d'énergie nécessite un dispositif de comptage spécifique : un compteur pour mesurer l'énergie soutirée au fournisseur et un second compteur pour quantifier l'énergie réinjectée dans le réseau. Dans le cas d'une injection totale, un troisième compteur, appelé compteur de non-consommation, peut être ajouté.

Enfin, l'installation requiert un onduleur homologué par la compagnie d'électricité afin de garantir la conversion du courant continu produit par les panneaux photovoltaïques en un signal alternatif parfaitement sinusoïdal, conforme aux normes de qualité du réseau électrique.

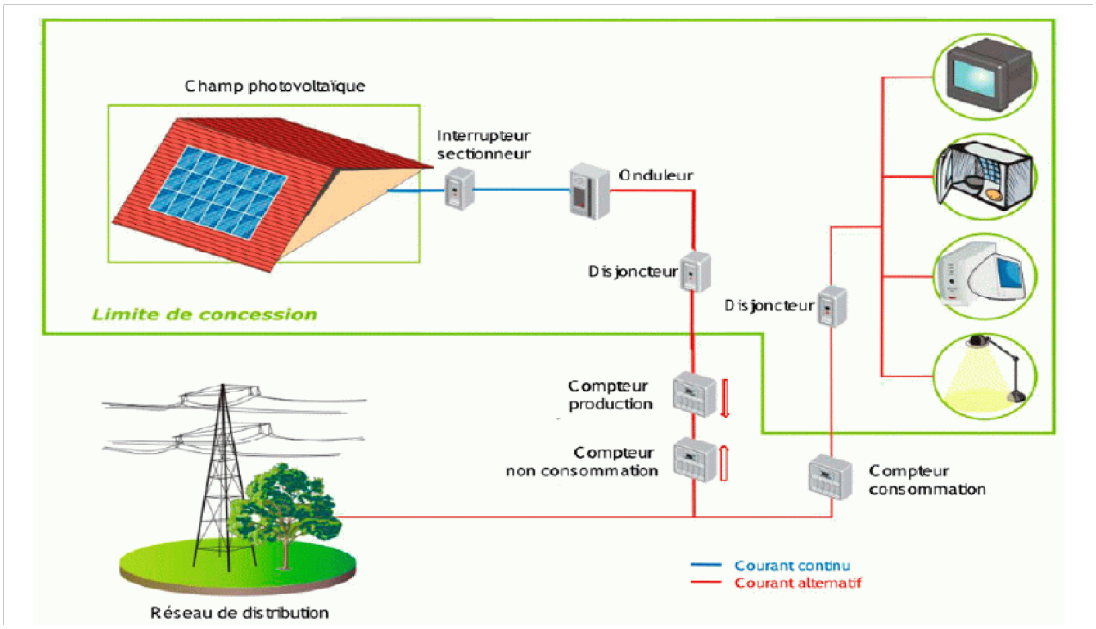

FIGURE 1.12. Schéma de principe d'un système photovoltaïque raccordé au réseau (On-Grid).

Le générateur photovoltaïque est relié à un onduleur qui convertit le courant continu en courant alternatif injecté dans le réseau de distribution.(8)

1.3.3 Installations photovoltaïques hybrides

Les installations photovoltaïques hybrides combinent plusieurs sources de production d'énergie afin d'assurer une alimentation électrique plus fiable et continue. En plus du générateur photovoltaïque, ces systèmes peuvent intégrer d'autres sources d'énergie telles qu'une turbine éolienne, un groupe électrogène diesel ou encore une unité de cogénération.

Cette configuration multi-énergies est particulièrement utilisée dans les zones isolées ou dans les sites où la production solaire seule ne permet pas de satisfaire l'ensemble de la demande énergétique. L'objectif principal d'un système hybride est d'améliorer la continuité de l'alimentation électrique tout en optimisant l'utilisation des ressources énergétiques disponibles.

Dans un tel système, le générateur photovoltaïque constitue généralement la source principale d'énergie renouvelable, tandis que les autres sources interviennent en complément lorsque la production solaire est insuffisante, notamment pendant la nuit ou lors de conditions météorologiques défavorables.

L'utilisation d'un système de gestion d'énergie permet d'assurer la coordination entre les différentes sources de production et les dispositifs de stockage, garantissant ainsi un fonctionnement optimal du système hybride.

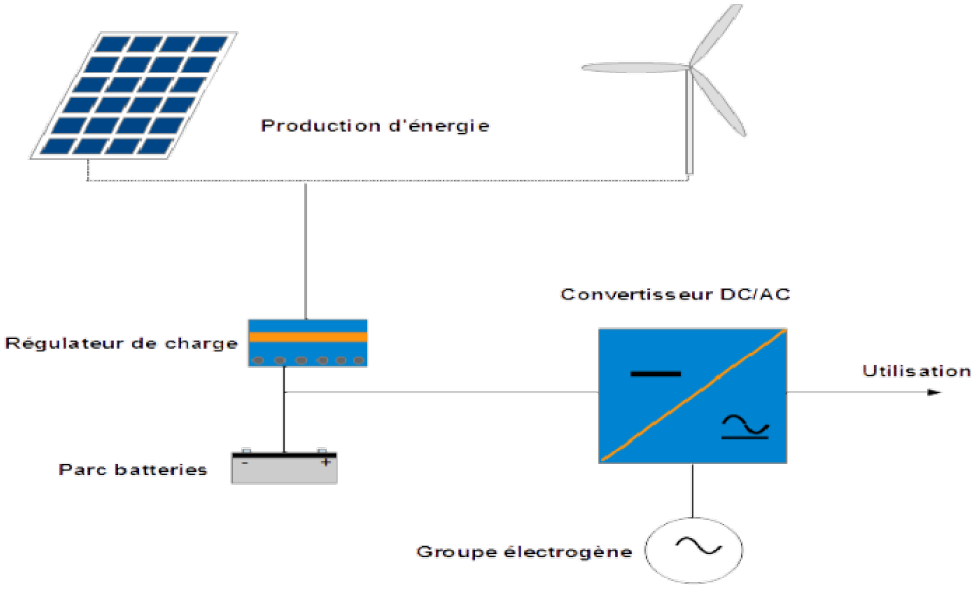

FIGURE 1.13. Schéma de principe d'un système photovoltaïque hybride combinant production solaire, éolienne, stockage par batteries et groupe électrogène.(6)

Source : schéma adapté par l'auteur à partir de la littérature sur les systèmes photovoltaïques hybrides.

1.3.4 Composants d'un système raccordé au réseau

Un système photovoltaïque (SPV) raccordé au réseau est composé de deux sous-ensembles principaux :

Le sous-système de conversion photovoltaïque

Cette unité assure la transformation du rayonnement solaire incident en énergie électrique sous forme de courant continu (DC). Elle est structurellement composée de :

— **Générateur photovoltaïque :** ensemble de modules photovoltaïques interconnectés et solidement fixés sur des structures porteuses.

— **Infrastructure de transport DC :** réseaux de câblages spécifiques permettant d'acheminer le courant continu produit par les modules.

— **Étage d'adaptation de tension :** intégration éventuelle de convertisseurs DC–DC (hacheurs) afin d'assurer l'optimisation du point de puissance maximale (MPPT).

— **Bus de regroupement DC :** interface centralisant la puissance totale générée avant sa conversion en courant alternatif.

L'interface de raccordement au réseau

Ce bloc fonctionnel gère l'injection de l'énergie produite sur le réseau électrique public et regroupe :

— **Onduleur de puissance :** convertisseur statique DC–AC assurant la conversion du courant continu produit par les panneaux photovoltaïques en courant alternatif compatible avec le réseau.

— **Circuit de liaison AC :** câblage spécifique destiné à transporter la puissance alternative vers le point de raccordement.

— **Dispositif d'élévation de tension :** un transformateur est généralement utilisé afin d'adapter la tension de sortie de l'onduleur aux exigences du réseau de distribution.

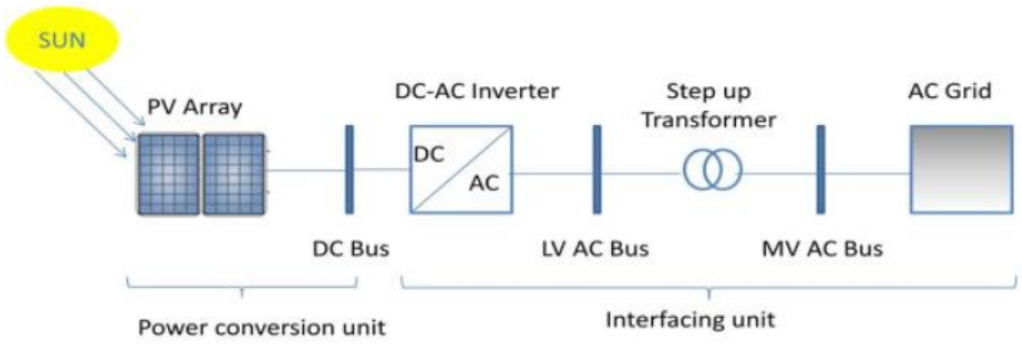

FIGURE 1.14. Architecture simplifiée d'un système photovoltaïque raccordé au réseau comprenant le générateur photovoltaïque, l'onduleur DC/AC, le transformateur élévateur et le réseau électrique.

Source : adapté de PV Education (2019).

Techniques d'intégration des centrales photovoltaïques(8)

Le raccordement d'un système photovoltaïque s'effectue soit en Basse Tension (BT), soit en Moyenne Tension (MT), selon la puissance de l'installation. Pour les centrales de grande envergure, l'utilisation d'un transformateur élévateur en sortie d'onduleur est systématique afin d'adapter le niveau de tension à celui du point de livraison.

L'intégration au réseau suit un protocole rigoureux incluant le choix du point de raccordement, la mise en conformité normative (puissance, tension, fréquence) et la coordination de la

mise en service avec le gestionnaire du réseau. Le choix de la technique d'intégration dépend de paramètres critiques tels que la capacité de la centrale, la topologie du réseau local et les objectifs de performance (soutien de tension, réduction des pertes).

On distingue principalement quatre méthodes d'intégration :

1. **Intégration directe au réseau de distribution (« Au fil du soleil »)**

   Cette configuration consiste à injecter la production via un ou plusieurs onduleurs connectés au Point de Couplage Commun (PCC).

   — **Avantages :** simplicité de mise en œuvre, rendement élevé et coûts d'investissement réduits.
   — **Limites :** dépendance totale au réseau (arrêt en cas de coupure), absence de régulation de fréquence et sensibilité à l'intermittence solaire.
   — **Note technique :** un transformateur élévateur est requis pour les puissances supérieures à 500 kW.

2. **Intégration via système hybride**

   Cette approche associe le champ photovoltaïque à un stockage électrochimique (batteries) géré par des onduleurs bidirectionnels.

   — **Fonctionnement :** permet l'autoconsommation avec injection du surplus ou le fonctionnement en mode îloté (secours) en cas de défaillance du réseau.
   — **Atouts :** amélioration de la qualité de l'onde, gestion des pointes de consommation et participation aux services système.
   — **Inconvénients :** coût initial important et complexité accrue des systèmes de protection.

3. **Couplage côté alternatif (AC-Side)**

   Dans cette configuration, les sources de production et les unités de stockage possèdent leurs propres onduleurs et convergent vers un tableau de distribution alternatif commun.

   — **Points forts :** grande flexibilité d'extension et gestion indépendante de chaque unité.
   — **Points faibles :** pertes énergétiques plus élevées dues à la multiplication des étapes de conversion.

4. **Couplage côté continu (DC-Side)**

   Dans cette architecture, le générateur photovoltaïque et le système de stockage partagent un bus continu commun. Un seul onduleur centralise l'injection vers le réseau.

— **Avantages :** rendement optimisé grâce à la réduction du nombre de conversions et conception compacte (adaptée aux installations résidentielles ou aux micro-réseaux).
— **Limites :** flexibilité technique plus faible et solution moins répandue pour les centrales photovoltaïques de forte puissance.

1.4 Onduleurs et stratégies de commande classiques

Les onduleurs d'un système photovoltaïque sont des dispositifs électroniques conçus pour convertir l'électricité sous forme de courant continu (DC) générée par les panneaux solaires en courant alternatif (AC) directement utilisable par les équipements électriques ou injectable dans le réseau.

Lorsqu'ils sont connectés au réseau, les onduleurs se synchronisent avec celui-ci à l'aide d'un algorithme de verrouillage de phase (PLL – *Phase Locked Loop*). Ce dispositif fournit l'angle nécessaire à la transformation de Park ($abc \rightarrow dq0$) utilisée dans les stratégies de commande du système. Ainsi, le courant et la fréquence du système photovoltaïque peuvent être synchronisés avec la tension et la fréquence du réseau.

Une autre fonction importante de l'onduleur consiste à faire fonctionner le générateur photovoltaïque à son point de puissance maximale grâce à une commande de type MPPT (*Maximum Power Point Tracking*). En effet, la production solaire varie en fonction des conditions météorologiques telles que l'éclairement et la température.(8)

1.4.1 Gestion des échanges de puissance entre la centrale PV et le réseau

Le contrôle des échanges de puissance active et réactive entre une centrale photovoltaïque et le réseau constitue un élément essentiel pour la stabilité d'un système électrique. Il conditionne notamment le maintien de la tension au point de couplage commun (PCC), la régulation de la fréquence du réseau ainsi que la capacité de la centrale à réagir face aux perturbations telles que les creux de tension ou les variations de fréquence.

Dans ce contexte, l'onduleur photovoltaïque joue un rôle stratégique. Il doit injecter dans le réseau les puissances active (P) et réactive (Q) selon des consignes précises, souvent imposées par les *grid codes*. Ces consignes peuvent être exprimées sous forme de différentes lois de contrôle.

Contrôle de la puissance active P

Le contrôle de la puissance active est généralement assuré en mode MPPT, permettant d'extraire en permanence la puissance maximale du générateur photovoltaïque en fonction des variations de l'irradiation solaire et de la température.

Toutefois, certaines limitations peuvent être imposées par le réseau ou par les normes du *grid code* :

— Réduction de la puissance active en cas de surfréquence ;
— Réduction de P en fonction de la tension en cas de surtension au PCC ;
— Fonction de régulation $P(f)$: modulation de la puissance active en fonction de la fréquence du réseau ;
— Enclenchement progressif (*ramp-up*) afin d'éviter les chocs d'injection de puissance.

Contrôle de la puissance réactive Q

La puissance réactive joue un rôle crucial dans le maintien de la tension au point d'injection (PCC) ainsi que dans la réduction des pertes et des chutes de tension dans le réseau.

Elle peut être contrôlée selon plusieurs stratégies :

— **Q constant :** l'onduleur maintient une puissance réactive fixe sans chercher à réguler la tension du réseau. Cette stratégie est rarement utilisée en pratique.
— **Contrôle $Q(V)$:** injection ou absorption de puissance réactive en fonction de la tension mesurée au PCC.
— **Contrôle $Q(P)$:** l'injection ou l'absorption de puissance réactive dépend de la puissance active injectée selon la courbe de capabilité $P-Q$.
— **Facteur de puissance constant ($\cos\varphi$ constant) :** l'onduleur fonctionne avec un facteur de puissance imposé.
— **Injection de Q en mode LVRT (*Low Voltage Ride Through*) :** en cas de creux de tension, la priorité est donnée à l'injection de puissance réactive afin de soutenir la tension du réseau.

Ces modes de contrôle sont essentiels pour garantir la sécurité, la fiabilité et la résilience du réseau électrique, en particulier dans les systèmes présentant une forte pénétration des énergies renouvelables intermittentes.

1.4.2 Stratégies de commande classiques

L'interaction de l'onduleur avec les grandeurs du réseau telles que la tension et la fréquence dépend du contexte d'intégration : réseau robuste ou faible, présence d'autres sources synchrones, fonctionnement en réseau isolé ou connecté, etc.(8)

On distingue principalement deux grandes stratégies de commande des onduleurs :

Onduleur Grid-Following

Un onduleur *grid-following* est commandé en courant, car la tension et la fréquence sont imposées par le réseau. Il utilise l'algorithme PLL pour déterminer l'angle instantané de la tension. Grâce à la transformation de Park ($abc \rightarrow dq0$), il est possible de découpler les puissances active et réactive et d'agir sur les composantes i_d et i_q afin de contrôler respectivement P et Q.

Ce type d'onduleur nécessite la présence d'un réseau pour obtenir la référence de tension et de fréquence permettant la synchronisation. En l'absence de réseau, il ne peut pas fonctionner, car le contrôleur enverrait un signal PWM correspondant à une consigne nulle, ce qui bloque les interrupteurs électroniques et empêche toute injection de puissance.

Onduleur Grid-Forming

Un onduleur *grid-forming* est capable de générer lui-même la tension et la fréquence du réseau local. Contrairement à l'onduleur *grid-following*, il ne dépend pas d'un réseau externe pour fonctionner.

Ce type d'onduleur est particulièrement utilisé dans les micro-réseaux ou dans les systèmes isolés. Il agit de manière similaire à une source synchrone en imposant les caractéristiques électriques du réseau, ce qui permet de stabiliser la tension et la fréquence même en l'absence d'un réseau principal.

Paradoxalement, un onduleur *grid-forming* (formateur de réseau) établit lui-même la tension et la fréquence de référence, de manière analogue à une génératrice synchrone.

Sa commande interne régule l'amplitude de la tension et la fréquence selon des lois de type *droop* (P–f, Q–V) ou via des stratégies de machine synchrone virtuelle (*Virtual Synchronous Machine* – VSM).

Un tel onduleur est capable d'alimenter un réseau en l'absence d'une source de référence externe, ce qui le rend essentiel pour les micro-réseaux autonomes, le *black-start* (redémarrage d'un réseau après un *blackout*) ainsi que pour la fourniture de services système, tels que l'inertie synthétique et le maintien de la stabilité de fréquence.(8)

1.5 Codes réseaux et normes

Les systèmes photovoltaïques connectés au réseau doivent satisfaire aux exigences établies par les gestionnaires de réseau (GR) afin de garantir une exploitation sûre et stable de l'ensemble du système électrique.

Étant donné l'existence de différentes normes nationales, *grid codes*, cadres réglementaires et techniques d'entreprise, il est souvent difficile pour les fabricants et les développeurs d'onduleurs photovoltaïques de satisfaire simultanément toutes ces exigences lors de la conception et de la fabrication des équipements.(8)

Plusieurs initiatives ont été mises en place afin d'harmoniser les normes, notamment au sein de l'Union Européenne :

— CENELEC ;
— DER-Lab ;
— Livre blanc sur l'intégration des ressources énergétiques distribuées ;
— Projet ADDRESS ;
— Projet EU-DEEP.

En l'absence d'un *grid code* spécifique à la République Démocratique du Congo (RDC) pour l'intégration des énergies renouvelables, le présent travail s'appuie principalement sur le *grid code* égyptien (*Solar Energy Plants Grid Connection Code*). Celui-ci est complété par plusieurs standards internationaux, notamment :

— La norme IEEE 1547-2018 (États-Unis) ;
— La norme EN 50549-1 (Europe) ;
— Le règlement européen RfG (EU 2016/631) ;
— Le projet ESPRIT (Études Scientifiques Prénormatives sur le Raccordement au Réseau des Installations Techniques Photovoltaïques).

Ces documents prescrivent une série d'exigences relatives à la continuité de service, à la sécurité, à la stabilité et à la qualité de l'énergie injectée dans le réseau.

1.5.1 Le grid code égyptien

Selon le *grid code* égyptien, les centrales photovoltaïques sont classées en trois catégories suivant leur taille et le niveau de tension auquel elles sont raccordées.

Ainsi, on distingue :

(a) **Les Small-scale PV (ssPV)** : centrales photovoltaïques de puissance inférieure à 500 kW, généralement connectées au réseau de distribution basse tension (BT).

(b) **Les Medium and Large-Scale PV (MSSPs et LSSPs)** :

— Les MSSPs correspondent aux centrales photovoltaïques dont la puissance est comprise entre 0,5 MW et 20 MW ;

— Les LSSPs correspondent aux centrales dont la puissance est supérieure à 20 MW.

Ces centrales peuvent être raccordées soit au réseau de moyenne tension (MT), soit au réseau de haute tension (HT).

Avec une puissance installée de 6 MWc, la centrale photovoltaïque étudiée dans ce travail appartient à la catégorie des MSSPs.

Les principales exigences réglementaires applicables sont les suivantes :

Point de couplage commun (PCC)

Le PCC correspond au point où la centrale photovoltaïque est connectée au réseau électrique public.

Plage de tension

La centrale photovoltaïque doit être capable de fournir sa puissance active lorsque la tension au PCC se situe dans les plages suivantes :

— $0,85 - 1,1$ p.u. pour une durée illimitée ;

— $1,1 - 1,15$ p.u. pendant une durée maximale de 30 minutes.

Plage de fréquence

Les centrales photovoltaïques doivent fonctionner dans les conditions suivantes :

— Si la fréquence est inférieure à 50 Hz, la centrale doit continuer à injecter de la puissance active jusqu'à une fréquence de 47,5 Hz ;

— Si la fréquence est comprise entre 50 Hz et 50,2 Hz, la centrale doit maintenir 100 % de sa puissance active ;

— Si la fréquence est supérieure à 50,2 Hz, la centrale doit continuer à injecter de la puissance active jusqu'à 51,5 Hz conformément aux exigences du contrôle de puissance active.

Mise en service des centrales photovoltaïques

Lors du démarrage de la centrale :

— la fréquence au PCC doit être comprise entre 48 Hz et 51 Hz ;
— la tension doit être comprise entre 0,9 p.u. et 1,1 p.u. ;
— la puissance active doit augmenter progressivement à raison de 10 % de la puissance nominale par minute.

Qualité de l'énergie

La centrale doit préserver la forme d'onde de la tension au PCC et respecter les exigences du *grid code*. En cas de défaut dans le réseau, la centrale doit rester connectée au réseau (*ride-through*).

Distorsion harmonique

Les distorsions harmoniques au PCC doivent respecter les limites définies par la norme IEEE 519-2014.

Les limites pour les harmoniques individuelles et totales de courant et de tension sont généralement spécifiées dans les tableaux normatifs.

Sévérité du flicker

Le flicker total au PCC doit être inférieur à :

— $\Delta P_{lt} \leq 0,25$ pour le long terme (2 heures) ;
— $\Delta P_{st} \leq 0,35$ pour le court terme (10 minutes).

Ces limites sont définies conformément à la norme IEC 61000-3-7.

Déséquilibre et fluctuations de tension

— Les déséquilibres de tension doivent être corrigés par la centrale solaire jusqu'à 2 % pendant au moins 30 secondes ;
— Les variations de tension au PCC doivent être limitées à 3 % de la tension nominale.

Contrôle de la puissance active et réactive

La centrale photovoltaïque doit être capable de contrôler l'injection de puissance active et réactive afin de contribuer au maintien de la stabilité du réseau et au respect des

exigences du *grid code*.

Exigences de fonctionnement et de protection

— La centrale doit continuer à fournir de la puissance dans la plage de fréquence de 47,5 Hz à 50,2 Hz ou dans la plage de tension spécifiée au PCC pour les périodes définies.
— Pour les fréquences de réseau comprises entre 50,2 Hz et 51,5 Hz, la centrale doit ajuster la puissance active conformément aux prescriptions du *grid code*.
— La centrale doit être capable de contrôler la puissance réactive Q au PCC dans une plage comprise entre 0,95 inductif et 0,95 capacitif.
— En cas de défaut triphasé, la centrale doit injecter un courant réactif pendant 250 ms après le déclenchement du défaut jusqu'à son élimination.(7)

Protection

— Les réglages de protection au PCC doivent être conformes aux prescriptions du *grid code*.
— Les réglages recommandés pour la sous-fréquence et la surfréquence sont :
  — Sous-fréquence : $47,5$ Hz pendant moins de 500 ms ;
  — Surfréquence : $51,5$ Hz pendant moins de 100 ms.
— Pour les sous-tensions et surtensions, les réglages recommandés sont :
  — $1,15 \times V_n$ en ≤ 3 secondes ;
  — $0,3 \times V_n$ en 1 seconde.

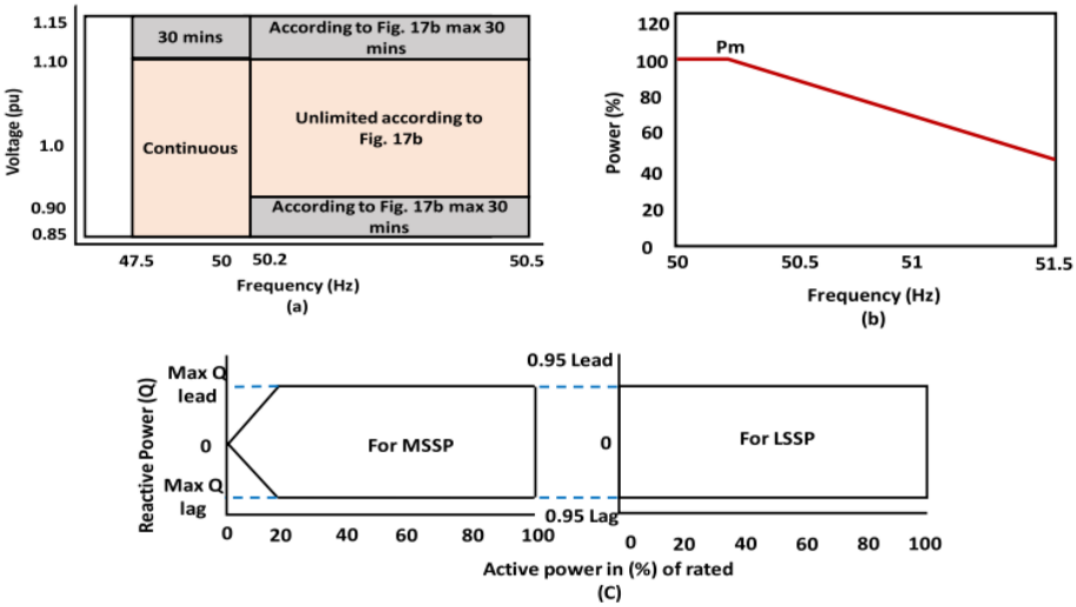

FIGURE 1.15. Exigences du grid code pour les centrales photovoltaïques : (a) plage tension–fréquence admissible, (b) réduction de la puissance active en fonction de la fréquence, (c) capacité d'injection de puissance réactive en fonction de la puissance active pour les centrales MSSP et LSSP.(7)

[1]

TABLE 1.1. Limites de distorsion harmonique de tension selon la norme IEEE 519

Niveau de tension (kV)	**Harmoniques impaires (%)**	**Distorsion totale (%)**
$V < 1$	5.0	8.0
$1 \leq V < 69$	3.0	5.0
$69 \leq V < 161$	1.5	2.5
$V \geq 161$	1.0	1.5

Source : IEEE Standard 519-2014.

1. Source : Adapté de Egyptian Solar Energy Grid Connection Code(2014).

TABLE 1.2. Limites de distorsion harmonique du courant pour les systèmes 69 kV

I_{sc}/I_L	**<11**	**11–17**	**17–23**	**23–35**	**TDD**
< 20	4.0	2.0	1.5	0.6	5
20–50	7.0	3.5	2.5	1.0	8
50–100	10.0	4.5	4.0	1.5	12
100–1000	12.0	5.5	5.0	2.0	15
> 1000	15.0	7.0	6.0	2.5	20

Source : IEEE Standard 519-2014.

Source : IEEE Standard 519-2014 – Recommended Practice and Requirements for Harmonic Control in Electric Power Systems.

1.6 Limites des stratégies classiques d'injection réactive

Dans les réseaux de distribution modernes intégrant des sources d'énergie renouvelables, notamment les générateurs photovoltaïques, les onduleurs jouent un rôle essentiel dans la gestion de la puissance réactive et dans la régulation de la tension au point de couplage commun (PCC). Les onduleurs modernes disposent généralement de plusieurs modes de contrôle local permettant de gérer l'injection ou l'absorption de puissance réactive afin d'assurer la stabilité du réseau.(13)

Parmi les stratégies de contrôle les plus couramment utilisées dans les onduleurs photovoltaïques, on retrouve notamment :

— **Const. Q** (puissance réactive constante) ;
— **Const. V** (régulation de tension) ;
— **Caractéristique** $Q(V)$;
— **Voltage** Q**-Droop** ;
— **Voltage** I_q**-Droop** ;
— **Facteur de puissance constant** ($\cos\varphi$ constant ou $\cos\varphi(P)$).

Ces différentes stratégies sont généralement intégrées dans les contrôleurs locaux des onduleurs et permettent d'assurer un fonctionnement stable du système dans des conditions de fonctionnement normales.

Dans le mode **Const. Q**, l'onduleur injecte ou absorbe une puissance réactive fixe indépendamment de l'état du réseau. Bien que cette approche soit simple à mettre en

œuvre, elle présente une limitation importante : la valeur de la puissance réactive ne s'adapte pas aux variations dynamiques de la charge ou de la production photovoltaïque. Par conséquent, cette stratégie peut conduire à une utilisation non optimale de la capacité réactive de l'onduleur.(14)

Le mode **Const. V**, quant à lui, vise à maintenir la tension au point de connexion à une valeur de référence prédéfinie. Dans ce cas, l'onduleur ajuste automatiquement l'injection de puissance réactive afin de corriger les écarts de tension. Bien que cette méthode contribue à stabiliser la tension localement, elle peut entraîner des interactions non désirées entre plusieurs onduleurs connectés au même réseau, ce qui peut provoquer des oscillations ou des phénomènes de surcompensation.

Les stratégies basées sur les caractéristiques $Q(V)$ ou les lois de *droop* tension–réactif constituent une amélioration par rapport aux méthodes précédentes. Dans ces approches, la puissance réactive injectée dépend directement de la tension mesurée au point de connexion. Ainsi, lorsque la tension augmente, l'onduleur absorbe de la puissance réactive, tandis que lorsque la tension diminue, il en injecte. Cette stratégie permet une réponse plus flexible et contribue à améliorer la régulation de tension dans les réseaux de distribution fortement pénétrés par les sources photovoltaïques.(15)

Cependant, malgré leurs avantages, ces stratégies restent des approches locales et statiques, basées sur des règles prédéfinies. Elles ne tiennent généralement pas compte de l'état global du réseau, tel que :

— le niveau de chargement des lignes ;
— les pertes de puissance dans le réseau ;
— les interactions entre plusieurs sources distribuées ;
— les variations simultanées de la production et de la demande.

De plus, les paramètres de ces contrôleurs sont généralement fixés de manière heuristique et ne garantissent pas nécessairement un fonctionnement optimal dans toutes les conditions d'exploitation du réseau.

Dans les réseaux de distribution modernes caractérisés par une forte variabilité de la production photovoltaïque et par une augmentation de la complexité opérationnelle, ces stratégies classiques peuvent donc montrer leurs limites en termes d'efficacité et de fiabilité.

Face à ces limitations, de nouvelles approches basées sur l'optimisation et l'apprentissage automatique commencent à émerger. Ces méthodes permettent d'exploiter les

données issues des simulations ou de l'exploitation du réseau afin de déterminer dynamiquement la consigne optimale de puissance réactive.

Dans le cadre de ce travail, une approche basée sur le *machine learning*, et plus particulièrement sur le modèle **Extreme Learning Machine (ELM)**, est proposée pour prédire la consigne optimale de puissance réactive à partir de l'état instantané du réseau. Cette méthode vise à dépasser les limitations des stratégies classiques en fournissant une commande adaptative et intelligente, capable d'améliorer simultanément le profil de tension, de réduire les pertes de puissance et de limiter la surcharge des lignes.

Ainsi, l'approche proposée contribue à renforcer la fiabilité et la performance des systèmes photovoltaïques connectés aux réseaux de distribution, tout en exploitant plus efficacement les capacités de régulation offertes par les onduleurs modernes.

Conclusion du chapitre

Ce premier chapitre a permis de présenter les principes fondamentaux liés à l'intégration des centrales photovoltaïques dans les réseaux électriques. Après une introduction aux bases du fonctionnement des systèmes photovoltaïques et aux différents composants constituant une centrale solaire, l'analyse s'est concentrée sur les conditions techniques nécessaires à leur raccordement au réseau électrique.

L'étude a mis en évidence que l'intégration de la production photovoltaïque doit respecter un ensemble d'exigences techniques, notamment en matière de régulation de tension, de gestion de la puissance réactive, de stabilité du réseau et de conformité aux prescriptions du gestionnaire du réseau électrique. Dans ce contexte, le rôle des convertisseurs électroniques de puissance, en particulier les onduleurs opérant en mode *grid-following*, apparaît essentiel pour assurer une synchronisation correcte entre la centrale photovoltaïque et le réseau d'accueil.

Par ailleurs, l'analyse des critères d'évaluation de la force du réseau, notamment à travers la puissance de court-circuit et le rapport de court-circuit (*Short Circuit Ratio – SCR*), a permis de mieux comprendre les conditions dans lesquelles une centrale photovoltaïque peut être intégrée sans compromettre la stabilité du système électrique. Ces indicateurs constituent des outils importants pour évaluer la capacité du réseau à absorber de nouvelles sources de production décentralisées.

Enfin, les différentes stratégies de contrôle de la puissance réactive, telles que les

lois de régulation $Q(P)$, ont été présentées comme des moyens efficaces pour garantir le respect des exigences du *grid code* et assurer une exploitation fiable du réseau.

L'ensemble de ces éléments théoriques constitue le socle conceptuel de cette étude. Sur cette base, le chapitre suivant sera consacré à la modélisation et à la simulation du réseau électrique étudié à l'aide du logiciel de simulation *DIgSILENT PowerFactory*. Cette étape permettra de représenter le réseau réel considéré, d'y intégrer la centrale photovoltaïque proposée et d'analyser l'impact de son raccordement sur les grandeurs électriques du système, notamment les profils de tension, les flux de puissance et les pertes dans le réseau.(16)

Chapitre 2

Modélisation du Réseau et Approche Traditionnelle d'Intégration

Tout au long de ce chapitre, nous porterons notre attention sur la modélisation de la centrale photovoltaïque et sur les conditions de son injection dans le réseau public de la SNEL (Société Nationale d'Électricité), en particulier au niveau de la sous-station Campus. Nous présenterons dans cette partie le réseau existant, qui sera le plus utilisé dans l'ensemble du travail, c'est-à-dire les sous-stations Makala et Campus. Ensuite, nous introduirons le logiciel *DIgSILENT PowerFactory*, largement utilisé pour la modélisation et la simulation des systèmes électriques.(17)

2.1 Présentation du réseau

L'intégration des systèmes photovoltaïques dans les réseaux électriques nécessite une compréhension approfondie des caractéristiques du réseau d'accueil. Avant toute analyse ou optimisation du système, il est essentiel de décrire la structure et les paramètres du réseau étudié afin d'identifier les contraintes techniques pouvant influencer le fonctionnement global du système.

Le réseau étudié dans ce travail correspond à un réseau de distribution électrique auquel sera raccordée une centrale photovoltaïque. Ce réseau est constitué de plusieurs éléments principaux, notamment les lignes électriques, les transformateurs, les charges et le point de connexion commun appelé *Point of Common Coupling* (PCC). Ce point représente l'interface entre la centrale photovoltaïque et le réseau électrique.

Dans un réseau de distribution, l'équilibre entre la production et la consommation

d'énergie est un facteur déterminant pour garantir la stabilité du système. Les paramètres électriques tels que la tension, la puissance active, la puissance réactive et les pertes dans les lignes doivent être maintenus dans des limites admissibles afin d'assurer un fonctionnement fiable du réseau.

Avant l'injection de la production photovoltaïque, le réseau fonctionne selon un régime d'exploitation classique où les charges sont alimentées par les sources conventionnelles. Dans ces conditions, une analyse de flux de puissance (*Load Flow*) permet d'évaluer l'état du réseau, notamment les niveaux de tension aux différents nœuds, les flux de puissance dans les lignes ainsi que les pertes électriques.

Dans cette étude, le réseau électrique est modélisé à l'aide du logiciel *DIgSILENT PowerFactory*, un outil largement utilisé pour l'analyse et la simulation des systèmes électriques. Ce logiciel permet de représenter avec précision les différents composants du réseau et d'effectuer des analyses telles que les calculs de flux de puissance, l'évaluation des pertes et l'analyse des contraintes opérationnelles.

L'objectif de cette modélisation initiale est d'obtenir une représentation fidèle du réseau existant avant l'intégration du système photovoltaïque. Cette étape constitue une base essentielle pour l'évaluation de l'impact de l'injection photovoltaïque et pour la mise en œuvre des stratégies d'optimisation basées sur l'apprentissage automatique qui seront présentées dans les chapitres suivants.

L'énergie électrique, étant souvent produite loin des centres de consommation, doit être transportée depuis le système de production (aménagement hydroélectrique, centrale éolienne, centrale photovoltaïque, etc.) à travers ce qu'on appelle un réseau de transport de l'énergie électrique. Les réseaux électriques sont définis comme l'ensemble des infrastructures mises en œuvre pour assurer, dans le respect des normes, l'acheminement de l'énergie électrique depuis la production jusqu'à la consommation chez les clients.(18)

Les réseaux électriques se composent généralement de :

— **Lignes électriques (aériennes et souterraines) :** elles ont pour rôle de véhiculer l'énergie électrique depuis les unités de production jusqu'aux consommateurs finaux (industries, habitations, etc.) ;

— **Les postes électriques :** ils jouent un rôle de transformation, de dispersion et d'interconnexion entre plusieurs lignes pouvant provenir de différentes sources de production électrique.

La SNEL utilise les terminologies suivantes pour désigner les différents types de postes :

(a) Les postes THT/HT, HT/HT et HT/MT sont appelés **Postes** ;

(b) Le poste MT/MT avec transformation est appelé **Sous-station** ;

(c) Le poste MT/MT sans transformation est appelé **Poste de sectionnement** ;

(d) Le poste MT/BT est appelé communément **Cabine** et parfois **Poste de réflexion** ;

(e) Le poste BT sans transformation est appelé **Poste de sectionnement**.

2.1.1 Sous-station Campus

La sous-station Campus, de coordonnées géographiques $4°24'34''$ S et $15°18'10''$ E, est située dans la commune de Lemba, sur la route de Kimwenza, dans la ville-province de Kinshasa, en République Démocratique du Congo (RDC).(8)

La sous-station comprend deux transformateurs de puissance apparente de 15 MVA chacun.

L'alimentation de l'Université de Kinshasa (UNIKIN) est assurée par l'un de ces deux transformateurs, ayant un rapport de transformation de $30/6{,}6$ kV.

Le second transformateur, de rapport de transformation $30/20$ kV, alimente quant à lui un autre réseau de distribution. Signalons également qu'il existe une dérivation à partir de l'arrivée 30 kV qui alimente en moyenne tension la REGIDESO Gombe.

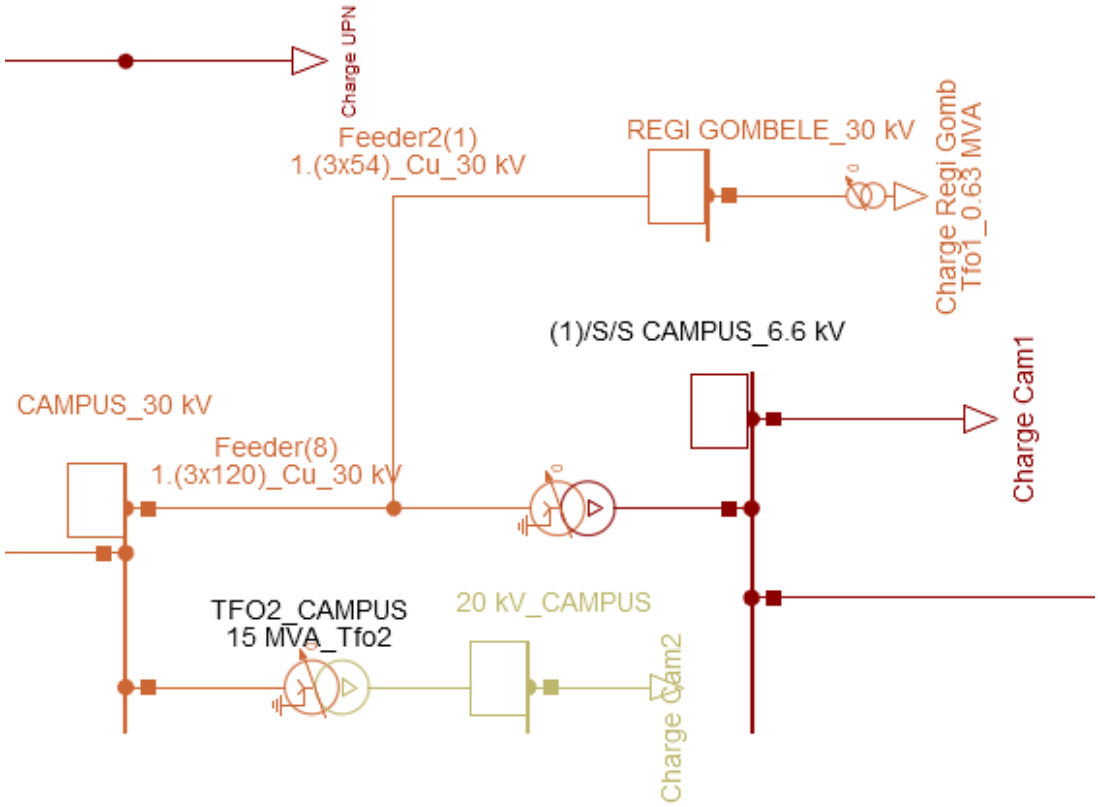

FIGURE 2.1. Schéma unifilaire du réseau étudié autour de la sous-station Campus modélisé dans DIgSILENT PowerFactory.

Source : Ketsia LUZOLO, modélisation réalisée sous *DIgSILENT PowerFactory*.

2.1.2 Le réseau UNIKIN

Comme mentionné précédemment, l'Université de Kinshasa est alimentée en énergie électrique par la sous-station **CAMPUS**, au moyen d'un transformateur de puissance nominale de **15 MVA**, avec un rapport de transformation de **30/6,6 kV**.

Les caractéristiques techniques des transformateurs ainsi que celles des différentes lignes qui leur sont associées sont présentées en annexe, afin de fournir une description exhaustive du système étudié.

2.2 Modélisation du réseau d'étude dans DIgSILENT PowerFactory

2.2.1 Présentation du logiciel DIgSILENT PowerFactory

DIgSILENT PowerFactory est un logiciel professionnel de simulation et d'analyse des systèmes électriques de puissance. Il est largement utilisé par les ingénieurs, les chercheurs et les entreprises du secteur de l'énergie pour l'étude du fonctionnement, de la planification et de l'optimisation des réseaux électriques.(19)

Ce logiciel permet de modéliser les différents composants d'un réseau électrique, notamment les générateurs, les transformateurs, les lignes de transport, les charges ainsi que les systèmes de production d'énergie renouvelable, tels que le photovoltaïque et l'éolien. Il offre plusieurs types d'analyses, parmi lesquelles le calcul de flux de puissance (*load flow*), l'analyse des courts-circuits, l'étude de stabilité dynamique et l'optimisation du fonctionnement du réseau.

PowerFactory se distingue également par sa capacité à intégrer des scripts Python et des outils d'automatisation, facilitant ainsi la génération de données, les procédures d'optimisation ainsi que le développement d'algorithmes avancés, notamment ceux reposant sur le *machine learning*. Grâce à ces fonctionnalités, il constitue un outil particulièrement adapté à la recherche, à la planification et à l'exploitation des réseaux électriques modernes et intelligents (*smart grids*).(8)

2.2.2 Modélisation du réseau d'étude

Dans le cadre de ce travail, le modèle utilisé comme base d'analyse est celui du réseau **Ouest KINSUKA 2023**, mis à disposition par la Société Nationale d'Électricité (SNEL). L'étude s'est principalement focalisée sur deux infrastructures majeures du réseau, à savoir la sous-station **MAKALA** et la sous-station **CAMPUS**.

Une attention particulière a été accordée à la modélisation détaillée de la sous-station **MAKALA**, dans la mesure où elle constitue la principale source d'alimentation de la sous-station **CAMPUS**. Cette représentation détaillée permet d'évaluer avec plus de précision les effets liés à l'intégration d'une production photovoltaïque dans le réseau, en tenant compte du caractère bidirectionnel des flux d'énergie susceptible d'apparaître lors de l'injection de cette production.

Dans la modélisation réalisée, le réseau est représenté comme suit :

— **Sous-station MAKALA :** elle est modélisée par un jeu de barres de **30 kV**, alimenté par un réseau externe. Cette sous-station assure l'alimentation de plusieurs charges, parmi lesquelles figure la sous-station **CAMPUS**.

— **Sous-station CAMPUS :** alimentée à partir de la sous-station **MAKALA**, elle est raccordée à un jeu de barres de **30 kV** qui distribue l'énergie vers différentes charges, notamment l'Université de Kinshasa, la REGIDESO GOMBELE, ainsi qu'un réseau de distribution fonctionnant à **20 kV**.

— **Réseau de l'Université de Kinshasa :** il est modélisé par une charge équivalente dénommée **CAMPUS 1**, raccordée au jeu de barres de **6,6 kV** de la sous-station **CAMPUS**.

Cette charge regroupe en réalité cinq départs (*feeders*) principaux : **A5F6**, **F745**, **F747**, **Agronomie** ainsi que **Clinique–CNPP**. Parmi ces départs, le feeder **Agronomie** assure l'alimentation de l'Université de Kinshasa (**UNIKIN**), dont la consommation moyenne est estimée à environ **2,5 MW**.

Dans le modèle du réseau, la charge **CAMPUS 1** est représentée par un courant de **0,42 kA** avec un facteur de puissance de **0,95**.

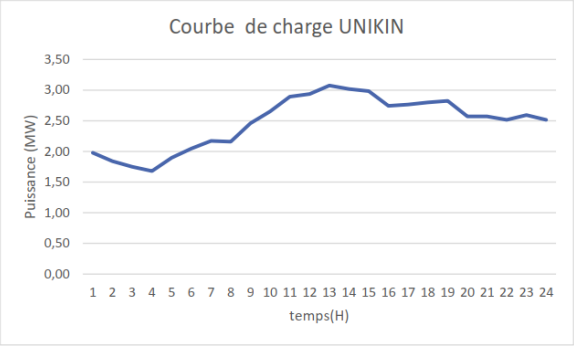

(a) Courbe de charge de l'Université de Kinshasa

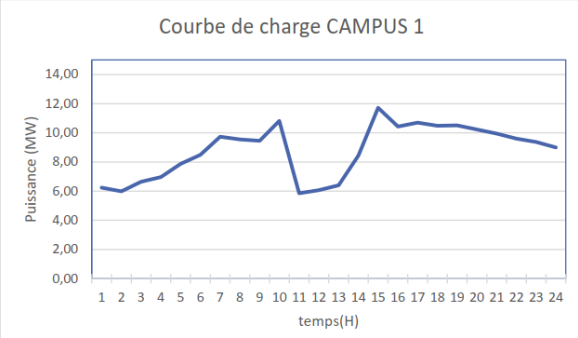

(b) Courbe de charge de CAMPUS 1

FIGURE 2.2. Profils journaliers de charge du réseau étudié (8)

[1]

2.2.3 Modélisation de la centrale photovoltaïque

La centrale photovoltaïque considérée dans cette étude est constituée de deux sous-champs photovoltaïques, nommés respectivement **Sous-champ 1** et **Sous-champ 2**, modélisés à l'aide du bloc *Large-Scale PV Plant*, un modèle développé par la *WECC* et disponible dans la bibliothèque du logiciel DIgSILENT PowerFactory.

Chaque unité photovoltaïque est connectée à un jeu de barres basse tension de **0,8 kV**, respectivement désigné **PV Plant LV_1** et **PV Plant LV_2**.

Afin d'adapter le niveau de tension au réseau de distribution, chaque sous-champ est associé à un transformateur élévateur de **3 MVA**, avec un rapport de transformation de **0,8/6,6 kV**. Bien

1. Source : Courbes de charge Campus 1 et unikin du 13/09/2025

qu'identiques, ces transformateurs sont identifiés sous les noms **Trf PV Plant-1** et **Trf PV Plant-2**. Ils permettent d'élever la tension à **6,6 kV** et d'injecter l'énergie produite vers le jeu de barres **Centrale PV** (**6,6 kV**).

À partir de ce jeu de barres de **6,6 kV**, la centrale photovoltaïque est reliée au point de couplage commun (*Point of Common Coupling, PCC*) par deux câbles souterrains en cuivre, de section **3×1×400 mm²** et d'une longueur de **1 km**. Ce PCC correspond au jeu de barres **6,6 kV** de la sous-station **CAMPUS** (**S/S CAMPUS_6.6 kV**).

Présentation des différents modèles photovoltaïques dans DIgSILENT PowerFactory

Dans DIgSILENT PowerFactory, plusieurs modèles sont disponibles pour représenter le comportement des systèmes photovoltaïques dans les études de réseaux électriques. Ces modèles permettent de simuler le fonctionnement des centrales photovoltaïques selon différents niveaux de précision, allant de représentations simplifiées à des modèles dynamiques plus détaillés.(19)

1. Modèle statique de générateur photovoltaïque Le modèle statique représente la centrale photovoltaïque comme une source de puissance active et réactive injectée dans le réseau. Dans ce cas, la puissance active produite est généralement fixée en fonction de l'irradiation solaire, tandis que la puissance réactive peut être contrôlée suivant différentes stratégies, notamment le maintien d'un facteur de puissance constant ou le contrôle de tension.

Ce modèle est principalement utilisé pour les calculs de flux de puissance (*load flow*) et les études de planification du réseau. Il présente l'avantage d'être simple à mettre en œuvre et de nécessiter un nombre réduit de paramètres.

2. Modèle avec convertisseur (PV System avec onduleur) Dans ce modèle, la centrale photovoltaïque est représentée par un système composé d'un générateur PV et d'un onduleur connecté au réseau. L'onduleur y joue un rôle essentiel, puisqu'il assure le contrôle de l'injection de puissance active et réactive dans le réseau.

Ce type de modèle permet de simuler plusieurs modes de commande, tels que :

— le contrôle du facteur de puissance ;
— le contrôle de tension au point de connexion ;
— la limitation de puissance en fonction des conditions du réseau.

Il est généralement utilisé dans les études de stabilité et d'analyse du comportement dynamique du réseau.

3. Modèle *Large-Scale PV Plant* Le modèle *Large-Scale PV Plant* est un modèle dynamique développé par la *Western Electricity Coordinating Council (WECC)* et intégré dans la bibliothèque de PowerFactory. Il est spécialement conçu pour représenter les centrales photovoltaïques de grande puissance raccordées aux réseaux de transport ou de distribution.

Ce modèle intègre notamment :

— la dynamique de l'onduleur ;
— les systèmes de contrôle de puissance active et réactive ;
— la régulation de tension ;
— les limites de fonctionnement du convertisseur.

Il est largement utilisé dans les études de stabilité transitoire et de comportement dynamique des réseaux comportant une forte pénétration de production solaire.

4. Modèle agrégé de centrale photovoltaïque Dans ce modèle, plusieurs unités photovoltaïques sont regroupées et représentées par une seule unité équivalente. Cette approche est utilisée pour simplifier la simulation lorsque la centrale comporte un grand nombre de panneaux et d'onduleurs.

Le modèle agrégé permet ainsi de réduire la complexité du système tout en conservant un comportement global représentatif de la centrale.

Conclusion Les différents modèles photovoltaïques disponibles dans PowerFactory permettent d'adapter le niveau de détail de la simulation aux objectifs de l'étude. Les modèles statiques sont généralement utilisés pour les analyses de flux de puissance, tandis que les modèles dynamiques, tels que le *Large-Scale PV Plant*, sont privilégiés pour les études de stabilité et d'intégration des énergies renouvelables dans les réseaux électriques modernes.

Dans le cadre de cette étude, le choix s'est porté sur le modèle **PV System 3PH**, qui fait partie des modèles de systèmes photovoltaïques avec onduleur dans DIgSILENT PowerFactory.

PV System 3PH Le modèle **PV System 3PH** (*Three-Phase Photovoltaic System*) représente un système photovoltaïque triphasé connecté au réseau à travers un onduleur. Dans une installation photovoltaïque réelle, les panneaux produisent du courant continu (*DC*) qui doit être converti en courant alternatif (*AC*) afin d'être injecté dans le réseau électrique. Cette conversion est assurée par l'onduleur, qui constitue l'élément central du modèle.(19)

Ainsi, dans le modèle **PV System 3PH**, le logiciel prend en compte :

— la production de puissance active du champ photovoltaïque ;
— le convertisseur *DC/AC* (onduleur) ;
— le contrôle de la puissance réactive ;

— les différentes stratégies de fonctionnement, telles que :
  — le contrôle du facteur de puissance ;
  — le contrôle de tension ;
  — la limitation de puissance.

Rôle du modèle Ce modèle est généralement utilisé pour :

— représenter des installations photovoltaïques raccordées à un réseau triphasé ;
— réaliser des études de flux de puissance ;
— analyser l'impact de l'injection photovoltaïque sur la tension et les flux de puissance dans le réseau.

Le **PV System 3PH** constitue donc un modèle de générateur photovoltaïque intégrant explicitement l'onduleur, utilisé pour simuler le comportement des installations photovoltaïques raccordées à un réseau triphasé dans PowerFactory.

Le bloc PV

Dans cette étude, la centrale photovoltaïque est modélisée dans DIgSILENT PowerFactory à l'aide de l'objet **PV System** (**ElmPvsys**), qui représente un système photovoltaïque raccordé au réseau à travers un onduleur. Ce modèle permet de simuler l'injection de puissance active et réactive dans le réseau électrique, tout en tenant compte des limites opérationnelles du convertisseur.

Le générateur photovoltaïque utilisé correspond à un sous-champ photovoltaïque dénommé **Sous-champ 1**, connecté au réseau via le jeu de barres basse tension **PV Plant LV_1**. Le modèle est configuré avec une technologie triphasée (**3PH**), ce qui signifie que l'injection de puissance s'effectue sur les trois phases du réseau électrique.(8)

Dans la configuration retenue, la centrale est représentée par un onduleur unique (*Parallel Inverters = 1*) ayant une puissance apparente nominale de **3010 kVA** et un facteur de puissance nominal de **0,997**. Cette valeur élevée du facteur de puissance traduit le fonctionnement habituel des centrales photovoltaïques, qui injectent principalement de la puissance active tout en conservant une capacité de soutien en puissance réactive pour la régulation de tension.

Le mode de fonctionnement choisi pour le calcul de flux de puissance est basé sur un modèle d'entrée en puissance active (*Active Power Input*). Dans ce cas, la puissance active injectée par le système photovoltaïque est imposée directement dans le modèle, et non déterminée à partir des conditions météorologiques telles que l'irradiation solaire et la température. Pour les conditions de fonctionnement étudiées, la puissance active est fixée à **2198,4 kW**. Ce choix se justifie par la volonté de ne pas exploiter le transformateur à sa pleine capacité, afin de préserver sa durée de

vie.

La gestion de la puissance réactive est assurée par un contrôleur local configuré en mode *Const. Q*, ce qui signifie que l'onduleur maintient une puissance réactive constante pendant la simulation. Ce mode permet d'analyser l'impact d'une injection photovoltaïque avec un niveau de compensation réactive fixé.

Par ailleurs, étant donné que le fonctionnement de l'onduleur est contraint par sa puissance apparente, les limites de fonctionnement de la centrale photovoltaïque sont définies à travers une courbe de capabilité **P–Q**. Cette courbe traduit les contraintes physiques de l'onduleur en matière de production de puissance active et réactive. Dans le modèle utilisé, la puissance active maximale est fixée à **2,7 MW**, tandis que la puissance réactive peut varier entre **-2,055 Mvar** et **+2,055 Mvar**, conformément à la relation reliant les puissances active, réactive et apparente. Ces limites représentent la capacité maximale de fonctionnement de l'onduleur à absorber ou fournir de la puissance réactive afin de contribuer à la régulation de tension du réseau.(19)

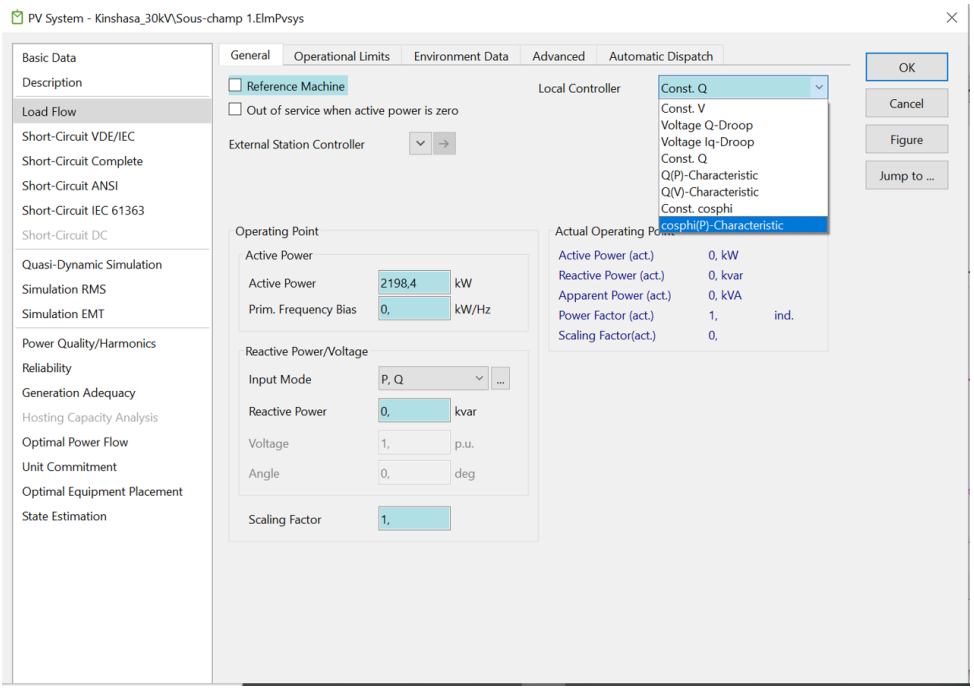

FIGURE 2.3. Paramétrage du bloc PV System (ElmPvsys) dans DIgSILENT PowerFactory 2021

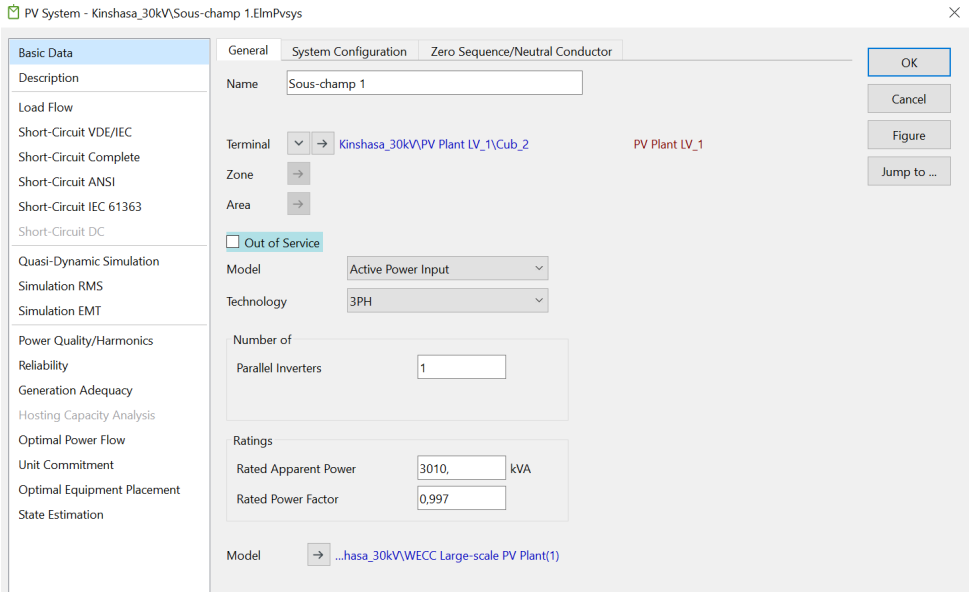

FIGURE 2.4. Mode d'entrée puissance imposée dans le bloc PV System (ElmPvsys) dans DIgSILENT PowerFactory 2021

2.2.4 Prise en compte de la variabilité de la production photovoltaïque

Lors d'une simulation dynamique d'une centrale photovoltaïque, l'irradiance solaire peut varier de manière significative au cours de la journée, ce qui entraîne des fluctuations de la puissance produite par l'installation photovoltaïque. Toutefois, dans les modèles génériques proposés par DIgSILENT PowerFactory, la puissance injectée par le générateur photovoltaïque est généralement considérée comme constante une fois que le calcul de flux de puissance est effectué.

Dans la version PowerFactory 2021 utilisée dans cette étude, il n'existe pas de fonction intégrée permettant de reproduire directement les variations temporelles de l'irradiation solaire lors d'une simulation dynamique. Par conséquent, la variabilité naturelle de la production photovoltaïque n'est pas automatiquement prise en compte dans le modèle standard.

Afin de contourner cette limitation, une approche basée sur l'utilisation de profils temporels a été adoptée. D'une part, la charge du réseau a été modélisée à l'aide d'un profil de charge journalière associé à la charge **CAMPUS 1**, permettant de représenter l'évolution de la demande électrique de l'Université de Kinshasa au cours de la journée. D'autre part, la production photovoltaïque a été définie à partir d'un profil solaire standard représentant l'évolution typique de l'irradiation solaire entre le lever et le coucher du soleil.(4)

L'utilisation combinée de ces deux profils a permis d'introduire des variations temporelles réalistes de la puissance active injectée par la centrale photovoltaïque ainsi que de la puissance consommée par la charge. Ainsi, au cours de la simulation, des fluctuations ont été observées

tant du côté de la production photovoltaïque que du côté de la demande électrique, ce qui permet de mieux représenter les conditions réelles d'exploitation du réseau.

Importance de la prise en compte de la variabilité

La prise en compte de la variabilité de la production photovoltaïque et de la demande électrique est essentielle pour analyser correctement le comportement d'un réseau électrique intégrant des sources d'énergie renouvelables. En effet, la production d'une centrale photovoltaïque dépend fortement des conditions météorologiques, notamment de l'irradiation solaire, qui varie au cours de la journée. Parallèlement, la consommation électrique du réseau évolue également en fonction des activités des usagers.

Dans le cas du réseau étudié, l'utilisation d'un profil de charge journalière pour la charge **CAMPUS 1**, combinée à un profil solaire standard pour la centrale photovoltaïque, permet de reproduire de manière plus réaliste les conditions d'exploitation du système électrique. Ces variations entraînent des fluctuations de la puissance active injectée dans le réseau ainsi que des modifications du niveau de tension et des flux de puissance dans les lignes.

La prise en compte de ces variations est particulièrement importante dans le cadre de cette étude, car elle permet d'évaluer l'impact réel de l'intégration de la centrale photovoltaïque sur le réseau, notamment en termes de profil de tension, de pertes électriques et de circulation de puissance réactive. Ces paramètres constituent des indicateurs essentiels pour analyser la performance du système et déterminer les stratégies de contrôle optimales.

Ainsi, l'introduction de profils temporels de charge et de production photovoltaïque permet de réaliser une simulation plus représentative du fonctionnement réel du réseau et constitue une base pertinente pour l'analyse et l'optimisation de l'injection de puissance réactive dans le réseau étudié.

2.3 Caractéristiques du réseau avant injection (Load Flow)

2.3.1 Contexte technique du calcul de flux de puissance

Le calcul de flux de puissance (*Load Flow*) constitue un outil fondamental pour l'analyse des réseaux électriques dans des conditions de fonctionnement en régime permanent, c'est-à-dire lorsque le système ne présente aucune perturbation telle qu'un court-circuit. Dans ce contexte, le régime permanent correspond à une situation où les différentes variables et paramètres du système sont supposés rester constants pendant la période d'observation.

Méthodes de résolution du calcul de flux de puissance

Le calcul de flux de puissance consiste à résoudre un ensemble d'équations non linéaires reliant les puissances actives et réactives aux tensions et aux angles de phase aux différents nœuds du réseau électrique. Pour résoudre ces équations, plusieurs méthodes numériques ont été développées. Les plus utilisées dans l'analyse des réseaux électriques sont notamment :

— la méthode de Gauss-Seidel,

— la méthode de Newton-Raphson,

— la méthode du découplage rapide (*Fast Decoupled Load Flow*).

On peut assimiler cette analyse à une photographie instantanée de l'état du réseau électrique à un moment donné t. Par exemple, il est possible de considérer l'évolution de la demande électrique sur une période de 24 heures. Dans un réseau réel, la consommation augmente généralement progressivement au cours de la journée, atteignant souvent un maximum en début de soirée, par exemple autour de 18 heures, avant de diminuer progressivement durant la nuit.

Le calcul de flux de puissance est qualifié d'analyse en régime permanent car il décrit l'état du réseau pour un instant précis, comme par exemple le moment correspondant à la demande maximale. Si l'on souhaite étudier l'évolution du système tout au long de la journée, il est alors nécessaire d'effectuer plusieurs calculs de flux de puissance, chacun correspondant à un instant donné.

Dans DIgSILENT PowerFactory, la puissance active et réactive des charges peut être définie à l'aide de caractéristiques temporelles (*profiles*). Ces caractéristiques permettent aux charges de suivre automatiquement une évolution prédéfinie, par exemple journalière, hebdomadaire ou mensuelle. Grâce à cette fonctionnalité, la puissance demandée par les charges peut varier automatiquement en fonction de la date et de l'heure définies dans la simulation.

Équations du calcul de flux de puissance

Les équations du calcul de flux de puissance déterminent la puissance active (P_i) et la puissance réactive (Q_i) injectées à chaque nœud i du réseau en fonction des tensions, des angles de phase et de la matrice d'admittance du réseau ($Y_{ij} = G_{ij} + jB_{ij}$).

La puissance active au nœud i est donnée par :

$$P_i = \sum_{j=1}^{n} V_i V_j \left[G_{ij} \cos(\theta_i - \theta_j) + B_{ij} \sin(\theta_i - \theta_j) \right] \tag{2.1}$$

La puissance réactive au nœud i est donnée par :

$$Q_i = \sum_{j=1}^{n} V_i V_j \left[G_{ij} \sin(\theta_i - \theta_j) - B_{ij} \cos(\theta_i - \theta_j) \right] \tag{2.2}$$

où :

— V_i et V_j représentent les tensions aux nœuds i et j,

— θ_i et θ_j sont les angles de phase correspondants,

— G_{ij} et B_{ij} représentent respectivement la conductance et la susceptance de la matrice d'admittance du réseau.(17)

Résultats obtenus par le calcul de flux de puissance

Le calcul de flux de puissance permet de déterminer plusieurs grandeurs essentielles du réseau électrique, notamment :

— les flux de puissance active et réactive dans chaque branche du réseau ;

— le niveau de tension aux différents nœuds ;

— l'angle de phase de la tension pour chaque nœud du réseau.

Ces informations sont indispensables pour comprendre le comportement du réseau et vérifier la fiabilité de son fonctionnement.

Domaines d'application du calcul de flux de puissance

Les applications du calcul de flux de puissance peuvent être classées selon deux catégories principales : les conditions normales de fonctionnement et les conditions anormales ou situations de contingence.

Conditions normales de fonctionnement : Dans les conditions normales d'exploitation du réseau, le calcul de flux de puissance est utilisé pour :

— déterminer les charges des lignes, les pertes de puissance dans le réseau et les profils de tension ;

— réaliser des analyses d'optimisation, telles que la minimisation des pertes du réseau ou la réduction des coûts de production ;

— déterminer les conditions initiales du système nécessaires pour effectuer d'autres études, notamment les simulations de stabilité ou les analyses de court-circuit.

Conditions anormales du système : Dans les situations anormales, par exemple en cas de défaillance d'un élément du réseau, le calcul de flux de puissance peut être utilisé pour :

— analyser les charges des lignes, les pertes du réseau et les profils de tension dans ces conditions perturbées ;

— effectuer des analyses de contingence afin d'évaluer la sécurité du réseau ;

— optimiser certaines stratégies d'exploitation du réseau ;

— vérifier les conditions de fonctionnement lors des analyses de fiabilité ;

— déterminer automatiquement les stratégies optimales de réalimentation du réseau après une perturbation ;

— optimiser les stratégies de délestage de charge.

Simulation des conditions normales d'exploitation

Dans le cadre de la simulation des conditions normales de fonctionnement, les puissances produites par les générateurs ainsi que les puissances consommées par les charges sont supposées connues. Le calcul de flux de puissance permet alors de représenter la répartition de ces puissances dans l'ensemble du réseau.

Les résultats obtenus doivent correspondre à un état du système dans lequel aucune limite d'exploitation des lignes ou des générateurs n'est dépassée, garantissant ainsi un fonctionnement sûr et stable du réseau électrique.

```
-----------------------------------------------------------------------------------------------
| Grid: Kinshasa_30kV        System Stage: Kinshasa_30kV   | Study Case: Study Dynamique
-----------------------------------------------------------------------------------------------
| Grid: Kinshasa_30kV        Summary
|
| No. of Substations     3          No. of Busbars        11         No. of Terminals      44
| No. of 2-w Trfs.       7          No. of 3-w Trfs.      0          No. of syn. Machines  0
| No. of Loads           8          No. of Shunts/Filters 0          No. of SVS            0
|
| Generation           =       0,00  MW            0,00   Mvar         0,00  MVA
| External Infeed      =       0,00  MW            0,00   Mvar         0,00  MVA
| Inter Grid Flow      =     -50,41  MW          -14,46   Mvar
| Load P(U)            =      50,15  MW           13,67   Mvar        51,98  MVA
| Load P(Un)           =      50,87  MW           13,90   Mvar        52,73  MVA
| Load P(Un-U)         =       0,72  MW            0,23   Mvar
| Motor Load           =       0,00  MW            0,00   Mvar         0,00  MVA
| Grid Losses          =       0,26  MW            0,81   Mvar
| Line Charging        =                           0,00   Mvar
| Compensation ind.    =                           0,00   Mvar
| Compensation cap.    =                           0,00   Mvar
|
| Installed Capacity   =       0,00  MW
| Spinning Reserve     =       0,00  MW
|
| Total Power Factor:
|-----------------------------------------------------------------------------------------------
```

FIGURE 2.5. Puissances et pertes du réseau d'étude Kinshasa 30 kV

```
-----------------------------------------------------------------------------------------
 Grid: Kinshasa_30kV        System Stage: Kinshasa_30kV   | Study Case: Study Dynamiqu
-----------------------------------------------------------------------------------------
           rated                            Active Reactive Power                  |
          Voltage     Bus-voltage           Power   Power   Factor Current Loading|
           [kV]  [p.u.]    [kV]   [deg]     [MW]   [Mvar]    [-]    [kA]    [%]  |
-----------------------------------------------------------------------------------------
(1)                                                                                |
  S/S CAMPUS,60    0,99    6,53  -19,32                                            |
   Cub_1  /Lod      Charge Cam1            4,91     1,61   0,95    0,46          |Pl0:
   Cub_1  /Lne      CPV_SSCAMP             0,00     0,00   1,00    0,00    0,00  |Pv:
   Cub_1  /Tr2      TFO1_CAMPUS           -4,91    -1,61  -0,95    0,46   34,83  |Tap:
                                                                                  |
Centrale PV                                                                       |
  6.6 kV   6,60    0,00    0,00    0,00                                           |
   Cub_1  /Lne      CPV_SSCAMP             0,00     0,00   1,00    0,00    0,00  |Pv:
   Cub_1  /Tr2      Trf PV Plant           0,00     0,00   1,00    0,00    0,00  |Tap:
   Cub_1  /Tr2      Trf PV Plant_1         0,00     0,00   1,00    0,00    0,00  |Tap:
                                                                                  |
20 kV_CAMPUS                                                                      |
          20,00    0,99   19,84  -18,89                                           |
   Cub_2  /Lod      Charge Cam2            1,30     0,43   0,95    0,04          |Pl0:
   Cub_1  /Tr2      TFO2_CAMPUS           -1,30    -0,43  -0,95    0,04    9,17  |Tap:
                                                                                  |
-----------------------------------------------------------------------------------------
```

FIGURE 2.6. Rapport des tensions et puissances aux différents nœuds du réseau

```
-----------------------------------------------------------------------------------------
| Grid: Kinshasa_30kV        System Stage: Kinshasa_30kV   | Study Case: Study Dynamique
-----------------------------------------------------------------------------------------
|          rated                            Active Reactive Power                  |
|         Voltage     Bus-voltage           Power   Power   Factor Current Loading|
|          [kV]  [p.u.]    [kV]   [deg]     [MW]   [Mvar]    [-]    [kA]    [%]  |
-----------------------------------------------------------------------------------------
|BB2                                                                                |
|         30,00    1,00   29,96  -48,74                                            |
|   Cub_1  /Tr2      TFO 1_15 MVA          11,32     4,01   0,94    0,23   80,15  |Tap:
|   Cub_3  /Coup     BR                   -40,39   -10,90  -0,97    0,81    0,00  |
|   Cub_4  /Coup     CBS                   29,07     6,89   0,97    0,58    0,00  |
|                                                                                   |
|CAMPUS_30 kV                                                                       |
|         30,00    0,99   29,79  -48,74                                            |
|   Cub_1  /Lne      Makala_Campus_3.6     -6,51    -2,47  -0,94    0,13   64,22  |Pv:
|   Cub_2  /Lne      Feeder(8)              5,21     2,04   0,93    0,11   13,55  |Pv:
|   Cub_3  /Tr2      TFO2_CAMPUS            1,30     0,43   0,95    0,03    9,17  |Tap:
|                                                                                   |
|MAKALA_30 kV                                                                       |
|         30,00    1,00   29,96  -48,74                                            |
|   Cub_3  /Lod      General Load          14,96     1,80   0,99    0,29          |Pl0:
|   Cub_1  /Lne      Makala_Campus_3.6      6,54     2,48   0,94    0,13   64,22  |Pv:
|   Cub_2  /Lne      Makala_UPN_ 6.5 km     7,57     2,62   0,95    0,15   36,73  |Pv:
|   Cub_4  /Coup     CBS                  -29,07    -6,89  -0,97    0,58    0,00  |
|                                                                                   |
|PV Plant LV-2                                                                      |
|          0,80    0,00    0,00    0,00                                           |
|   Cub_2  /Pvsys    Sous-champ 2           0,00     0,00   1,00    0,00    0,00  |
|   Cub_1  /Tr2      Trf PV Plant           0,00     0,00   1,00    0,00    0,00  |Tap:
|   Cub_2(1/Coup     Disjoncteur/Interr     0,00     0,00   1,00    0,00    0,00  |
|                                                                                   |
|PV Plant LV_1                                                                      |
|          0,80    0,00    0,00    0,00                                           |
|   Cub_2  /Pvsys    Sous-champ 1           0,00     0,00   1,00    0,00    0,00  |
|   Cub_1  /Tr2      Trf PV Plant_1         0,00     0,00   1,00    0,00    0,00  |Tap:
|   Cub_2(1/Coup     Disjoncteur/Interr     0,00     0,00   1,00    0,00    0,00  |
|                                                                                   |
-----------------------------------------------------------------------------------------
```

FIGURE 2.7. Rapport des puissances et chargement des lignes du réseau

2.3.2 Intégration de la centrale photovoltaïque à la sous-station CAMPUS

Comme indiqué dans le chapitre 1, l'intégration d'une centrale photovoltaïque dans un réseau électrique s'effectue selon une démarche structurée comprenant plusieurs étapes essentielles, notamment :

— le choix du point de raccordement au réseau ;
— l'adaptation du niveau de tension au moyen de transformateurs appropriés ;
— la conformité aux exigences techniques et réglementaires du gestionnaire du réseau ;
— la vérification des conditions d'injection, telles que la puissance active, la tension, la fréquence et la puissance réactive ;
— la mise en service coordonnée de l'installation au sein du réseau électrique.

Par ailleurs, l'intégration d'une centrale photovoltaïque peut être réalisée selon différentes techniques. Le choix de la méthode la plus appropriée dépend de plusieurs facteurs, notamment la puissance de la centrale, le niveau de tension du réseau, les exigences réglementaires, la topologie du réseau local ainsi que les performances attendues du système.

Dans cette optique, il est nécessaire d'identifier la stratégie d'intégration la plus adaptée aux caractéristiques du projet étudié. Ainsi, la démarche décrite précédemment est appliquée dans cette section afin de réaliser l'intégration de la centrale photovoltaïque au niveau de la sous-station étudiée.

Rapport de court-circuit et évaluation de la force du réseau

La capacité d'un réseau électrique à accueillir une centrale photovoltaïque raccordée par convertisseur peut être évaluée à l'aide du *Short-Circuit Ratio* (SCR), appelé en français rapport de court-circuit. Ce paramètre compare la puissance de court-circuit disponible au point de raccordement à la puissance nominale de l'installation photovoltaïque.(20)

Pour un point de connexion unique, il est généralement défini par :

$$SCR = \frac{S_{CC}}{S_{PV}} \tag{2.3}$$

où :

— S_{CC} est la puissance de court-circuit triphasée au point de couplage commun (PCC),
— S_{PV} est la puissance apparente nominale de la centrale photovoltaïque.(8)

Lorsque le facteur de puissance nominal de l'installation est proche de l'unité, on assimile souvent S_{PV} à la puissance active nominale P_{PV}, ce qui conduit à l'approximation suivante :

$$SCR \approx \frac{S_{CC}}{P_{PV}} \tag{2.4}$$

Le SCR est utilisé comme indicateur de la *raideur électrique* du réseau au point de raccordement. Plus la puissance de court-circuit disponible est élevée par rapport à la puissance injectée par la centrale, plus le réseau est capable de maintenir sa tension et sa fréquence face aux perturbations locales et aux variations de puissance.

À l'inverse, un faible SCR traduit un réseau plus sensible aux variations de puissance active et réactive, avec un risque accru d'interactions de commande, d'oscillations et de difficultés de régulation de tension pour les ressources à électronique de puissance.

Dans la littérature technique, le SCR est donc fréquemment utilisé pour distinguer les réseaux forts et les réseaux faibles. Une règle pratique souvent citée consiste à considérer qu'un réseau est faible lorsque $SCR < 3$, et fort lorsque $SCR > 5$. Il ne s'agit toutefois pas d'une frontière absolue, car le comportement réel dépend également de la technologie des convertisseurs, de leurs réglages et de la présence d'autres ressources connectées au réseau.

D'un point de vue physique, la puissance de court-circuit au PCC est liée à l'impédance équivalente vue depuis ce point. Un niveau élevé de S_{CC} correspond à une impédance de réseau plus faible, donc à un réseau plus rigide vis-à-vis des perturbations électriques.

Dans le cas des centrales photovoltaïques, cette rigidité est importante car les convertisseurs synchronisent et régulent leur injection à partir des grandeurs électriques locales. Un réseau faible peut alors dégrader la stabilité dynamique, la tenue de tension et la qualité de l'interaction entre l'onduleur et le réseau.

Dans le cadre de cette étude, le point de couplage commun est situé au niveau **6,6 kV**. L'étude de court-circuit réalisée au PCC a donné une puissance de court-circuit :

$$S_{CC} = 344 \text{ MVA}$$

La puissance nominale de la centrale photovoltaïque étant :

$$P_{PV} = 6 \text{ MW}$$

Le rapport de court-circuit est alors donné par :

$$SCR = \frac{344}{6} = 57,33$$

Cette valeur est très largement supérieure aux seuils empiriques généralement utilisés pour caractériser un réseau fort. On peut donc conclure que, du point de vue du critère SCR, le réseau vu depuis le point de couplage commun (PCC) à 6.6 kV est très fort vis-à-vis d'une centrale

photovoltaïque de 6 MWc. Une telle valeur signifie que la puissance de court-circuit disponible au point de raccordement est très supérieure à la puissance injectée par la centrale, ce qui traduit un bon niveau de soutien du réseau et une faible sensibilité de la tension locale aux variations de production photovoltaïque.

En d'autres termes, dans ce cas, le raccordement de la centrale photovoltaïque ne s'effectue pas dans des conditions typiques de réseau faible. Le PCC dispose au contraire d'une réserve importante de puissance de court-circuit, ce qui est favorable à la stabilité du raccordement, à la tenue de tension et à l'intégration de la centrale. Cela ne dispense toutefois pas de vérifier les autres critères techniques, tels que les variations de tension, les flux de puissance, les pertes du réseau, les limites thermiques des équipements ainsi que la stratégie de réglage de la puissance réactive. Néanmoins, le critère SCR indique ici un environnement de raccordement robuste.

2.3.3 Intégration de la centrale photovoltaïque à la sous-station

Comme indiqué dans le chapitre 1 et confirmé par l'analyse réalisée précédemment, le réseau au point d'injection présente un niveau de robustesse élevé. Dans ces conditions, les centrales photovoltaïques peuvent être raccordées au réseau à l'aide d'onduleurs opérant en mode *grid-following*. Ce mode de fonctionnement implique que l'onduleur synchronise son fonctionnement avec les grandeurs électriques du réseau hôte, en s'alignant dynamiquement sur la tension et la fréquence imposées par celui-ci.

Par ailleurs, conformément aux exigences du *grid code* mentionnées au point 1.4, toute centrale photovoltaïque raccordée au réseau doit être en mesure de réguler sa puissance réactive en fonction de la puissance active injectée. Cette exigence est généralement représentée par la courbe de capabilité P–Q présentée à la figure 2.8, qui définit les limites d'injection ou d'absorption de la puissance réactive en fonction du niveau de production active P.

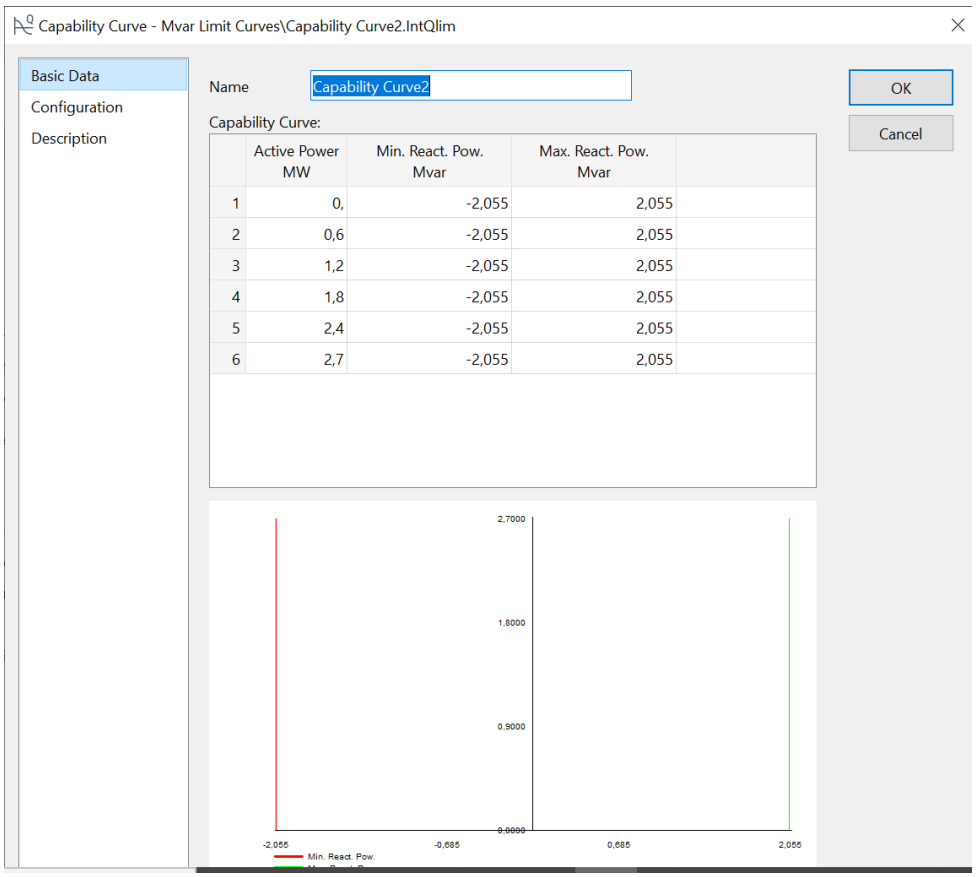

FIGURE 2.8. Courbe de capabilité P–Q de l'onduleur de la centrale photovoltaïque dans DIgSILENT PowerFactory

2.3.4 Raccordement de la centrale photovoltaïque au PCC

Le contrôleur de la centrale photovoltaïque est configuré pour assurer la régulation de la puissance réactive au niveau du Point de Couplage Commun (PCC). Ce contrôleur applique une loi de régulation $Q(P)$ conforme au profil exigé par le gestionnaire de réseau, tel que décrit précédemment. Cette stratégie permet d'assurer une coordination efficace entre les deux sous-champs photovoltaïques modélisés, garantissant ainsi une gestion optimale de la puissance réactive et le respect des exigences d'exploitation du réseau.

Chaque sous-champ photovoltaïque est associé à un transformateur élévateur de puissance nominale 3 MVA, avec un rapport de transformation de 0.8 kV/6.6 kV et un couplage *Dyn11*. Ces transformateurs assurent l'élévation de la tension afin de permettre l'intégration de la centrale photovoltaïque au niveau du nœud PCC du réseau.

2.4 Simulation quasi-dynamique

2.4.1 Principe de la simulation quasi-dynamique

Dans les études de réseaux électriques, l'analyse du flux de puissance (*load flow*) permet d'évaluer l'état du système pour une condition donnée supposée constante. Toutefois, dans un réseau réel, les grandeurs électriques évoluent continuellement en raison des variations de la demande électrique et de la production des sources d'énergie, notamment dans le cas des centrales photovoltaïques.

Afin de prendre en compte ces variations temporelles, le logiciel DIgSILENT PowerFactory propose une fonctionnalité appelée *simulation quasi-dynamique*. Cette méthode consiste à effectuer une série de calculs de flux de puissance successifs pour différents instants d'une période donnée, généralement sur une journée complète.

Dans cette approche, les paramètres du réseau tels que la puissance active des charges et la production photovoltaïque sont définis à l'aide de profils temporels appelés *characteristics*. À chaque pas de temps, le logiciel met à jour ces paramètres puis exécute un nouveau calcul de flux de puissance. Cette technique permet ainsi d'analyser l'évolution des grandeurs électriques du réseau en fonction du temps.

Profils de charge et de production :

Dans cette étude, la simulation quasi-dynamique a été réalisée sur une période de 24 heures, avec un pas de calcul correspondant à une heure.

Deux profils principaux ont été utilisés.

Profil de charge : La charge CAMPUS 1 a été modélisée à l'aide d'un profil journalier de consommation représentant l'évolution de la demande électrique au cours de la journée. Ce profil reflète le comportement typique d'un réseau urbain caractérisé par :

— une faible consommation durant la nuit ;
— une augmentation progressive de la demande en matinée ;
— un pic de consommation en fin d'après-midi ou en début de soirée ;
— une diminution progressive durant la nuit.

Profil de production photovoltaïque : La production de la centrale photovoltaïque a été représentée à l'aide d'un profil standard d'irradiation solaire permettant de simuler la variation de la puissance produite au cours de la journée. La production photovoltaïque est nulle durant la

nuit, augmente progressivement après le lever du soleil, atteint un maximum vers le milieu de la journée puis diminue progressivement jusqu'au coucher du soleil.

Ces profils permettent de reproduire de manière réaliste les conditions d'exploitation du réseau et d'étudier l'impact de la variabilité de la production photovoltaïque sur le fonctionnement du système électrique.

Grandeurs électriques analysées

La simulation quasi-dynamique permet d'observer l'évolution de plusieurs grandeurs importantes du réseau, notamment :

— la tension (en p.u.) au nœud PCC ;
— les flux de puissance active et réactive dans les lignes ;
— le chargement de la ligne Makala–Campus ;
— les pertes de puissance dans le réseau ;
— la puissance injectée par la centrale photovoltaïque.

L'analyse de ces grandeurs permet d'évaluer l'impact de l'injection photovoltaïque sur le fonctionnement du réseau et de vérifier le respect des limites d'exploitation.

Conformément aux exigences du *grid code*, la centrale photovoltaïque est exploitée en mode de contrôle de puissance réactive dépendant de la puissance active injectée, selon la caractéristique $Q(P)$. Dans ce mode de fonctionnement, l'onduleur ajuste l'injection ou l'absorption de puissance réactive en fonction du niveau de puissance active produite par le générateur photovoltaïque.

Cette stratégie permet de respecter la courbe de capabilité P–Q imposée par les normes de raccordement et d'assurer une contribution adéquate de la centrale au maintien des conditions de fonctionnement du réseau.

2.4.2 Analyse des grandeurs électriques

Les résultats de la simulation quasi-dynamique sont présentés sous forme de courbes illustrant l'évolution temporelle des principales grandeurs électriques du réseau. Les figures suivantes présentent respectivement le profil de production photovoltaïque, l'évolution de la charge, la variation de la tension au point de couplage commun ainsi que les pertes dans le réseau au cours de la journée.

Dans les réseaux de distribution modernes intégrant des générateurs photovoltaïques, la gestion de la puissance réactive constitue un élément essentiel pour assurer la stabilité du système électrique et maintenir un profil de tension acceptable au point de couplage commun (PCC). En

effet, la puissance réactive joue un rôle déterminant dans la régulation de la tension et dans la limitation des pertes dans les réseaux électriques.

Dans le cadre de cette étude, la centrale photovoltaïque est exploitée selon une stratégie de contrôle $Q(P)$, c'est-à-dire que la puissance réactive échangée avec le réseau dépend de la puissance active produite par le générateur photovoltaïque. Cette stratégie est généralement utilisée pour respecter les courbes de capabilité P–Q imposées par les codes réseaux.

Cependant, le comportement optimal d'un générateur photovoltaïque dépend fortement de la robustesse du réseau auquel il est connecté. Cette robustesse est généralement caractérisée par le rapport de court-circuit (SCR – *Short Circuit Ratio*).

Rappelons que dans notre cas d'étude le réseau est considéré comme fort étant donné que :

$$SCR \approx 57$$

Dans ce type de réseau, les variations de tension dues à l'injection de puissance active sont généralement faibles et le réseau possède déjà une capacité importante de régulation de tension grâce aux sources synchrones et aux dispositifs de compensation existants.

Par conséquent, l'injection de puissance réactive par la centrale photovoltaïque n'est pas nécessaire dans les conditions normales d'exploitation. Il est alors préférable de faire fonctionner l'onduleur avec un facteur de puissance unitaire :

$$\cos(\varphi) = 1 \quad \Rightarrow \quad Q = 0$$

Ce mode de fonctionnement présente plusieurs avantages :

— il minimise les courants circulant dans les lignes du réseau ;
— il réduit les pertes actives dans les conducteurs ;
— il évite une circulation inutile de puissance réactive ;
— il permet d'exploiter toute la capacité apparente de l'onduleur pour l'injection de puissance active.

Dans ces conditions, la caractéristique $Q(P)$ retenue dans la simulation quasi-dynamique est définie de manière simple par :

$$Q(P) = 0$$

pour toute la plage de puissance active du générateur photovoltaïque.

Ainsi, pour toute valeur de puissance active injectée par la centrale, l'onduleur fonctionne avec un facteur de puissance proche de l'unité. Cette hypothèse constitue une référence de fonctionnement classique, permettant d'évaluer par la suite l'apport de la stratégie d'optimisation

proposée dans ce travail, basée sur l'apprentissage automatique (*Extreme Learning Machine – ELM*), qui permettra de déterminer dynamiquement une consigne optimale de puissance réactive afin d'améliorer les performances globales du réseau.

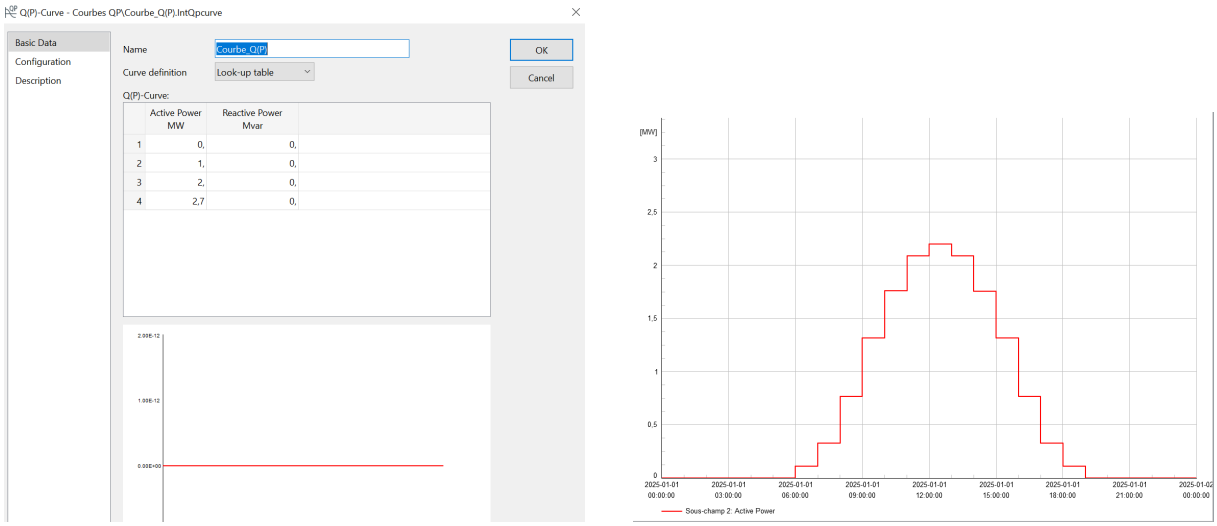

(a) Caractéristique $Q(P)$ appliquée à l'onduleur (b) Profil de production photovoltaïque

FIGURE 2.9. Caractéristique $Q(P)$ et profil de production photovoltaïque

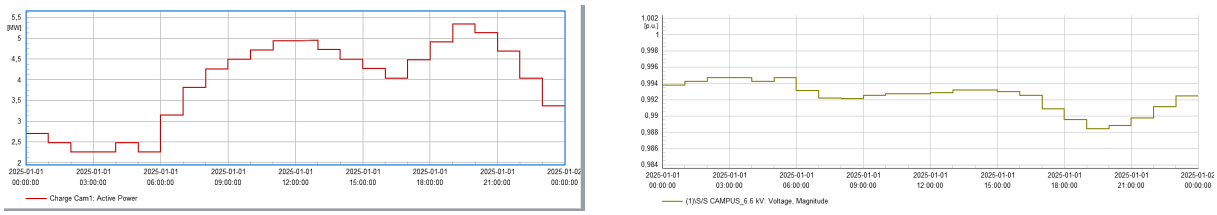

(a) Profil de charge Campus 1 (b) Évolution de la tension au PCC

FIGURE 2.10. Variation de la charge et de la tension au PCC

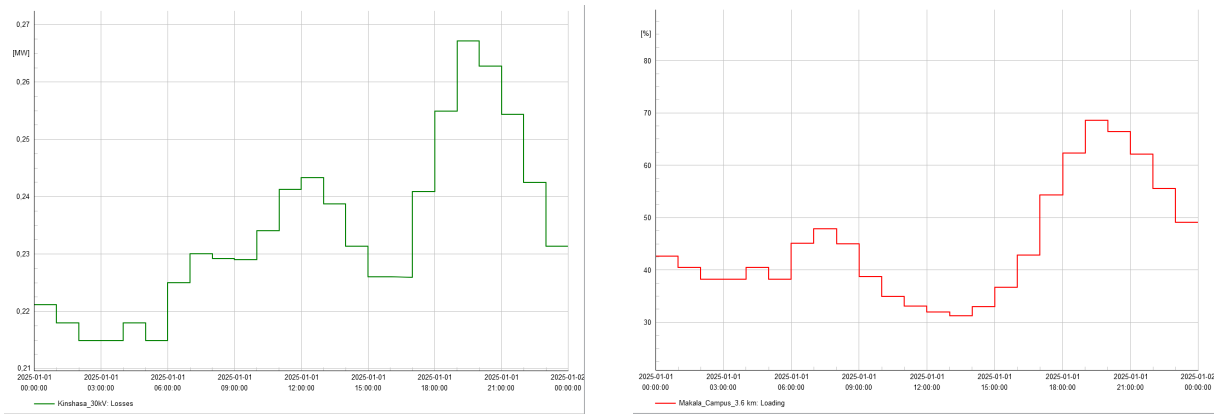

(a) Pertes actives du réseau (b) Chargement des lignes

FIGURE 2.11. Évolution des pertes et du chargement des lignes

2.5 Analyse critique des résultats

La simulation quasi-dynamique réalisée sur le réseau d'étude Kinshasa 30 kV en conditions normales de fonctionnement a permis d'observer l'évolution temporelle de plusieurs grandeurs caractéristiques du système, notamment la puissance active de la charge **CAMPUS 1**, la puissance photovoltaïque injectée, la tension au point de couplage commun (PCC), le chargement de la ligne Makala–Campus ainsi que les pertes actives totales du réseau. Ces résultats mettent en évidence les interactions entre la variabilité de la demande, la production solaire et le comportement électrique global du réseau.

2.5.1 Évolution de la puissance de charge et de la production photovoltaïque

La courbe de la charge **CAMPUS 1** présente un profil journalier classique : une demande relativement faible durant la nuit, une hausse progressive à partir de la matinée, puis un maximum observé en soirée. Dans les résultats obtenus, la puissance active de la charge varie approximativement entre 2.25 MW et 5.30 MW, avec un pic situé vers 19 h – 20 h. Ce comportement est cohérent avec celui d'un réseau de distribution alimentant des usages universitaires et urbains, pour lesquels la demande devient plus importante lorsque les activités de la journée s'intensifient.

À l'inverse, la puissance photovoltaïque d'un sous-champ suit un profil solaire typique : elle est nulle pendant la nuit, croît après le lever du soleil, atteint un maximum aux environs de midi, puis décroît progressivement jusqu'au coucher du soleil. D'après les résultats obtenus, un sous-champ atteint un maximum d'environ 2.2 MW. En considérant que les deux sous-champs sont identiques, la puissance totale de la centrale est donc de l'ordre de 4.4 MW au voisinage du pic solaire.

L'analyse conjointe de ces deux courbes met en évidence un aspect important : les pics de charge et de production photovoltaïque ne sont pas simultanés. La centrale photovoltaïque fournit sa puissance maximale en milieu de journée, alors que la demande maximale survient en soirée, à un moment où la production solaire a déjà fortement diminué. Ce décalage temporel explique pourquoi l'injection photovoltaïque améliore le fonctionnement du réseau pendant les heures solaires sans pour autant éliminer la contrainte liée au pic de consommation du soir.

2.5.2 Analyse de la tension au PCC

La tension au PCC reste globalement stable au cours de la journée. Les résultats indiquent qu'elle évolue approximativement entre 0.988 p.u. et 0.995 p.u., ce qui correspond à une variation relativement faible et toujours située dans une plage acceptable de fonctionnement.(21)

La légère hausse de tension observée durant les heures de forte production photovoltaïque s'explique par la réduction du transit de puissance active provenant du réseau amont. En milieu de journée, l'injection locale de puissance par la centrale photovoltaïque alimente directement une partie de la charge située à proximité du PCC. Le courant appelé depuis la sous-station amont diminue alors, ce qui réduit les chutes de tension le long des lignes du réseau.

À l'inverse, lorsque la production solaire devient nulle en fin de journée alors que la charge atteint son maximum, la tension au PCC diminue légèrement, ce qui correspond au comportement classique d'un réseau radial soumis à une augmentation du courant de transit.

La faible amplitude des variations de tension observées est cohérente avec le fait que le réseau étudié a été précédemment identifié comme un réseau fort au point de raccordement, avec un rapport de court-circuit $SCR \approx 57$. Dans ces conditions, la sensibilité de la tension aux variations de puissance active et réactive reste relativement faible.

2.5.3 Analyse du chargement de la ligne Makala–Campus

Le chargement de la ligne Makala–Campus (longueur 3.6 km) varie de manière significative au cours de la journée, avec des valeurs comprises approximativement entre 31 % et 68 %. Le minimum est observé autour de midi, tandis que le maximum apparaît en soirée.

Lorsque la centrale photovoltaïque produit fortement, une partie de la demande locale est alimentée directement au niveau du PCC. Le transit de puissance depuis la sous-station Makala diminue alors, ce qui réduit le courant circulant dans la ligne et diminue son taux de chargement.

À l'inverse, en fin de journée, la disparition de la production photovoltaïque oblige le réseau amont à fournir la quasi-totalité de la puissance demandée par la charge CAMPUS 1. Le courant circulant dans la ligne augmente alors, ce qui explique le niveau de chargement maximal observé durant cette période.

Ce résultat illustre l'un des avantages classiques de la production décentralisée : le soulagement partiel des infrastructures du réseau pendant les périodes de production locale. Toutefois, cet effet reste limité dans le temps, puisqu'il disparaît précisément lorsque la charge atteint son maximum.

2.5.4 Analyse des pertes actives du réseau

Les pertes actives totales du réseau évoluent approximativement entre 0.215 MW et 0.267 MW. Elles atteignent leur minimum durant les heures de faible transit ou de forte injection locale, et leur maximum en soirée lorsque la charge est élevée et que la production photovoltaïque devient faible.

Cette évolution est cohérente avec la théorie des réseaux de distribution, selon laquelle les pertes dans les lignes dépendent fortement du courant qui y circule, généralement selon une loi proportionnelle à I^2R.(21)

La réduction des pertes observée en milieu de journée constitue donc un effet positif direct de l'injection photovoltaïque. En alimentant localement une partie de la demande, la centrale réduit le courant appelé depuis le réseau amont et diminue ainsi les pertes associées au transit de puissance.

2.5.5 Portée et limites du fonctionnement en mode $Q(P)$

Dans cette simulation, la centrale photovoltaïque fonctionne selon une stratégie de contrôle $Q(P)$ de référence dans laquelle la puissance réactive échangée avec le réseau reste nulle sur toute la plage de fonctionnement, soit :

$$Q(P) = 0$$

Ce mode correspond à un fonctionnement avec un facteur de puissance unitaire ($\cos\varphi = 1$). Il constitue une stratégie simple et cohérente pour un premier scénario d'évaluation, permettant d'observer l'effet naturel de l'injection photovoltaïque sans assistance réactive supplémentaire.

Les résultats montrent cependant que cette stratégie présente certaines limites. Bien que la tension reste dans une plage admissible et que les pertes diminuent pendant les heures solaires, les grandeurs critiques du réseau se dégradent à nouveau en fin de journée lorsque la production photovoltaïque devient nulle et que la charge atteint son maximum.

Cela signifie que le mode $Q(P)$ avec $Q = 0$ assure un fonctionnement acceptable du réseau, mais n'exploite pas pleinement les capacités de l'onduleur à fournir ou absorber de la puissance réactive pour améliorer davantage le profil de tension, réduire les pertes ou limiter le chargement des lignes.

2.5.6 Synthèse critique

Dans l'ensemble, les résultats de la simulation quasi-dynamique montrent que l'intégration de la centrale photovoltaïque dans le réseau Kinshasa 30 kV est techniquement favorable dans les conditions normales de fonctionnement. L'injection photovoltaïque :

— contribue à soulager la ligne Makala–Campus pendant les heures de production solaire ;
— permet une réduction des pertes actives du réseau durant la journée ;
— maintient la tension au PCC dans une plage stable ;
— n'entraîne pas de surcharge critique dans le scénario analysé.

Néanmoins, les bénéfices observés restent partiels et limités dans le temps. Le réseau redevient plus contraint au moment du pic de charge du soir, précisément lorsque la production photovoltaïque devient faible ou nulle.

Cette observation justifie l'introduction d'une stratégie d'optimisation plus avancée présentée dans le chapitre suivant. Cette approche, fondée sur l'apprentissage automatique à l'aide du modèle *Extreme Learning Machine* (ELM), permettra de déterminer dynamiquement une consigne optimale de puissance réactive afin d'améliorer simultanément le profil de tension, de réduire les pertes et de limiter le chargement des lignes du réseau.

Conclusion du chapitre

Ce chapitre a été consacré à la modélisation et à la simulation du réseau électrique étudié, ainsi qu'à l'intégration de la centrale photovoltaïque dans l'environnement de simulation. À partir du modèle du réseau *Ouest Kinsuka 2023*, fourni par la Société Nationale d'Électricité (SNEL), une représentation détaillée du système électrique a été réalisée en mettant un accent particulier sur les sous-stations **MAKALA** et **CAMPUS**, qui constituent les principaux nœuds d'analyse de cette étude.

La modélisation du réseau a été effectuée à l'aide du logiciel **DIgSILENT PowerFactory**, permettant de représenter avec précision les différents éléments du système électrique, notamment les lignes de distribution, les transformateurs, les charges ainsi que les unités de production photovoltaïque. La centrale photovoltaïque a été modélisée à travers deux sous-champs PV raccordés au réseau via des onduleurs et des transformateurs élévateurs, assurant l'adaptation du niveau de tension au réseau de distribution.

Afin de reproduire des conditions de fonctionnement proches de la réalité, des profils journaliers de charge et de production solaire ont été introduits dans la simulation. Cette approche permet de prendre en compte la variabilité temporelle de la production photovoltaïque et de la demande électrique, ce qui constitue un aspect essentiel dans l'analyse de l'intégration des sources d'énergie renouvelables dans les réseaux électriques modernes.

Dans un premier temps, les simulations basées sur le calcul de flux de puissance (*Load Flow*) ont permis d'évaluer le comportement du réseau en régime permanent et de déterminer les principales grandeurs électriques du système, notamment les tensions aux nœuds, les flux de puissance dans les lignes, les pertes électriques et le niveau de chargement des équipements. Ces résultats ont permis de vérifier la cohérence du modèle du réseau et d'analyser l'impact initial de l'injection photovoltaïque sur le fonctionnement global du système.

Dans un second temps, une simulation quasi dynamique sur un horizon de 24 heures a été

réalisée afin d'étudier l'évolution temporelle du réseau en tenant compte des variations de la charge et de la production photovoltaïque. Cette simulation a permis d'observer le comportement des principales grandeurs du système, notamment la tension au point de couplage commun (PCC), le chargement de la ligne Makala–Campus, les pertes actives du réseau, la puissance de la charge **CAMPUS 1** ainsi que la puissance injectée par la centrale photovoltaïque.

L'analyse des résultats obtenus montre que l'injection photovoltaïque contribue à réduire le transit de puissance dans les lignes et à diminuer les pertes électriques pendant les heures de production solaire, tout en maintenant la tension du réseau dans une plage acceptable. Toutefois, les simulations mettent également en évidence certaines limites du fonctionnement conventionnel en mode $Q(P)$ avec facteur de puissance unitaire, notamment lors des périodes de forte demande où la production photovoltaïque devient faible ou nulle.

Ainsi, bien que l'intégration de la centrale photovoltaïque améliore le fonctionnement du réseau pendant les heures d'ensoleillement, les résultats montrent qu'une gestion plus intelligente de la puissance réactive pourrait permettre d'optimiser davantage les performances du système, notamment en termes de profil de tension, de réduction des pertes et de limitation du chargement des lignes.

La modélisation et les simulations réalisées dans ce chapitre constituent donc une base essentielle pour l'analyse et l'optimisation du réseau étudié. Les résultats obtenus serviront notamment à générer le jeu de données nécessaire à l'entraînement du modèle d'apprentissage automatique utilisé dans ce travail.

Dans cette perspective, le chapitre suivant sera consacré à la génération du *dataset* et au développement du modèle d'apprentissage basé sur les réseaux **Extreme Learning Machine (ELM)**. Cette approche permettra d'exploiter les données issues des simulations afin de déterminer une stratégie optimale de gestion de la puissance réactive, capable d'améliorer les performances globales du réseau électrique intégrant la centrale photovoltaïque.

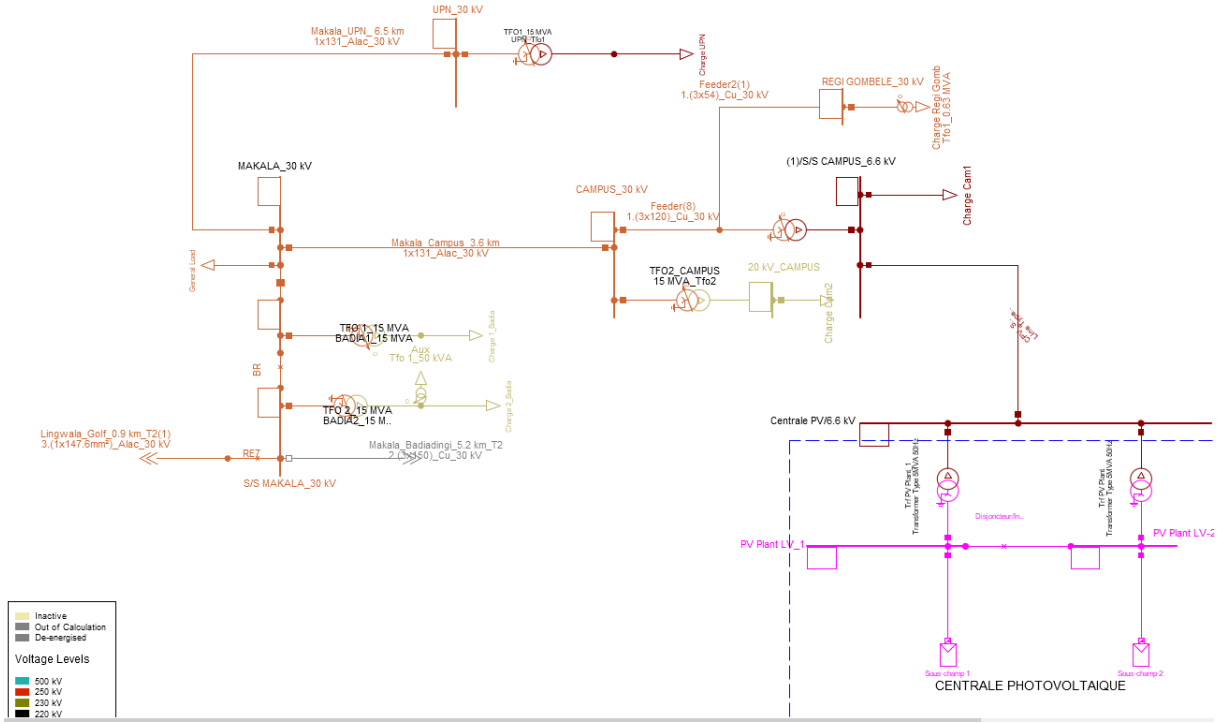

FIGURE 2.12. Schéma unifilaire du réseau d'étude Kinshasa 30 kV avec intégration de la centrale photovoltaïque

Chapitre 3

Optimisation par Machine Learning (ELM)

Introduction

L'intégration croissante des sources d'énergie renouvelables dans les réseaux électriques de distribution constitue aujourd'hui un enjeu majeur pour l'exploitation et la planification des systèmes électriques modernes. Parmi ces sources, l'énergie photovoltaïque occupe une place importante en raison de son caractère renouvelable, de sa modularité et de sa facilité d'installation à proximité des centres de consommation. Toutefois, la nature intermittente de la production solaire, ainsi que la variabilité des charges, peuvent engendrer des fluctuations de tension, des variations des flux de puissance et une augmentation des pertes dans les réseaux de distribution.(22)

Dans les approches traditionnelles, la gestion de la puissance réactive des générateurs photovoltaïques repose généralement sur des stratégies de contrôle simples, telles que les lois $Q(P)$ ou $Q(V)$.(23) Bien que ces méthodes permettent d'assurer le respect des exigences des codes de réseau, elles restent souvent limitées dans leur capacité à optimiser simultanément plusieurs critères de performance du système électrique, tels que la réduction des pertes, l'amélioration du profil de tension ou encore la limitation du chargement des lignes.

Les résultats obtenus dans le chapitre précédent ont montré que, dans les conditions normales de fonctionnement, l'injection photovoltaïque contribue à améliorer le fonctionnement du réseau en réduisant les pertes et le transit de puissance pendant les heures de production solaire. Néanmoins, ces résultats ont également mis en évidence certaines limites du fonctionnement conventionnel, notamment lorsque la demande électrique atteint son maximum alors que la production photovoltaïque diminue. Dans ce contexte, une approche plus avancée fondée sur l'optimisation et l'apprentissage automatique peut permettre d'exploiter de manière plus efficace

les capacités de régulation des onduleurs photovoltaïques.

L'apprentissage automatique constitue aujourd'hui un outil puissant pour l'analyse et l'optimisation des systèmes énergétiques complexes. En particulier, les *Extreme Learning Machines* (ELM) représentent une catégorie de réseaux de neurones artificiels à apprentissage rapide, caractérisés par une structure simple et un temps d'entraînement très réduit. Contrairement aux réseaux de neurones traditionnels, les ELM permettent de déterminer rapidement une relation non linéaire entre les variables d'entrée du système et les variables de sortie à optimiser, ce qui les rend particulièrement adaptés aux applications en temps réel dans les réseaux électriques intelligents.

Dans ce travail, l'objectif principal est d'utiliser un modèle ELM afin de déterminer la puissance réactive optimale à injecter par la centrale photovoltaïque, de manière à améliorer les performances globales du réseau électrique étudié. Pour atteindre cet objectif, il est nécessaire de disposer d'un jeu de données représentatif (*dataset*) décrivant les différents états de fonctionnement du réseau.

Ainsi, la première étape de ce chapitre consiste à générer un ensemble de données à partir des simulations réalisées dans DIgSILENT PowerFactory. Ces simulations permettent de faire varier plusieurs paramètres du système, notamment la puissance photovoltaïque, la charge du réseau, la tension au point de couplage commun et le niveau de chargement des lignes. À partir de ces variables, une fonction objectif est utilisée afin de déterminer la valeur optimale de la puissance réactive qui minimise les pertes électriques et améliore les performances du réseau.

Le *dataset* obtenu servira ensuite à entraîner le modèle *Extreme Learning Machine*, qui apprendra la relation entre les variables d'entrée du réseau et la puissance réactive optimale à injecter. Une fois entraîné, ce modèle pourra être utilisé pour prédire rapidement la consigne optimale de puissance réactive en fonction de l'état du réseau.(24)

Ce chapitre présente donc l'approche d'optimisation du réseau électrique étudié à l'aide des techniques d'apprentissage automatique. L'objectif est de développer un modèle intelligent capable de déterminer la puissance réactive optimale à injecter par la centrale photovoltaïque afin d'améliorer les performances du réseau en termes de profil de tension, de pertes électriques et de chargement des lignes.

Pour atteindre cet objectif, une méthodologie basée sur les *Extreme Learning Machines* est adoptée. Cette approche consiste à exploiter les données générées par les simulations du réseau afin d'entraîner un modèle capable de prédire la puissance réactive optimale en fonction de l'état du système électrique.

Ce chapitre est structuré de la manière suivante :

— **Section 3.1 : Fondements théoriques du Machine Learning :** Cette section présente les

principes généraux de l'apprentissage automatique, ainsi que son intérêt pour l'analyse et l'optimisation des systèmes électriques modernes.

— **Section 3.2 : Principe du modèle Extreme Learning Machine (ELM) :** Cette section introduit le modèle *Extreme Learning Machine* et décrit son fonctionnement en tant que réseau de neurones à une seule couche cachée, caractérisé par une grande rapidité d'apprentissage.

— **Section 3.3 : Formulation mathématique de la puissance réactive optimale :** Cette section présente la formulation mathématique du problème d'optimisation visant à déterminer la puissance réactive optimale permettant d'améliorer les performances du réseau électrique.

— **Section 3.4 : Construction du dataset :** Cette section décrit la méthodologie utilisée pour générer le jeu de données à partir des simulations du réseau réalisées dans DIgSILENT PowerFactory.

— **Section 3.5 : Entraînement et validation du modèle ELM :** Cette section présente le processus d'entraînement du modèle ELM ainsi que les méthodes utilisées pour évaluer ses performances de prédiction.

— **Section 3.6 : Intégration du contrôleur ELM dans PowerFactory :** Enfin, cette section décrit l'intégration du modèle ELM dans l'environnement de simulation afin d'implémenter un contrôleur intelligent de puissance réactive pour la centrale photovoltaïque.

3.1 Fondements théoriques du Machine Learning

Le *Machine Learning* ou apprentissage automatique est une branche de l'intelligence artificielle qui vise à donner à une machine la capacité d'apprendre à partir de données, sans être explicitement programmée pour chaque tâche à accomplir. Le principe fondamental consiste à exploiter des algorithmes capables d'identifier des relations, des tendances ou des structures cachées dans les données afin de réaliser des prédictions ou de prendre des décisions de manière autonome.(25)

Pour développer un modèle d'apprentissage automatique, il est nécessaire de disposer d'un ensemble de données, appelé *dataset*, qui servira de base à l'apprentissage. Ce *dataset* est généralement composé de variables d'entrée et de variables de sortie, permettant au modèle d'apprendre une relation mathématique entre les différentes grandeurs observées.(22)

De manière générale, l'apprentissage automatique peut se faire selon trois approches principales :

— l'apprentissage supervisé ;

— l'apprentissage non supervisé ;

— l'apprentissage par renforcement.

3.1.1 Apprentissage supervisé

L'apprentissage supervisé est l'approche la plus utilisée dans les applications d'ingénierie. Dans ce cas, le modèle apprend à partir d'un *dataset* contenant à la fois les variables d'entrée et la variable cible à prédire. L'objectif est d'établir une relation entre les entrées et la sortie afin de pouvoir généraliser cette relation à de nouvelles données.

Cette approche est particulièrement adaptée aux problèmes de :

— **régression**, lorsque la variable cible est continue ou quantitative, comme la puissance électrique, le courant, la tension ou la température ;

— **classification**, lorsque la variable cible est discrète ou qualitative, comme une catégorie, une couleur ou une classe d'état.

Par exemple, la régression est une méthode d'apprentissage supervisé utilisée pour prédire des valeurs continues telles que les ventes, le salaire, le poids, la température ou encore une puissance électrique.

À partir du *dataset*, il est ensuite nécessaire de choisir le type de modèle que la machine devra apprendre. Ce modèle peut être, par exemple :

— une régression linéaire ;

— une régression polynomiale ;

— un arbre de décision ;

— une machine à vecteurs de support (*Support Vector Machine, SVM*) ;

— une forêt aléatoire (*Random Forest*) ;

— un réseau de neurones ;

— une machine d'apprentissage extrême (*Extreme Learning Machine, ELM*).

Pour le modèle choisi, il faut également spécifier certains hyperparamètres. Par exemple, pour un arbre de décision, il peut s'agir de la profondeur maximale ou du nombre de branches ; pour un réseau de neurones, il s'agit notamment du nombre de couches cachées et du nombre de neurones par couche.(22)

Ensuite, la machine commence à apprendre en utilisant un algorithme d'optimisation afin de déterminer les paramètres du modèle qui offrent les meilleures performances sur les données d'apprentissage. Cette étape correspond à la phase d'entraînement.

Une fois cette phase terminée, le modèle est prêt à être utilisé. Il reçoit alors de nouvelles données, appelées données de test ou données d'entrée, et produit une prédiction de la variable cible Y, également appelée *target* ou *label*.(26)

3.1.2 Quelques algorithmes utilisés en Machine Learning

Parmi les principaux algorithmes utilisés en apprentissage automatique, on peut citer :

— les réseaux de neurones convolutifs (*Convolutional Neural Networks, CNN*) ;
— les réseaux de neurones récurrents (*Recurrent Neural Networks, RNN*) ;
— les machines à vecteurs de support (*SVM*) ;
— les forêts d'arbres de décision (*Random Forest*) ;
— les réseaux de neurones multicouches (*Multi-Layer Perceptron, MLP*) ;
— la machine d'apprentissage extrême (*Extreme Learning Machine, ELM*).(12)

3.1.3 Intérêt du Machine Learning dans les systèmes électriques

Dans les systèmes énergétiques modernes, notamment dans les réseaux électriques intégrant des sources d'énergie renouvelables telles que les centrales photovoltaïques, le *Machine Learning* joue un rôle essentiel dans l'analyse et la gestion de grandes quantités de données issues des capteurs, des mesures réseau et des systèmes de supervision.

Ces méthodes permettent notamment :

— d'améliorer la prévision de production ;
— d'optimiser les flux de puissance ;
— de faciliter la gestion intelligente de la puissance réactive ;
— d'exploiter des relations non linéaires difficiles à modéliser par des approches analytiques classiques.

Dans le contexte des systèmes photovoltaïques et des réseaux électriques intelligents, les approches basées sur les données (*data-driven*) sont de plus en plus utilisées pour modéliser des phénomènes complexes difficiles à représenter par des modèles physiques traditionnels. Ces méthodes permettent d'exploiter directement les données mesurées ou simulées afin de capturer les relations non linéaires entre les différentes variables du système électrique.(27)

3.2 Principe du modèle Extreme Learning Machine (ELM)

3.2.1 Introduction

Les réseaux de neurones artificiels (RNA) sont inspirés du fonctionnement du système nerveux biologique, en particulier du cerveau humain. L'idée fondamentale de ces modèles est de reproduire, de manière simplifiée, les mécanismes de traitement de l'information observés dans les réseaux de neurones naturels. Cette inspiration biologique constitue l'origine même du développement des réseaux de neurones artificiels dans le domaine de l'intelligence artificielle.(28)

Dans le cerveau humain, l'unité fondamentale de traitement de l'information est le neurone biologique. Le cerveau contient environ plusieurs dizaines de milliards de neurones, interconnectés par un très grand nombre de connexions appelées synapses. Chaque neurone reçoit, traite et transmet des signaux électriques et chimiques provenant d'autres neurones. Cette organisation permet au cerveau d'effectuer des fonctions complexes telles que la perception, la mémoire, l'apprentissage et la prise de décision.

Un neurone biologique est généralement constitué de trois parties principales :

— les dendrites, qui reçoivent les signaux provenant d'autres neurones ;
— le corps cellulaire (*soma*), qui traite les informations reçues ;
— l'axone, qui transmet le signal vers d'autres neurones à travers les synapses.

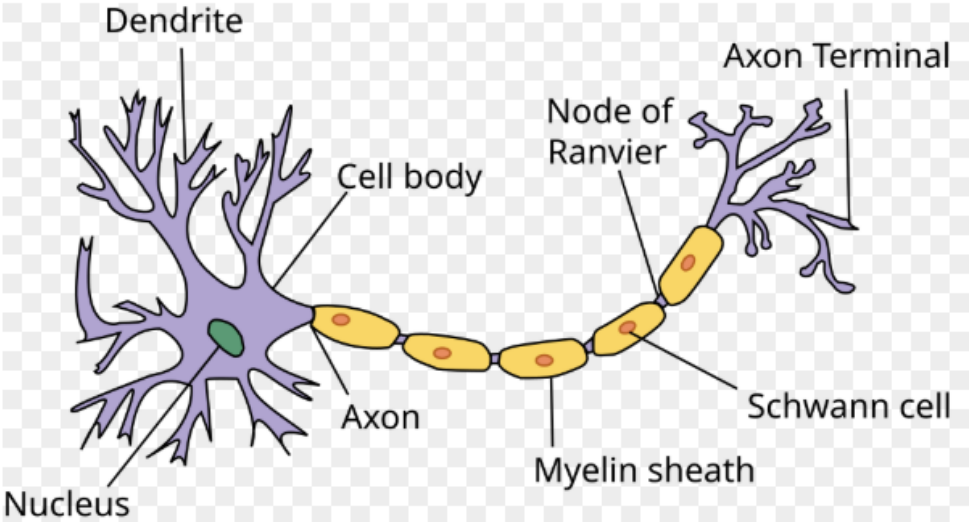

FIGURE 3.1. Structure d'un neurone biologique : dendrites, corps cellulaire, axone et synapses.

[1]

Le fonctionnement d'un neurone repose sur la réception de signaux électriques provenant des neurones voisins. Ces signaux sont combinés et analysés dans le corps cellulaire. Si la somme des signaux dépasse un certain seuil d'activation, le neurone génère un potentiel d'action, c'est-à-dire une impulsion électrique qui se propage le long de l'axone vers d'autres neurones. Ce mécanisme constitue la base de la transmission de l'information dans le système nerveux.

Les réseaux de neurones artificiels reproduisent ce principe de manière mathématique et simplifiée. Dans ce modèle, un neurone artificiel reçoit plusieurs entrées numériques correspondant aux signaux provenant d'autres neurones. Chaque entrée est associée à un poids synaptique qui représente l'importance de cette connexion. Le neurone effectue ensuite une combinaison pondérée de ces entrées et applique une fonction d'activation afin de produire une sortie.

1. Source : Adapté de Wikimedia Commons, *Neuron Diagram*, https ://commons.wikimedia.org/wiki/File :Neuron.svg

3.2.2 L'Extreme Learning Machine (ELM)

L'*Extreme Learning Machine* (ELM) est un modèle de *Machine Learning* appartenant à la famille des réseaux de neurones artificiels à propagation avant (*Feedforward Neural Networks*). Ce modèle a été introduit afin de résoudre certaines limitations des réseaux de neurones classiques, notamment les temps d'apprentissage élevés et la complexité du processus d'optimisation des paramètres.(28)

Le principe fondamental de l'ELM repose sur l'utilisation d'un réseau de neurones à une seule couche cachée (*Single Hidden Layer Feedforward Network – SLFN*). Contrairement aux réseaux de neurones traditionnels qui utilisent des méthodes d'apprentissage itératives telles que l'algorithme de rétropropagation du gradient, l'ELM adopte une approche différente dans laquelle les paramètres internes du réseau sont déterminés de manière analytique, ce qui permet de réduire considérablement le temps de calcul.(29)

Dans un modèle ELM, les poids reliant la couche d'entrée à la couche cachée ainsi que les biais des neurones cachés sont générés aléatoirement et restent fixes pendant le processus d'apprentissage. Seuls les poids reliant la couche cachée à la couche de sortie sont calculés de manière analytique en résolvant un système d'équations linéaires.

Cette approche permet de réduire considérablement le temps de calcul tout en conservant une bonne capacité de généralisation du modèle.(30)

L'architecture générale d'un modèle ELM comprend trois couches principales :

— **La couche d'entrée** : elle reçoit les variables d'entrée du système étudié.
— **La couche cachée** : composée de plusieurs neurones qui appliquent une fonction d'activation non linéaire afin de transformer les données d'entrée.
— **La couche de sortie** : elle fournit la prédiction du modèle.

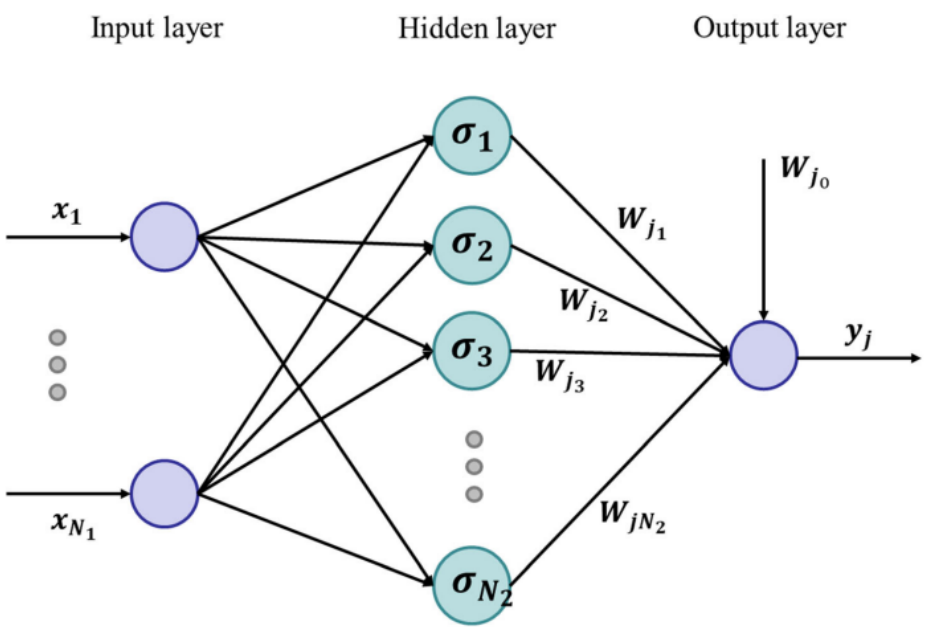

FIGURE 3.2. Architecture d'un réseau de neurones à propagation avant utilisé dans le modèle Extreme Learning Machine (ELM).

[2]

La sortie du réseau peut être représentée sous la forme :

$$y_j = \sum_{i=1}^{H} \beta_i G(w_i \cdot x_j + b_i)(22) \tag{3.1}$$

Où :

— x_j correspond au vecteur d'entrée du j^{me} échantillon ;

— w_i est le vecteur de poids reliant la couche d'entrée au neurone caché i ;

— b_i est le biais du neurone caché ;

— $G(\cdot)$ représente la fonction d'activation ;

— β_i est le poids reliant le neurone caché i à la couche de sortie ;

— y_j est la sortie du réseau ;

— H est le nombre de neurones dans la couche cachée.

Dans l'ELM, les paramètres w_i et b_i sont choisis aléatoirement, tandis que les poids de sortie β_i sont déterminés en minimisant l'erreur entre la sortie du modèle et les données cibles. Cette opération est généralement réalisée en utilisant la pseudo-inverse de Moore–Penrose.

$$\beta = H^{\dagger} T \tag{3.2}$$

2. Source : Adapté de Huang, G.-B., Zhu, Q.-Y., & Siew, C.-K. (2006), Extreme learning machine : theory and applications, Neurocomputing. https ://www.extreme-learning-machines.org/pdf/ELM-NC-2006.pdf

où $H^{\dagger}$ représente la pseudo-inverse de la matrice H et T correspond au vecteur des sorties cibles.

L'un des principaux avantages du modèle ELM réside dans sa vitesse d'apprentissage très élevée, car il ne nécessite pas de processus d'optimisation itératif. De plus, plusieurs études ont montré que l'ELM présente une bonne capacité de généralisation, ce qui le rend particulièrement adapté aux problèmes de modélisation non linéaire et de prédiction dans les systèmes énergétiques.

3.2.3 Choix du modèle pour ce travail de fin d'étude

Dans le cadre de ce travail, le modèle ELM est utilisé afin d'apprendre la relation entre les variables caractéristiques du réseau électrique étudié et la puissance réactive optimale à injecter par la centrale photovoltaïque.

L'objectif est de développer un modèle capable de fournir rapidement une estimation de cette puissance réactive optimale afin d'améliorer les performances du réseau en termes de pertes, de niveau de tension et de chargement des lignes.

3.3 Formulation mathématique de la puissance réactive optimale

Dans le cadre de l'intégration d'une centrale photovoltaïque dans un réseau de distribution, la détermination d'une puissance réactive optimale constitue un problème d'optimisation visant à améliorer les performances globales du réseau.(17)

La puissance réactive optimale est définie comme :

$$Q_{opt} = \arg\min_{Q} J(Q) \tag{3.3}$$

où $J(Q)$ est la fonction coût évaluée pour une valeur candidate de puissance réactive.

3.3.1 Fonction coût utilisée dans le script

La fonction coût adoptée dans cette étude est inspirée des formulations classiques du problème d'optimisation de la puissance réactive dans les réseaux électriques, généralement désigné dans la littérature sous le nom d'Optimal Reactive Power Dispatch (ORPD). Dans ce type de problème, l'objectif consiste à déterminer les réglages optimaux des variables de contrôle, notamment la puissance réactive injectée par les générateurs, de manière à améliorer les performances globales du réseau tout en respectant les contraintes opérationnelles.

Dans les travaux académiques sur l'ORPD et l'Optimal Power Flow (OPF), la fonction objectif est souvent construite comme une combinaison pondérée de plusieurs critères techniques du réseau. Ces critères incluent généralement la minimisation des pertes actives dans les lignes, la réduction des écarts de tension par rapport à la valeur nominale et la limitation du chargement des lignes ou des transformateurs. Une formulation multi-critère de ce type est largement utilisée dans la littérature afin de représenter de manière réaliste les différents objectifs de fonctionnement du réseau électrique.(13)

Dans ce travail, la fonction coût est formulée sous la forme d'une combinaison pondérée de plusieurs termes de pénalisation correspondant respectivement à la déviation de la tension au point de couplage commun, au taux de chargement des lignes, aux pertes actives du réseau et à l'effort de compensation réactive fourni par la centrale photovoltaïque. Cette formulation permet de traduire le problème d'optimisation du réseau sous la forme d'une fonction scalaire unique, facilitant ainsi la recherche de la puissance réactive optimale.

Des formulations similaires ont été largement utilisées dans les travaux de référence sur l'optimisation des réseaux électriques, notamment dans les ouvrages de Wood et Wollenberg (1996), Kundur (1994) et Conejo (2006), qui décrivent les bases théoriques des problèmes d'Optimal Power Flow et de contrôle optimal de la puissance réactive dans les systèmes électriques.(13)

$$J = w_V\, term_V + w_L\, term_L + w_P\, term_P + w_Q\, term_Q \tag{3.4}$$

[3]

où :

— w_V est le poids associé au critère de tension ;

— w_L est le poids associé au critère de chargement ;

— w_P est le poids associé aux pertes actives ;

— w_Q est le poids associé à l'effort de compensation réactive.

Terme de tension

$$term_V = \left(\frac{V - 1.0}{V_{BAND}}\right)^2 (13) \tag{3.5}$$

où :

— V est la tension au PCC en p.u ;

— V_{BAND} représente la bande de tolérance autour de la tension nominale.

3. Comme décrit dans la littérature sur l'Optimal Power Flow Wood1996,Kundur1994,Conejo2006.

Terme de chargement des lignes

$$term_L = \begin{cases} 0 & \text{si } L \leq LOADING_LIMIT \\ \left(\frac{L - LOADING_LIMIT}{LOADING_LIMIT}\right)^2 & \text{si } L > LOADING_LIMIT \end{cases} \tag{3.6}$$

où L est le taux de chargement de la ligne critique.

Terme lié aux pertes actives

$$term_P = \left(\frac{P_l}{P_{loss_ref} + \varepsilon}\right)^2 \tag{3.7}$$

où :

— P_l représente les pertes actives du réseau ;

— P_{loss_ref} est une valeur de référence ;

— ε est une constante évitant la division par zéro.

Terme de pénalisation de la puissance réactive

$$term_Q = \left(\frac{q_{act_tot}}{q_{max_tot} + \varepsilon}\right)^2 \tag{3.8}$$

où :

— q_{act_tot} est la puissance réactive injectée ;

— q_{max_tot} est la capacité maximale de puissance réactive disponible.

Ainsi, la fonction coût finale peut s'écrire :

$$J = w_V \left(\frac{V - 1.0}{V_{BAND}}\right)^2 + w_L \left(\max(0, L - LOADING_LIMIT)\right)^2 + w_P \left(\frac{P_l}{P_{loss_ref} + \varepsilon}\right)^2 + w_Q \left(\frac{q_{act_tot}}{q_{max_tot} + \varepsilon}\right)^2 \tag{3.9}$$

Cette formulation permet de rechercher un compromis entre :

— le maintien de la tension proche de la valeur nominale ;

— l'évitement des surcharges de lignes ;

— la réduction des pertes actives ;

— la limitation de l'effort de compensation réactive.

Détermination de la cible du dataset

Pour chaque scénario simulé, plusieurs valeurs candidates de puissance réactive sont testées. À chaque essai, les grandeurs du réseau sont recalculées par *load flow*, puis la fonction coût J est évaluée. La valeur de puissance réactive qui donne la plus petite valeur de J est retenue comme puissance réactive optimale :

$$Q_{\text{opt}} = \arg\min_{Q} J(Q) \tag{3.10}$$

Cette valeur Q_{opt} constitue alors la sortie cible du dataset, tandis que les variables décrivant l'état du réseau constituent les entrées du modèle d'apprentissage.

Dans notre cas, les entrées du dataset sont :

$$X = [P_{pv}, P_{load}, Q_{load}, V_{PCC}, L, P_{loss}] \tag{3.11}$$

où :

— P_{pv} : puissance active totale produite par la centrale photovoltaïque ;
— P_{load} : puissance active de la charge ;
— Q_{load} : puissance réactive de la charge ;
— V_{PCC} : tension au point de couplage commun ;
— L : taux de chargement de la ligne critique ;
— P_{loss} : pertes actives totales du réseau.

La sortie associée est :

$$Y = Q_{\text{opt}} \tag{3.12}$$

Ainsi, le problème d'optimisation électrique est transformé en un problème d'apprentissage supervisé dans lequel le modèle ELM apprend à approximer la relation :

$$Q_{\text{opt}} = f(P_{pv}, P_{load}, Q_{load}, V_{PCC}, L, P_{loss}) \tag{3.13}$$

3.4 Construction du Dataset

Afin d'entraîner le modèle d'apprentissage automatique destiné à estimer la puissance réactive optimale, un jeu de données (*dataset*) a été généré à partir de simulations réalisées dans l'environnement DIgSILENT PowerFactory. Ce dataset relie différents états de fonctionnement du réseau électrique à la valeur optimale de la puissance réactive à injecter par la centrale photovoltaïque.

La génération de ces données repose sur une approche basée sur la simulation quasi-dynamique, permettant de reproduire l'évolution du réseau au cours d'une journée complète tout en prenant en compte plusieurs conditions d'exploitation du système électrique.

3.4.1 Principe de génération des données

Le dataset est généré à l'aide d'un script Python utilisant l'interface de programmation de DIgSILENT PowerFactory. Le script automatise les étapes suivantes :

— modification des paramètres du réseau selon différents scénarios d'exploitation ;
— exécution d'une simulation quasi-dynamique sur une période de 24 heures ;
— calcul du flux de puissance pour chaque instant ;
— recherche de la puissance réactive optimale à l'aide d'un balayage de valeurs candidates ;
— enregistrement des grandeurs électriques du réseau dans un fichier CSV.

Cette procédure permet de générer automatiquement un grand nombre de configurations du réseau tout en garantissant la cohérence physique des données produites.

3.4.2 Scénarios de fonctionnement du réseau

Afin de représenter différentes conditions d'exploitation réalistes du réseau, plusieurs scénarios de fonctionnement ont été définis. Chaque scénario correspond à une combinaison particulière de niveau de charge, de production photovoltaïque et de tension du réseau amont.

Au total, 11 scénarios ont été considérés, parmi lesquels :

— fonctionnement normal du réseau ;
— forte charge ;
— charge très élevée ;
— fort ensoleillement ;
— faible production photovoltaïque ;
— réseau relativement faible ;
— réseau relativement fort ;
— pointe de consommation en soirée.

Pour chaque scénario, des multiplicateurs sont appliqués à plusieurs paramètres du système :

— la production photovoltaïque ;
— la puissance active de la charge ;
— la puissance réactive de la charge ;
— la tension du réseau amont.

Ces multiplicateurs introduisent une variabilité réaliste du fonctionnement du réseau.

3.4.3 Génération temporelle des données

Pour chaque scénario, plusieurs jours synthétiques sont simulés. Dans l'étude réalisée :

— 20 jours synthétiques sont générés par scénario ;

— chaque journée comporte 24 instants horaires.

Ainsi, le nombre total de points de simulation est donné par :

$$N = N_{\text{scénarios}} \times N_{\text{jours}} \times N_{\text{heures}} \tag{3.14}$$

Avec :

$$N = 11 \times 20 \times 24 = 5280 \tag{3.15}$$

Le dataset final comporte donc 5280 points, chacune représentant un état particulier du réseau.

Détermination de la puissance réactive optimale

Pour chaque état du réseau, la puissance réactive optimale est déterminée par une procédure d'optimisation basée sur un balayage de valeurs candidates.(21)

Le fonctionnement de l'onduleur étant limité par sa puissance apparente nominale S, la capacité maximale de puissance réactive disponible pour chaque onduleur est déterminée à partir de la relation :

$$Q_{\max} = \sqrt{S^2 - P^2} \tag{3.16}$$

où :

— S est la puissance apparente nominale de l'onduleur ;

— P est la puissance active injectée par le système photovoltaïque.

Dans l'étude, chaque sous-champ photovoltaïque possède un onduleur de 3 MVA.

Le script teste ensuite plusieurs valeurs de puissance réactive réparties symétriquement dans l'intervalle :

$$Q \in [-\alpha Q_{\max}, \alpha Q_{\max}] \tag{3.17}$$

avec :

$$\alpha = 0.5$$

Pour chaque valeur candidate de puissance réactive :

— un calcul de flux de puissance est effectué ;

— les grandeurs électriques du réseau sont mesurées ;

— la fonction coût J est évaluée.

La valeur de puissance réactive qui minimise cette fonction coût est retenue comme puissance réactive optimale :

$$Q_{\text{opt}} = \arg\min_{Q} J(Q) \tag{3.18}$$

Variables enregistrées dans le dataset

Pour chaque simulation, plusieurs grandeurs électriques sont enregistrées afin de caractériser l'état du réseau.

Les variables d'entrée du modèle sont :

— la puissance active totale de la centrale photovoltaïque P_{pv} ;

— la puissance active de la charge P_{load} ;

— la puissance réactive de la charge Q_{load} ;

— la tension au point de couplage commun V_{PCC} ;

— le taux de chargement de la ligne critique L ;

— les pertes actives totales du réseau P_{loss}.

La variable de sortie correspond à :

— la puissance réactive optimale Q_{opt}.

D'autres informations relatives au scénario et aux multiplicateurs appliqués sont également enregistrées afin de faciliter l'analyse des données.

Structure finale du dataset

Chaque ligne du dataset correspond donc à un état particulier du réseau et peut être représentée sous la forme :

$$(X, Y) \tag{3.19}$$

où :

$$X = [P_{pv}, P_{load}, Q_{load}, V_{PCC}, L, P_{loss}] \tag{3.20}$$

représente le vecteur des variables d'entrée, et

$$Y = Q_{opt} \tag{3.21}$$

représente la sortie cible du modèle d'apprentissage.

Les données sont ensuite exportées dans un fichier CSV afin d'être utilisées pour l'entraînement et la validation du modèle Extreme Learning Machine (ELM).

Le dataset ainsi construit constitue la base de l'apprentissage du modèle ELM. La section suivante est donc consacrée au processus d'entraînement et de validation du modèle, ainsi qu'à l'évaluation de ses performances dans la prédiction de la puissance réactive optimale.

TABLE 3.1. Aperçu du dataset utilisé pour l'entraînement du modèle ELM

P_{pv} (MW)	P_{load} (MW)	Q_{load} (MVar)	V_{PCC} (p.u)	Line loading (%)	P_{loss} (MW)	Q_{opt} (MVar)
0.000000	2.032742	0.668130	0.995167	36.112	0.211885	0.000000
0.000000	1.358858	0.446635	0.996524	29.585	0.203439	0.000000
0.000000	1.493933	0.491032	0.996253	30.891	0.205058	0.000000
0.000000	1.358858	0.446635	0.996524	29.585	0.203439	0.000000
0.307778	1.899424	0.624310	0.996378	31.497	0.206197	0.209724
0.923334	2.305365	0.757737	0.997380	28.944	0.205431	0.622497
2.154446	2.579210	0.847745	0.998753	20.333	0.204305	0.914642
3.693334	2.719513	0.893861	0.998848	12.909	0.212408	0.661991
4.924443	2.858096	0.939411	0.999246	13.762	0.228685	0.639845
5.847775	2.995293	0.984505	0.997491	23.457	0.250175	-0.000019
6.155551	2.996083	0.984765	0.997622	25.238	0.257180	-0.000020
5.847774	2.860660	0.940253	0.997756	23.697	0.249487	-0.000019
4.924443	2.723445	0.895153	0.999512	13.758	0.227883	0.639845
3.693333	2.584919	0.849622	0.999115	11.993	0.211375	0.661991
2.154446	2.444778	0.803559	0.997665	20.854	0.203124	0.457317
0.923334	2.707793	0.890008	0.996571	32.862	0.210339	0.622497
0.307776	2.971847	0.976799	0.994213	41.932	0.220544	0.209724
0.000000	3.236501	1.063786	0.992734	47.829	0.229301	0.000000
0.000000	3.103336	1.020017	0.993004	46.529	0.227226	0.000000
0.000000	2.836568	0.932334	0.993545	43.928	0.223181	0.000000

Le tableau 3.1 présente un extrait du dataset généré à partir des simulations réalisées dans DIgSILENT PowerFactory. Chaque ligne correspond à un état particulier du réseau électrique caractérisé par plusieurs variables d'entrée telles que la puissance photovoltaïque, la charge du réseau, la tension au PCC, le chargement de la ligne et les pertes actives. La dernière colonne

représente la puissance réactive optimale Q_{opt} déterminée à partir de la fonction coût définie précédemment. Ce dataset est ensuite utilisé pour entraîner le modèle Extreme Learning Machine afin d'apprendre la relation entre l'état du réseau et la puissance réactive optimale.

3.5 Entraînement et validation du modèle ELM

Après la génération du dataset à partir des simulations du réseau électrique, l'étape suivante consiste à entraîner un modèle d'apprentissage automatique capable de prédire la puissance réactive optimale en fonction de l'état du réseau. Dans ce travail, l'algorithme retenu est l'*Extreme Learning Machine* (ELM), qui constitue une méthode efficace pour l'apprentissage des réseaux de neurones à une seule couche cachée.

L'objectif de cette étape est d'apprendre la relation non linéaire reliant les grandeurs électriques du réseau à la puissance réactive optimale déterminée lors de la phase d'optimisation.

3.5.1 Préparation des données

Avant l'entraînement du modèle, le dataset généré doit être préparé afin d'être exploité efficacement par l'algorithme d'apprentissage. Les données sont stockées dans un fichier CSV généré à partir des simulations réalisées dans DIgSILENT PowerFactory.

Les variables d'entrée du modèle correspondent aux grandeurs décrivant l'état du réseau électrique :

$$X = [P_{pv}, P_{load}, Q_{load}, V_{PCC}, L, P_{loss}] \tag{3.22}$$

où :

— P_{pv} : puissance active totale produite par la centrale photovoltaïque ;
— P_{load} : puissance active de la charge ;
— Q_{load} : puissance réactive de la charge ;
— V_{PCC} : tension au point de couplage commun ;
— L : taux de chargement de la ligne critique ;
— P_{loss} : pertes actives totales du réseau.

La variable de sortie correspond à :

$$Y = Q_{opt} \tag{3.23}$$

qui représente la puissance réactive optimale obtenue par minimisation de la fonction coût définie dans la section précédente.

3.5.2 Normalisation des données

Afin d'améliorer les performances de l'apprentissage, les variables d'entrée sont généralement normalisées ou standardisées. Cette étape permet d'éviter que certaines variables dominent le processus d'apprentissage en raison de leur ordre de grandeur.

Dans cette étude, la normalisation des variables d'entrée est réalisée à l'aide de la transformation suivante :

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \tag{3.24}$$

où :

— X_{norm} représente la variable normalisée ;

— X représente la valeur originale de la variable ;

— X_{min} et X_{max} correspondent respectivement aux valeurs minimale et maximale observées dans le dataset.

Cette transformation permet de ramener toutes les variables d'entrée dans l'intervalle $[0, 1]$, facilitant ainsi le processus d'apprentissage du modèle.

3.5.3 Division des données d'apprentissage et de test

Afin d'évaluer correctement les performances du modèle ELM, le dataset est divisé en deux sous-ensembles :

— un ensemble d'apprentissage (*training set*) utilisé pour entraîner le modèle ;

— un ensemble de test (*test set*) utilisé pour évaluer la capacité de généralisation du modèle.

Dans ce travail, une division classique est utilisée :

— 80% des données sont utilisées pour l'entraînement ;

— 20% des données sont utilisées pour le test.

Si N représente le nombre total d'échantillons du dataset, le nombre d'échantillons utilisés pour l'apprentissage est donné par :

$$N_{train} = 0.8 \times N \tag{3.25}$$

et le nombre d'échantillons utilisés pour le test par :

$$N_{test} = 0.2 \times N \tag{3.26}$$

Dans le cas de cette étude, le dataset comporte $N = 5280$ échantillons, ce qui conduit à :

$$N_{train} = 4224, \qquad N_{test} = 1056 \tag{3.27}$$

Ces données sont ensuite utilisées pour entraîner le modèle ELM et évaluer sa capacité à prédire correctement la puissance réactive optimale à partir de l'état du réseau électrique.

```
[2]: import pandas as pd

df = pd.read_csv(r"C:\Users\Public\Documents\DATASET_TFE_MBUSU_new_essai.csv", sep=";")

print("Nombre de lignes :", len(df))
print("Colonnes :", df.columns)
df.head()

Nombre de lignes : 5280
Colonnes : Index(['P_pv_tot_MW', 'P_load_MW', 'Q_load_MVAr', 'V_pcc_pu',
       'line_loading_pct', 'P_loss_MW', 'Q_opt_actual_tot_MVAr'],
      dtype='object')
```

[2]:

	P_pv_tot_MW	P_load_MW	Q_load_MVAr	V_pcc_pu	line_loading_pct	P_loss_MW	Q_opt_actual_tot_MVAr
0	0.0	2.032742	0.668130	0.995167	36.112	0.211885	0.0
1	0.0	1.358858	0.446635	0.996524	29.585	0.203439	0.0
2	0.0	1.358858	0.446635	0.996524	29.585	0.203439	0.0
3	0.0	1.493933	0.491032	0.996253	30.891	0.205058	0.0
4	0.0	1.358858	0.446635	0.996524	29.585	0.203439	0.0

FIGURE 3.3. Lecture du dataset et affichage des premières lignes dans l'environnement Python à l'aide de la bibliothèque *Pandas*.

[4] La figure 3.3 présente l'importation du dataset généré à partir des simulations PowerFactory dans l'environnement Python. Le fichier CSV contenant les données est chargé à l'aide de la bibliothèque *Pandas*, qui permet de manipuler efficacement les données tabulaires. L'instruction `pd.read_csv()` est utilisée pour lire le fichier contenant le dataset, tandis que les fonctions `len(df)` et `df.columns` permettent respectivement d'afficher le nombre total d'échantillons et les différentes variables du dataset.

Les premières lignes du dataset sont ensuite affichées afin de vérifier la structure des données et la cohérence des variables avant l'entraînement du modèle Extreme Learning Machine (ELM).

3.5.4 Principe de l'apprentissage ELM

Le modèle *Extreme Learning Machine* (ELM) est basé sur un réseau de neurones à une seule couche cachée (*Single Hidden Layer Feedforward Neural Network – SLFN*). Dans ce modèle :

— Les poids reliant la couche d'entrée à la couche cachée sont générés aléatoirement ;

— Seuls les poids reliant la couche cachée à la couche de sortie sont déterminés lors de la phase d'apprentissage.

Le fonctionnement du modèle peut être exprimé par la relation :

$$Y = H\beta \tag{3.28}$$

4. Source : Capture d'écran de l'environnement de développement Python utilisé pour le traitement du dataset

où :

— H est la matrice de sortie de la couche cachée ;

— β est le vecteur des poids reliant la couche cachée à la couche de sortie ;

— Y est le vecteur des sorties du réseau.

La matrice H est obtenue en appliquant une fonction d'activation non linéaire aux combinaisons pondérées des entrées :

$$H = g(WX + b) \tag{3.29}$$

où :

— W est la matrice des poids aléatoires de la couche d'entrée ;

— X est la matrice des données d'entrée ;

— b est le biais des neurones cachés ;

— $g(\cdot)$ est la fonction d'activation.

Les poids de sortie β sont ensuite déterminés en résolvant le système linéaire suivant :

$$\beta = H^{\dagger} Y \tag{3.30}$$

où $H^{\dagger}$ représente la pseudo-inverse de Moore–Penrose de la matrice H.

Cette approche permet d'obtenir une solution analytique rapide, ce qui constitue l'un des principaux avantages du modèle ELM par rapport aux méthodes d'apprentissage classiques basées sur l'optimisation itérative.

3.5.5 Division du dataset

Pour évaluer la capacité de généralisation du modèle, le dataset est divisé en deux ensembles :

— un ensemble d'entraînement (*training set*) utilisé pour apprendre les paramètres du modèle ;

— un ensemble de test (*test set*) utilisé pour évaluer les performances du modèle sur des données non vues.

Dans cette étude, le dataset est divisé selon la répartition suivante :

— 80% des données pour l'entraînement ;

— 20% des données pour le test.

Si N représente le nombre total d'échantillons du dataset, la taille des ensembles d'apprentissage et de test est donnée par :

$$N_{train} = 0.8 \times N \tag{3.31}$$

$$N_{test} = 0.2 \times N \tag{3.32}$$

Dans le cas de cette étude, le dataset comporte $N = 5280$ échantillons, ce qui conduit à :

$$N_{train} = 4224 \tag{3.33}$$

$$N_{test} = 1056 \tag{3.34}$$

```
Nombre de lignes valides : 5060
Colonnes utilisées : ['P_pv_tot_MW', 'P_load_MW', 'Q_load_MVAr', 'V_pcc_pu', 'line_loading_pct', 'P_loss_MW']
Cible : Q_opt_actual_tot_MVAr
Train : (4048, 6) (4048,)
Test  : (1012, 6) (1012,)
```

FIGURE 3.4. Résumé de la structure du dataset et de la division des données en ensembles d'entraînement et de test dans l'environnement Python.

[5].

3.5.6 Évaluation des performances du modèle

La capacité du modèle à prédire correctement la puissance réactive optimale pour de nouveaux états du réseau est évaluée à l'aide de plusieurs indicateurs statistiques couramment utilisés dans les problèmes de régression.

Erreur quadratique moyenne (MSE)

L'erreur quadratique moyenne (*Mean Squared Error*) mesure la moyenne des carrés des écarts entre les valeurs prédites par le modèle et les valeurs réelles du dataset :

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{3.35}$$

où :

— y_i représente la valeur réelle de la puissance réactive optimale ;

— $\hat{y}_i$ représente la valeur prédite par le modèle ;

— N est le nombre d'échantillons du dataset.

5. Source : Capture d'écran du script Python utilisé pour la préparation des données

Racine de l'erreur quadratique moyenne (RMSE)

La racine de l'erreur quadratique moyenne (*Root Mean Squared Error*) est définie comme :

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} \tag{3.36}$$

Cet indicateur permet d'exprimer l'erreur moyenne de prédiction dans la même unité que la variable prédite, ce qui facilite son interprétation.

Coefficient de détermination R^2

Le coefficient de détermination R^2 mesure la capacité du modèle à expliquer la variance des données observées :

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2} \tag{3.37}$$

où $\bar{y}$ représente la moyenne des valeurs réelles.

Un coefficient R^2 proche de 1 indique une excellente capacité du modèle à reproduire la relation entre les variables d'entrée et la puissance réactive optimale.

3.5.7 Présentation des résultats de performance du modèle ELM

Les résultats obtenus montrent que le modèle ELM est capable d'apprendre efficacement la relation non linéaire reliant l'état du réseau à la puissance réactive optimale. Grâce à sa structure simple et à son apprentissage rapide, ce modèle constitue une solution particulièrement adaptée pour une implémentation dans un système de contrôle en temps réel.

La précision des prédictions obtenues confirme la pertinence de l'approche adoptée, dans laquelle les données issues des simulations réalisées sous DIgSILENT PowerFactory sont exploitées afin d'entraîner un modèle d'apprentissage capable de reproduire le comportement optimal du système électrique.

Il convient également de souligner qu'une fois le modèle ELM entraîné et validé, celui-ci peut être intégré dans l'environnement de simulation afin de générer en temps réel la consigne optimale de puissance réactive.

La section suivante présente donc l'intégration du contrôleur ELM dans le réseau modélisé sous PowerFactory.

```
Nombre de lignes valides : 5060
Colonnes utilisées : ['P_pv_tot_MW', 'P_load_MW', 'Q_load_MVAr', 'V_pcc_pu', 'line_loading_pct', 'P_loss_MW']
Cible : Q_opt_actual_tot_MVAr
Train : (4048, 6) (4048,)
Test  : (1012, 6) (1012,)

===== METRICS TEST =====
MAE  : 6.914202860015202e-16
RMSE : 8.628947710840077e-16
R2   : 1.0
```

FIGURE 3.5. Résultats de l'évaluation du modèle ELM sur l'ensemble de test montrant les indicateurs statistiques MAE, RMSE et R^2.

6

TABLE 3.2. Aperçu des résultats de prédiction du modèle ELM

Index	Q_{reel} (MVar)	Q_{pred} (MVar)	Erreur abs.
0	0.000000	3.608225e-16	6.08225e-16
1	0.457317	4.573170e-01	4.440892e-16
2	0.209724	2.097240e-01	9.436896e-16
3	0.661991	6.619910e-01	3.330669e-16
4	0.000000	1.137779e-15	1.137779e-15
5	0.000000	-2.775558e-17	2.775558e-17
6	0.209724	2.097240e-01	2.221245e-15
7	0.639845	6.398450e-01	6.661338e-16
8	0.639845	6.398450e-01	6.661338e-16
9	0.000019	1.900000e-05	1.018202e-15
10	0.000000	3.608225e-16	3.608225e-16
11	0.209724	2.097240e-01	2.221245e-15
12	0.914642	9.146420e-01	2.220446e-16
13	0.000000	1.137779e-15	1.137779e-15
14	0.000000	1.554312e-15	1.554312e-15
15	0.209724	2.097240e-01	2.221245e-15
16	0.000000	-2.498002e-16	2.498002e-16
17	0.000000	1.193490e-15	1.193490e-15
18	0.000000	3.608225e-16	3.608225e-16
19	0.661991	6.619910e-01	0.000000e+00

Après l'entraînement du modèle *Extreme Learning Machine* (ELM) sur le jeu de données

généré à partir des simulations réalisées sous DIgSILENT PowerFactory, les performances du modèle ont été évaluées à l'aide de plusieurs indicateurs statistiques, notamment l'erreur absolue moyenne (*Mean Absolute Error, MAE*), la racine de l'erreur quadratique moyenne (*Root Mean Squared Error, RMSE*) et le coefficient de détermination R^2.

Les résultats obtenus montrent des erreurs de prédiction extrêmement faibles ainsi qu'un coefficient de détermination égal ou très proche de l'unité.

3.5.8 Interprétation des métriques MAE, RMSE et R^2

Ces résultats doivent être interprétés en tenant compte de la nature du jeu de données utilisé dans cette étude. En effet, le dataset n'est pas issu de mesures expérimentales réelles entachées de bruit ou d'incertitudes, mais d'un processus de simulation numérique déterministe combinant :

— des simulations du réseau sous DIgSILENT PowerFactory ;
— une fonction coût bien définie ;
— une procédure d'optimisation numérique permettant de déterminer la puissance réactive optimale.

Ainsi, chaque ligne du dataset est obtenue selon la logique suivante :

$$\text{État du réseau} \longrightarrow \text{Optimisation} \longrightarrow Q_{opt} \tag{3.38}$$

Autrement dit, le dataset peut être représenté sous la forme :

$$X \longrightarrow Q_{opt} \tag{3.39}$$

avec :

$$X = [P_{pv}, P_{load}, Q_{load}, V_{PCC}, Loading, P_{loss}] \tag{3.40}$$

Dans ce cadre, la procédure d'optimisation applique une relation déterministe de la forme :

$$Q_{opt} = f(X) \tag{3.41}$$

Cela signifie que pour un même état du réseau, décrit par le vecteur d'entrée X, on obtient toujours la même valeur optimale de puissance réactive Q_{opt}. Il n'existe donc pas d'incertitude aléatoire dans la génération de la cible du modèle.

Le rôle du modèle ELM consiste alors à apprendre cette fonction non linéaire déterministe afin de reproduire directement la relation entre les variables d'entrée du réseau et la puissance réactive optimale.

3.5.9 Justification d'un coefficient $R^2 = 1$

Le coefficient de détermination est défini par :

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2} \tag{3.42}$$

où :

— y_i représente la valeur réelle de la sortie ;

— $\hat{y}_i$ représente la valeur prédite par le modèle ;

— $\bar{y}$ représente la moyenne des valeurs réelles.

Lorsque l'erreur de prédiction est quasi nulle, le terme résiduel :

$$SS_{res} = \sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{3.43}$$

devient très proche de zéro, ce qui conduit à :

$$R^2 \approx 1 \tag{3.44}$$

Dans ce travail, cette situation s'explique par le fait que :

— le dataset est propre et cohérent ;

— les données proviennent d'un processus de simulation numérique ;

— il n'existe pas de bruit de mesure comme dans le cas de données expérimentales réelles ;

— la cible Q_{opt} est obtenue à partir d'une règle d'optimisation déterministe.

Par conséquent, un coefficient R^2 égal à 1 n'est pas anormal dans ce contexte. Il signifie simplement que le modèle ELM est capable de reproduire presque parfaitement la relation fonctionnelle utilisée pour générer les données.

Les performances du modèle ELM obtenues lors de la phase de validation montrent donc un coefficient de détermination très proche de l'unité ainsi que des erreurs de prédiction extrêmement faibles. Ces résultats confirment que le modèle est capable d'apprendre efficacement la relation non linéaire reliant l'état du réseau à la puissance réactive optimale.

Le modèle ELM agit ainsi comme un approximateur universel capable de reproduire avec une très grande précision la fonction d'optimisation utilisée pour générer le dataset. En d'autres termes, il apprend fidèlement la relation entre les variables d'entrée du réseau et la puissance réactive optimale.

La figure de régression entre les valeurs réelles et les valeurs prédites montre que l'ensemble des points se situe pratiquement sur la droite :

$$y = x \tag{3.45}$$

ce qui confirme que les prédictions du modèle correspondent parfaitement aux valeurs réelles issues du processus d'optimisation.

De plus, la comparaison temporelle entre les valeurs réelles et les valeurs prédites indique que les deux courbes se superposent presque entièrement, ce qui confirme la capacité du modèle à reproduire le comportement du système étudié.

Ainsi, le modèle ELM peut être utilisé comme un contrôleur intelligent capable de prédire instantanément la puissance réactive optimale à injecter, sans nécessiter de recalcul d'optimisation à chaque instant. Cela ouvre la voie à une stratégie de contrôle rapide et efficace pour l'intégration des systèmes photovoltaïques dans les réseaux électriques intelligents.

Ces résultats ne sont donc pas anormaux dans ce cas d'étude. Ils s'expliquent par le fait que le dataset provient de :

— simulations PowerFactory ;
— une fonction coût déterministe ;
— une optimisation numérique bien définie.

La relation étudiée est donc mathématiquement déterministe :

$$Q_{opt} = f(X) \tag{3.46}$$

et le modèle ELM apprend simplement cette fonction.

3.6 Intégration du contrôleur ELM dans PowerFactory

Une fois le modèle *Extreme Learning Machine* entraîné, celui-ci peut être utilisé comme un estimateur direct de la puissance réactive optimale à injecter dans le réseau. Contrairement aux méthodes classiques d'optimisation, qui nécessitent un calcul itératif de la fonction coût, le modèle ELM permet d'obtenir quasi instantanément la valeur optimale de puissance réactive à partir des variables de fonctionnement du réseau.

Dans cette approche, les variables caractéristiques du réseau électrique sont utilisées comme entrées du modèle d'apprentissage. Ces variables comprennent la puissance active photovoltaïque, la puissance active et réactive de la charge, la tension au point de couplage commun (PCC), le taux de chargement de la ligne ainsi que les pertes actives du réseau.

Après l'exécution du calcul de flux de puissance dans PowerFactory, ces grandeurs sont extraites et introduites dans le modèle ELM entraîné. Le modèle calcule alors directement la puissance réactive optimale selon la relation :

$$Q_{opt} = f(P_{pv}, P_{load}, Q_{load}, V_{PCC}, Loading, P_{loss}) \tag{3.47}$$

La valeur obtenue constitue ensuite la consigne de puissance réactive des onduleurs photovoltaïques. Dans le cas de la centrale étudiée, composée de deux sous-champs photovoltaïques identiques, la puissance réactive optimale totale est répartie équitablement entre les deux onduleurs :

$$Q_1 = Q_2 = \frac{Q_{opt}}{2} \tag{3.48}$$

Cette stratégie permet ainsi de transformer le modèle d'apprentissage automatique en un contrôleur intelligent capable d'optimiser en temps réel l'injection de puissance réactive, améliorant la tenue de tension, la réduction des pertes et la gestion des flux de puissance dans le réseau électrique.

Avant l'intégration du modèle ELM, le système fonctionnait sur la base d'une optimisation classique réalisée par balayage des valeurs candidates de puissance réactive. Bien que cette méthode permette de déterminer une solution optimale, elle reste relativement lente en raison du caractère itératif des calculs de flux de puissance et de l'évaluation répétée de la fonction coût. L'utilisation du modèle ELM permet donc de remplacer cette procédure d'optimisation lente par une prédiction directe, rapide et adaptée à une implémentation temps réel.

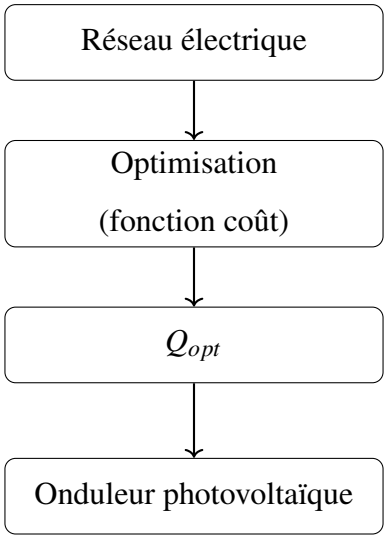

FIGURE 3.6. Principe du contrôle classique basé sur l'optimisation de la puissance réactive

Pour le cas avec ELM, ce dernier agit comme un contrôleur intelligent temps réel. Il applique la valeur obtenue comme consigne de puissance réactive des onduleurs photovoltaïques.

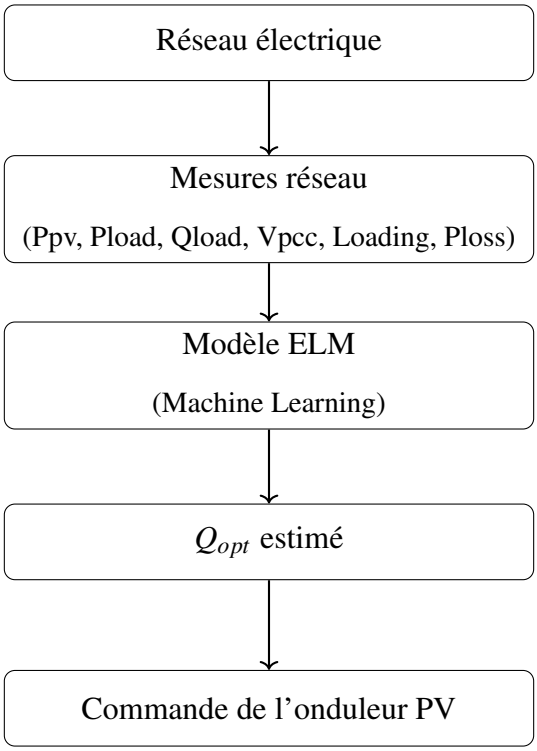

FIGURE 3.7. Principe du contrôleur basé sur le modèle Extreme Learning Machine pour l'estimation de la puissance réactive optimale.

Conclusion du chapitre

Ce chapitre a été consacré au développement d'une approche d'optimisation de la puissance réactive basée sur les techniques d'apprentissage automatique, en particulier le modèle *Extreme Learning Machine* (ELM). L'objectif principal était de mettre en place un modèle intelligent capable de déterminer rapidement la puissance réactive optimale à injecter par la centrale photovoltaïque afin d'améliorer les performances du réseau électrique étudié.

Dans un premier temps, les fondements théoriques du *Machine Learning* ont été présentés, en mettant en évidence l'intérêt des approches basées sur les données pour la modélisation et l'optimisation des systèmes électriques modernes. Le principe de fonctionnement du modèle *Extreme Learning Machine* a ensuite été détaillé, en soulignant ses avantages en termes de simplicité d'architecture, de rapidité d'apprentissage et de capacité de généralisation.

Une formulation mathématique du problème d'optimisation de la puissance réactive a été proposée en s'appuyant sur une fonction coût multicritère inspirée des approches classiques d'*Optimal Reactive Power Dispatch* (ORPD). Cette fonction objectif permet de prendre simultanément en compte plusieurs aspects importants du fonctionnement du réseau, notamment le

maintien du profil de tension, la limitation du chargement des lignes, la réduction des pertes actives et la maîtrise de l'effort de compensation réactive.

Afin d'entraîner le modèle d'apprentissage, un jeu de données représentatif a été généré à partir de simulations réalisées dans l'environnement DIgSILENT PowerFactory. Ces simulations ont permis de reproduire différentes conditions d'exploitation du réseau en faisant varier les niveaux de charge, la production photovoltaïque et la tension du réseau amont. Au total, 5280 états de fonctionnement du réseau ont été générés et enregistrés dans un *dataset*, constituant ainsi la base de l'apprentissage du modèle ELM.

Le modèle a ensuite été entraîné et validé à l'aide d'outils de calcul scientifique sous Python (*Jupyter Notebook*). Les résultats obtenus montrent une excellente capacité du modèle à reproduire la relation non linéaire entre les variables du réseau et la puissance réactive optimale. Les indicateurs de performance obtenus, notamment le coefficient de détermination R^2 proche de l'unité et les erreurs de prédiction très faibles, confirment la pertinence de l'approche proposée.

Enfin, l'intégration du modèle ELM dans l'environnement de simulation a été présentée afin de transformer le modèle d'apprentissage en contrôleur intelligent de puissance réactive. Une fois entraîné, le modèle peut être utilisé pour estimer instantanément la puissance réactive optimale à partir des variables de fonctionnement du réseau, ce qui permet d'éviter les calculs d'optimisation itératifs généralement coûteux en temps de calcul.

Ainsi, l'approche proposée permet de combiner les techniques d'optimisation des réseaux électriques avec les méthodes modernes d'apprentissage automatique afin de développer une stratégie de contrôle rapide et efficace pour les réseaux électriques intégrant des sources d'énergie renouvelables.

Le chapitre suivant sera consacré à la validation et à l'analyse des performances du contrôleur proposé, à travers des analyses statiques, quasi-dynamiques et dynamiques permettant de comparer le fonctionnement du réseau avec et sans l'utilisation du modèle ELM.

Chapitre 4

Validation et Analyse des Performances

4.1 Analyse statique comparative

Hypothèse : Dans l'ensemble des analyses présentées dans ce chapitre, on considère le cas d'un fonctionnement normal du système photovoltaïque raccordé au réseau. Autrement dit, les facteurs d'échelle (*scaling factors*) des deux onduleurs photovoltaïques sont fixés à 1.0.

L'analyse statique constitue une étape essentielle pour évaluer l'impact de la stratégie de contrôle proposée sur le fonctionnement du réseau électrique étudié. Cette analyse repose sur des calculs de flux de puissance (*Load Flow*) réalisés dans l'environnement de simulation DIgSILENT PowerFactory afin d'observer le comportement du réseau dans différentes configurations de contrôle de la puissance réactive de la centrale photovoltaïque.

L'objectif de cette étude est de comparer les performances du réseau pour plusieurs stratégies de gestion de la puissance réactive, afin de mettre en évidence l'apport du contrôleur intelligent basé sur le modèle *Extreme Learning Machine* (ELM).

Dans cette analyse, trois modes de fonctionnement du système ont été considérés.

Le premier cas correspond au fonctionnement du réseau sans optimisation de la puissance réactive. Dans cette configuration, les onduleurs photovoltaïques fonctionnent avec un facteur de puissance unitaire, ce qui signifie que la centrale photovoltaïque n'injecte ni n'absorbe de puissance réactive. La puissance réactive échangée avec le réseau est alors uniquement fournie par les charges et les éléments du réseau.

Le deuxième cas correspond à une stratégie de contrôle classique de la puissance réactive. Dans cette approche, la puissance réactive injectée par la centrale photovoltaïque est déterminée à l'aide d'une loi de contrôle locale telle que la loi $Q(V)$ ou $Q(P)$, couramment utilisée dans les réseaux de distribution intégrant des sources d'énergie renouvelables. Ce type de stratégie permet de contribuer à la régulation de la tension locale mais ne garantit pas nécessairement une

optimisation globale du fonctionnement du réseau.

Le troisième cas correspond à l'approche proposée dans ce travail, dans laquelle la puissance réactive injectée par la centrale photovoltaïque est déterminée à l'aide du modèle d'apprentissage automatique *Extreme Learning Machine*. Dans cette configuration, les variables caractérisant l'état du réseau électrique, notamment la puissance photovoltaïque, la charge, la tension au point de couplage commun, le taux de chargement des lignes et les pertes du réseau, sont introduites dans le modèle ELM entraîné. Celui-ci fournit instantanément la valeur optimale de puissance réactive à injecter afin d'améliorer les performances globales du réseau.

Pour chacune de ces configurations, plusieurs indicateurs de performance du réseau ont été analysés à partir des résultats des calculs de flux de puissance. Les principaux indicateurs étudiés sont :

— La tension au point de couplage commun (PCC) ;
— Les pertes actives totales du réseau ;
— Le taux de chargement de la ligne critique.

La comparaison de ces indicateurs permet d'évaluer l'efficacité du contrôleur basé sur l'*Extreme Learning Machine* dans l'amélioration du fonctionnement du réseau électrique.

4.1.1 Cas 1 : Fonctionnement sans contrôle optimal de la puissance réactive

Dans cette première configuration, les onduleurs photovoltaïques fonctionnent à facteur de puissance unitaire ($\cos\varphi = 1$), ce qui revient à imposer une puissance réactive nulle ($Q = 0$). Ce cas constitue la situation de référence pour l'analyse comparative.

À l'instant retenu pour l'étude statique, correspondant à 12 h, les résultats du calcul de flux de puissance montrent que la centrale photovoltaïque injecte une puissance active totale de 4.3893 MW, tandis que la charge absorbe 4.9458 MW de puissance active et 1.6256 MVAr de puissance réactive.

La tension au point de couplage commun est de 0.99285 p.u, ce qui reste dans une plage de fonctionnement acceptable, bien qu'inférieure à la valeur nominale. Le taux de chargement de la ligne critique est de 32%, ce qui traduit un niveau de sollicitation modéré du réseau. Les pertes actives totales du réseau s'élèvent à 0.24 MW.

Ces résultats montrent que l'injection photovoltaïque contribue déjà à améliorer le fonctionnement du réseau en réduisant le transit de puissance depuis l'amont. Cependant, l'absence de compensation réactive ne permet pas d'optimiser pleinement le profil de tension ni de minimiser davantage les pertes électriques. Ce cas servira donc de référence pour la comparaison avec les stratégies de contrôle classique et intelligent.

TABLE 4.1. Comparaison des performances du réseau selon la stratégie de contrôle de la puissance réactive

Méthode	V_{PCC} **(p.u)**	**Loading (%)**	**Pertes (MW)**
Sans contrôle ($Q = 0$)	0.99285	32	0.24
Contrôleur classique $Q(P)$	–	–	–
ELM	–	–	–

4.1.2 Cas 2 : Contrôle classique basé sur la loi $Q(P)$

Dans cette configuration, la centrale photovoltaïque fonctionne selon une loi de commande de type $Q(P)$. Toutefois, pour l'instant de simulation retenu, les résultats obtenus sont identiques à ceux du cas de référence sans contrôle réactif.

Cette situation s'explique par le fait que la caractéristique $Q(P)$ utilisée dans le modèle impose une puissance réactive nulle ou négligeable pour le niveau de puissance active correspondant à cet état de fonctionnement.

Ainsi, dans ce cas particulier, la stratégie de contrôle classique $Q(P)$ n'apporte pas d'amélioration supplémentaire par rapport à un fonctionnement à facteur de puissance unitaire.

Cette observation met en évidence l'une des limites des lois de commande classiques fixes, qui ne permettent pas toujours d'exploiter pleinement les capacités de compensation réactive des onduleurs photovoltaïques. En effet, ces stratégies reposent généralement sur des règles prédéfinies dépendant uniquement de la puissance active ou de la tension locale, sans tenir compte de l'état global du réseau.

Par conséquent, une approche plus avancée capable d'intégrer plusieurs variables du réseau et de déterminer dynamiquement la puissance réactive optimale peut permettre d'améliorer significativement les performances du système électrique. C'est précisément l'objectif de la stratégie de contrôle intelligent basée sur le modèle d'apprentissage automatique *Extreme Learning Machine*, étudiée dans le cas suivant.

TABLE 4.2. Comparaison des performances du réseau pour différentes stratégies de contrôle

Méthode	V_{PCC} **(p.u)**	**Loading (%)**	**Pertes (MW)**
Sans contrôle ($Q = 0$)	0.99285	32	0.24
Contrôleur classique $Q(P)$	0.99285	32	0.24
ELM	–	–	–

4.1.3 Cas 3 : Contrôle basé sur le modèle ELM

Le troisième cas correspond à l'utilisation du contrôleur intelligent basé sur le modèle *Extreme Learning Machine* (ELM). Les résultats obtenus montrent une amélioration du fonctionnement du réseau par rapport aux deux configurations précédentes.

Les principaux résultats observés sont les suivants :

— La tension au point de couplage commun passe de 0.99285 p.u. à 0.99333 p.u. ;

— Le taux de chargement de la ligne critique diminue de 32% à 30% ;

— Les pertes actives restent proches de 0.24 MW à l'arrondi affiché.

L'injection de puissance réactive calculée par le modèle ELM permet ainsi d'améliorer légèrement le profil de tension et de réduire le transit de puissance dans la ligne critique. Même si la réduction des pertes n'apparaît pas clairement à deux décimales dans l'affichage, cela ne signifie pas qu'il n'existe aucun effet ; l'amélioration peut simplement être trop faible pour être visible avec cet arrondi. En revanche, l'effet sur la tension et sur le chargement de la ligne est déjà observable.

Le fait que le Cas 2 présente des résultats identiques au Cas 1 confirme que, pour l'instant de fonctionnement étudié, la loi classique $Q(P)$ ne fournit pas de compensation réactive utile. À l'inverse, le contrôleur ELM exploite plusieurs variables caractérisant l'état réel du réseau afin de déterminer une consigne réactive plus adaptée au fonctionnement du système.

4.1.4 Résultats de l'analyse statique comparative

L'analyse statique comparative a été réalisée à $12\,h$, instant correspondant à une forte production photovoltaïque. Trois configurations de fonctionnement ont été étudiées : le fonctionnement sans contrôle réactif, le contrôle classique basé sur une loi $Q(P)$ et le contrôle intelligent proposé basé sur le modèle ELM.

Dans le cas sans contrôle réactif, la tension au point de couplage commun est de 0.99285 p.u., le taux de chargement de la ligne critique atteint 32% et les pertes actives totales du réseau s'élèvent à 0.24336 MW.

Lorsque le contrôle classique $Q(P)$ est appliqué, les résultats obtenus restent identiques à ceux du cas sans contrôle. Cela indique que, pour l'état de fonctionnement considéré, la caractéristique $Q(P)$ utilisée ne fournit pas de compensation réactive significative et ne permet donc pas d'amélioration mesurable des performances du réseau.

En revanche, lorsque la puissance réactive est déterminée par le modèle ELM, une amélioration du comportement du réseau est observée. La tension au PCC augmente à 0.99333 p.u., le chargement de la ligne critique diminue à 30%, et les pertes actives totales sont réduites à

0.24231 MW. Le contrôleur ELM permet ainsi une réduction des pertes d'environ 1.05 kW, soit environ 0.43% par rapport au fonctionnement sans optimisation.

Ces résultats montrent que le contrôleur basé sur l'*Extreme Learning Machine* adapte la puissance réactive de manière plus efficace que la stratégie classique étudiée. Même si l'amélioration reste modérée dans ce cas statique, elle confirme l'intérêt du modèle ELM pour l'optimisation du profil de tension, la réduction du transit dans la ligne critique et l'amélioration globale du fonctionnement du réseau électrique.

TABLE 4.3. Comparaison des performances du réseau pour différentes stratégies de contrôle de la puissance réactive

Méthode	V_{PCC} **(p.u)**	**Loading (%)**	**Pertes (MW)**
Sans contrôle ($Q = 0$)	0.99285	32	0.24
Contrôleur classique $Q(P)$	0.99285	32	0.24336
ELM	0.99333	30	0.24231

4.1.5 Conclusion de l'analyse statique

Pour conclure, l'analyse statique comparative montre que la stratégie de contrôle basée sur le modèle ELM offre de meilleures performances que les modes de fonctionnement sans compensation réactive ou basés sur une loi $Q(P)$ fixe. Cette première validation confirme la pertinence de l'approche proposée et justifie son évaluation dans un cadre temporel plus réaliste à travers l'analyse quasi-dynamique.

4.2 Analyse quasi-dynamique comparative

Dans cette partie, l'objectif est d'exploiter les courbes sur 24 heures afin de montrer que l'intérêt du contrôleur basé sur le modèle ELM devient encore plus visible sur l'ensemble de la journée.

L'analyse vise à observer le comportement du réseau électrique pendant toute la journée (24 h) et à comparer trois configurations de fonctionnement :

— Cas 1 : fonctionnement sans contrôle réactif ($Q = 0$) ;

— Cas 2 : contrôle classique basé sur la loi $Q(P)$;

— Cas 3 : contrôle intelligent basé sur le modèle ELM.

Contrairement à l'analyse statique présentée dans la section précédente, qui portait sur un seul instant de fonctionnement, l'analyse quasi-dynamique permet ici d'observer l'évolution des

grandeurs électriques du réseau dans le temps.

4.2.1 Méthodologie d'évaluation des stratégies de contrôle

Afin d'évaluer l'impact des différentes stratégies de contrôle de la puissance réactive sur le fonctionnement du réseau électrique étudié, une analyse quasi-dynamique sur une période de 24 heures a été réalisée à l'aide du logiciel DIgSILENT PowerFactory.

Cette méthode consiste à effectuer une succession de calculs de flux de puissance à différents instants de la journée, en tenant compte de la variation temporelle de la production photovoltaïque et de la demande électrique.

Les simulations ont été réalisées en utilisant un profil journalier de charge appliqué à la charge Campus 1, ainsi qu'un profil standard d'irradiation solaire permettant de représenter la variation de la puissance produite par la centrale photovoltaïque au cours de la journée. Cette approche permet de reproduire des conditions de fonctionnement proches de la réalité et d'analyser le comportement du réseau face aux fluctuations naturelles de la production photovoltaïque et de la consommation électrique.

Dans cette étude, trois configurations de fonctionnement du système ont été considérées afin de comparer les performances du réseau électrique.

4.2.2 Cas 1 : Fonctionnement sans contrôle de la puissance réactive

Dans le premier scénario, la centrale photovoltaïque fonctionne sans stratégie particulière de régulation de la puissance réactive. Les onduleurs photovoltaïques sont configurés avec un facteur de puissance unitaire, ce qui correspond à une puissance réactive injectée nulle :

$$Q = 0$$

Dans DIgSILENT PowerFactory, cette configuration est obtenue en définissant le mode de commande locale de l'onduleur en *Const. Q*, avec une valeur de puissance réactive fixée à zéro.

Ce scénario représente un fonctionnement de référence dans lequel la centrale photovoltaïque injecte uniquement de la puissance active dans le réseau. Les résultats obtenus permettent d'observer l'évolution naturelle des grandeurs électriques du système, notamment :

— la tension au point de couplage commun V_{PCC} ;
— le taux de chargement de la ligne Makala–Campus ;
— les pertes actives totales du réseau.

Ces résultats servent de base de comparaison pour l'évaluation des stratégies de contrôle étudiées dans les scénarios suivants.

4.2.3 Cas 2 : Contrôle classique basé sur la loi $Q(P)$

Dans le deuxième scénario, la centrale photovoltaïque fonctionne avec une stratégie de contrôle classique de la puissance réactive basée sur la loi $Q(P)$. Dans ce mode de fonctionnement, la puissance réactive injectée par l'onduleur est définie comme une fonction de la puissance active produite par la centrale photovoltaïque.

Ce type de stratégie est largement utilisé dans les réseaux de distribution modernes et est généralement imposé par les codes de réseau (*Grid Codes*) afin de contribuer à la régulation de tension et à la stabilité du système électrique.

Dans cette étude, la courbe $Q(P)$ a été définie en considérant que le réseau étudié présente un rapport de court-circuit élevé, indiquant un réseau relativement fort. Dans ce cas, le fonctionnement à facteur de puissance proche de l'unité est généralement recommandé afin d'éviter une injection excessive de puissance réactive. La courbe $Q(P)$ utilisée est donc définie de manière à maintenir une puissance réactive proche de zéro pour l'ensemble de la plage de fonctionnement de la centrale.

La simulation quasi-dynamique réalisée dans ce scénario permet d'observer l'impact de cette stratégie de contrôle sur les principales grandeurs du réseau, notamment la tension au PCC, les pertes électriques et le niveau de chargement des lignes.

4.2.4 Cas 3 : Détermination de la puissance réactive optimale à l'aide du modèle ELM

Dans un réseau électrique intégrant des sources d'énergie renouvelables telles que les centrales photovoltaïques, l'état du système varie continuellement au cours du temps en raison des fluctuations de la production solaire et de la demande électrique. Par conséquent, la puissance réactive optimale à injecter dans le réseau n'est pas constante mais dépend de l'état instantané du système électrique.

Afin de prendre en compte cette variabilité temporelle, une analyse quasi-dynamique sur une période de 24 heures est réalisée.

La simulation quasi-dynamique consiste à effectuer une succession de calculs de flux de puissance à différents instants de la journée, généralement à intervalles horaires. À chaque instant t, le réseau est caractérisé par un ensemble de variables décrivant son état de fonctionnement, notamment :

— la puissance photovoltaïque injectée $P_{pv}(t)$;

— la puissance active de la charge $P_{load}(t)$;

— la puissance réactive de la charge $Q_{load}(t)$;

— la tension au point de couplage commun $V_{PCC}(t)$;

— le taux de chargement de la ligne critique $Loading(t)$;

— les pertes actives totales du réseau $P_{loss}(t)$.

Ces grandeurs constituent les variables d'entrée du modèle *Extreme Learning Machine* préalablement entraîné.

Le modèle ELM établit une relation non linéaire entre ces variables d'entrée et la puissance réactive optimale à injecter par la centrale photovoltaïque. Ainsi, pour chaque instant de la journée, la puissance réactive optimale est déterminée selon la relation :

$$Q_{opt}(t) = f(P_{pv}, P_{load}, Q_{load}, V_{PCC}, Loading, P_{loss}) \tag{4.1}$$

L'application du modèle ELM aux données horaires du réseau permet ainsi d'obtenir une série temporelle de valeurs optimales de puissance réactive sur l'ensemble de la journée.

Dans le cas de la centrale photovoltaïque étudiée, composée de deux sous-champs photovoltaïques identiques, la puissance réactive optimale totale est répartie équitablement entre les deux onduleurs :

$$Q_1(t) = Q_2(t) = \frac{Q_{opt}(t)}{2} \tag{4.2}$$

Les valeurs obtenues sont ensuite utilisées pour construire une caractéristique temporelle de la puissance réactive sur 24 heures. Cette caractéristique est associée à la commande de puissance réactive des onduleurs photovoltaïques dans l'environnement de simulation DIgSILENT PowerFactory en mode *Const. Q*.

Une nouvelle simulation quasi-dynamique est alors réalisée afin d'évaluer l'impact du contrôleur basé sur le modèle ELM sur le comportement global du réseau électrique.

Cette approche permet de reproduire le fonctionnement d'un contrôleur intelligent de puissance réactive capable d'adapter dynamiquement la compensation réactive en fonction de l'état du réseau. Contrairement aux stratégies de contrôle classiques reposant sur des lois fixes telles que $Q(P)$ ou $Q(V)$, le modèle ELM exploite l'ensemble des variables du système pour estimer la puissance réactive optimale.

Cela permet d'améliorer la régulation de tension, de réduire les pertes électriques et de limiter le chargement des lignes dans le réseau étudié.

4.3 Analyse comparative des résultats

Afin d'évaluer l'efficacité de la stratégie de contrôle basée sur le modèle d'apprentissage automatique *Extreme Learning Machine* (ELM), une analyse comparative des résultats obtenus dans les trois scénarios étudiés a été réalisée. Les simulations quasi-dynamiques ont été effectuées sur une période de 24 heures en considérant les profils journaliers de production photovoltaïque et de charge appliqués au réseau.

Les performances du réseau ont été évaluées à partir de trois indicateurs principaux :

— la tension au point de couplage commun (PCC) ;

— le taux de chargement de la ligne Makala–Campus ;

— les pertes actives totales du réseau.

Ces indicateurs permettent d'évaluer la qualité de l'intégration de la centrale photovoltaïque dans le réseau et l'efficacité des stratégies de contrôle de la puissance réactive.

4.3.1 Évolution de la tension au point de couplage commun

Analyse technique des courbes

Cas 1 : fonctionnement sans contrôle : Dans le premier graphique, la tension au point de couplage commun (V_{PCC}) varie approximativement entre 0.988 p.u et 0.995 p.u au cours de la journée. Cette variation est principalement liée aux fluctuations naturelles de la production photovoltaïque et de la demande électrique.

Pendant les heures de forte production solaire, la tension tend à augmenter légèrement en raison de l'injection de puissance active par la centrale photovoltaïque dans le réseau. En revanche, durant les périodes de faible production photovoltaïque ou de forte demande, la tension diminue légèrement en raison de l'augmentation du transit de puissance depuis le réseau amont.

Bien que les valeurs observées restent dans la plage de fonctionnement acceptable du réseau de distribution, l'absence de compensation réactive limite la capacité du système à maintenir un profil de tension plus stable et plus proche de la valeur nominale.

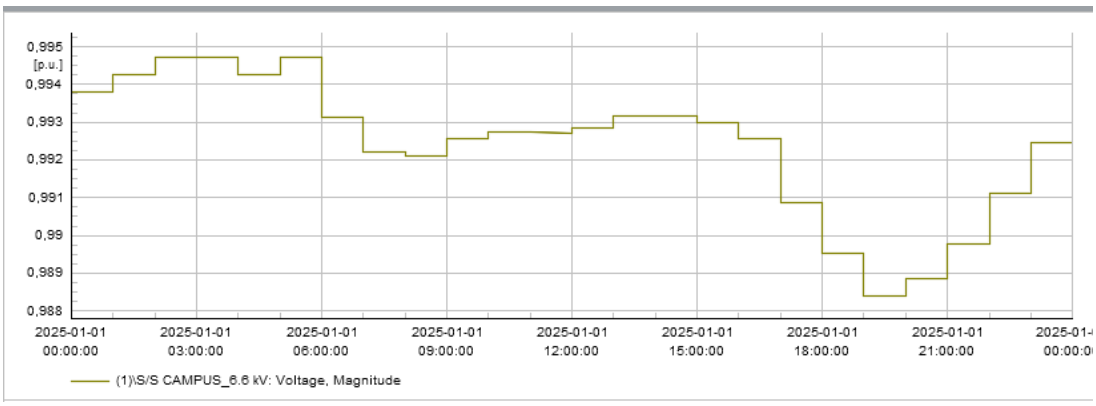

FIGURE 4.1. Évolution de la tension au point de couplage commun (PCC) sur 24 heures dans le cas sans contrôle de la puissance réactive.

Observations importantes : L'analyse de la courbe de tension au point de couplage commun permet de mettre en évidence plusieurs observations importantes :

— La tension est relativement plus élevée pendant la nuit et tôt le matin ;

— Elle diminue progressivement en fin de journée, notamment entre 18 h et 21 h ;

— La valeur minimale de tension est observée autour de 20 h.

Explication physique : Ces variations de tension peuvent s'expliquer par l'évolution simultanée de la production photovoltaïque et de la demande électrique du réseau :

— En soirée, la charge du réseau augmente en raison de l'intensification de la consommation électrique ;

— Dans le même temps, la production photovoltaïque diminue progressivement jusqu'à devenir nulle après le coucher du soleil ;

— Le réseau doit alors fournir davantage de puissance réactive pour alimenter les charges ;

— Cette augmentation de la demande en puissance réactive provoque une baisse de la tension dans le réseau de distribution.

Dans cette configuration, aucune compensation réactive n'est fournie par la centrale photovoltaïque puisque les onduleurs fonctionnent avec un facteur de puissance unitaire. Par conséquent, la régulation de la tension dépend uniquement du réseau amont et des caractéristiques des charges.

Cas 2 : contrôle classique basé sur la loi $Q(P)$: Dans le deuxième graphique correspondant au contrôle classique basé sur la loi $Q(P)$, la courbe de tension observée est presque identique à celle du cas précédent sans contrôle réactif.

Cette situation s'explique par le fait que la caractéristique $Q(P)$ utilisée dans cette étude impose une puissance réactive très faible ou nulle pour les niveaux de puissance active produits

par la centrale photovoltaïque dans les conditions étudiées. Ainsi, la centrale photovoltaïque ne contribue pas de manière significative à la compensation de la puissance réactive du réseau.

Par conséquent, le comportement du réseau reste pratiquement inchangé par rapport au fonctionnement sans contrôle, ce qui met en évidence les limites des stratégies de contrôle classiques basées sur des lois fixes.

Observations importantes : L'analyse de la courbe de tension au point de couplage commun permet de mettre en évidence plusieurs observations importantes :

— La tension est relativement plus élevée pendant la nuit et tôt le matin ;
— Elle diminue progressivement en fin de journée, notamment entre 18 h et 21 h ;
— La valeur minimale de tension est observée autour de 20 h.

Explication physique : Ces variations de tension peuvent s'expliquer par l'évolution simultanée de la production photovoltaïque et de la demande électrique du réseau :

— En soirée, la charge du réseau augmente en raison de l'intensification de la consommation électrique ;
— Dans le même temps, la production photovoltaïque diminue progressivement jusqu'à devenir nulle après le coucher du soleil ;
— Le réseau doit alors fournir davantage de puissance réactive pour alimenter les charges ;
— Cette augmentation de la demande en puissance réactive provoque une baisse de la tension dans le réseau de distribution.

Dans cette configuration, aucune compensation réactive n'est fournie par la centrale photovoltaïque puisque les onduleurs fonctionnent avec un facteur de puissance unitaire. Par conséquent, la régulation de la tension dépend uniquement du réseau amont et des caractéristiques des charges.

Cas 2 : contrôle classique basé sur la loi $Q(P)$: Dans le deuxième graphique correspondant au contrôle classique basé sur la loi $Q(P)$, la courbe de tension observée est presque identique à celle du cas précédent sans contrôle réactif.

Cette situation s'explique par le fait que la caractéristique $Q(P)$ utilisée dans cette étude impose une puissance réactive très faible ou nulle pour les niveaux de puissance active produits par la centrale photovoltaïque dans les conditions étudiées. Ainsi, la centrale photovoltaïque ne contribue pas de manière significative à la compensation de la puissance réactive du réseau.

Par conséquent, le comportement du réseau reste pratiquement inchangé par rapport au fonctionnement sans contrôle, ce qui met en évidence les limites des stratégies de contrôle classiques basées sur des lois fixes.

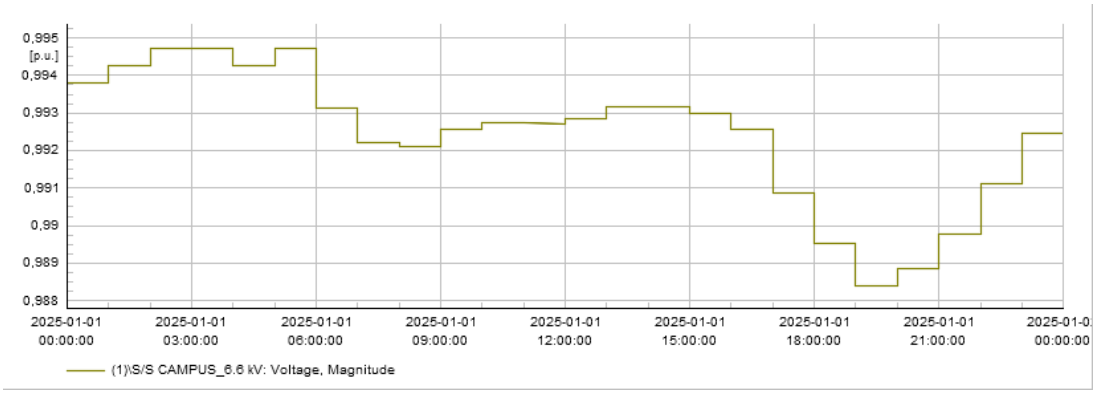

FIGURE 4.2. Évolution de la tension au point de couplage commun (PCC) sur 24 heures avec la stratégie de contrôle classique basée sur la loi $Q(P)$.

Interprétation des résultats du cas 2 : La similitude entre les profils de tension observés dans les cas 1 et 2 s'explique par le fait que la loi de commande $Q(P)$ utilisée dans cette étude produit une puissance réactive très faible, voire quasi nulle :

$$Q \approx 0$$

Par conséquent, la compensation réactive fournie par la centrale photovoltaïque reste négligeable et son effet sur le profil de tension du réseau est très limité.

Conclusion : la stratégie de contrôle basée sur la loi $Q(P)$ ne permet pas de corriger efficacement les variations de tension dans le réseau étudié.

Cas 3 : contrôle basé sur le modèle ELM : Dans le troisième graphique correspondant à l'utilisation du contrôleur intelligent basé sur le modèle *Extreme Learning Machine*, on observe une amélioration du profil de tension.

Les observations principales sont les suivantes :

— La tension au point de couplage commun est légèrement plus élevée sur l'ensemble de la journée ;

— La chute de tension observée en soirée est moins prononcée ;

— Le profil de tension apparaît globalement plus stable.

En particulier, durant la période comprise entre 18 h et 21 h, la tension reste plus élevée et présente des variations moins importantes que dans les deux scénarios précédents.

Cette amélioration s'explique par le fait que le modèle ELM détermine et injecte une puissance réactive optimale :

$$Q_{opt} = f(P_{pv}, P_{load}, Q_{load}, V_{PCC}, Loading, P_{loss}) \tag{4.3}$$

Cette puissance réactive dépend donc directement de l'état du réseau, notamment :

— la tension au point de couplage commun ;

— les pertes actives du réseau ;

— le taux de chargement de la ligne critique ;

— la puissance active et réactive de la charge ;

— la production photovoltaïque.

Ainsi, contrairement aux stratégies de contrôle classiques basées sur des lois fixes, le modèle ELM adapte dynamiquement la puissance réactive injectée en fonction des besoins du réseau. Le contrôleur agit donc précisément aux moments où le système en a le plus besoin, notamment lors des périodes de forte charge ou de faible production photovoltaïque.

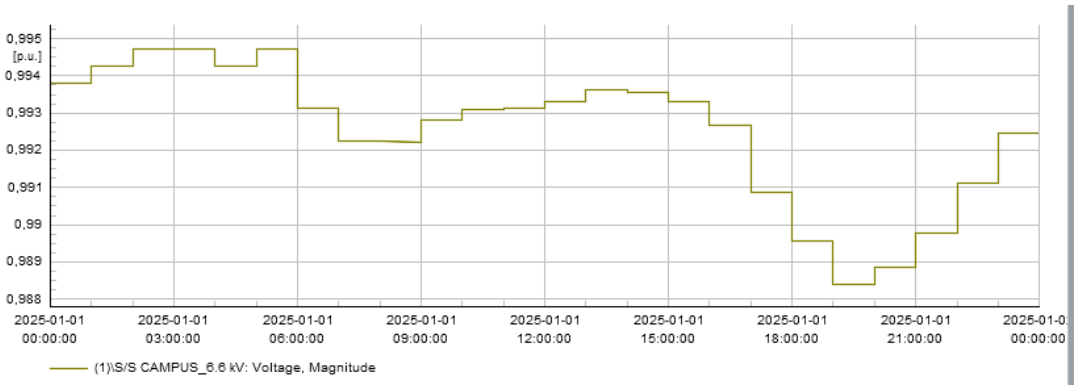

FIGURE 4.3. Évolution de la tension au point de couplage commun (PCC) sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM).

4.3.2 Analyse comparative de l'évolution de la tension au PCC

La figure précédente présente l'évolution de la tension au point de couplage commun (PCC) sur une période de 24 heures pour les trois scénarios étudiés : fonctionnement sans contrôle de la puissance réactive, contrôle classique basé sur la loi $Q(P)$ et contrôle intelligent basé sur le modèle *Extreme Learning Machine* (ELM).

Dans le premier scénario, correspondant au fonctionnement sans stratégie de contrôle de la puissance réactive, la centrale photovoltaïque fonctionne avec un facteur de puissance unitaire, ce qui implique une injection de puissance réactive nulle. Dans ce cas, la tension au PCC dépend uniquement des flux naturels de puissance active et réactive dans le réseau. Les résultats montrent que la tension varie au cours de la journée entre environ 0.988 p.u. et 0.995 p.u.. Une diminution plus marquée de la tension est observée durant la période de forte demande, notamment entre 18 h et 21 h, où la charge du réseau augmente alors que la production photovoltaïque diminue.

Dans le deuxième scénario, utilisant la stratégie classique de contrôle $Q(P)$, la puissance réactive injectée par les onduleurs dépend uniquement de la puissance active produite par la cen-

trale photovoltaïque. Toutefois, les résultats montrent que l'évolution de la tension au PCC reste très proche de celle observée dans le premier scénario. Cela indique que, dans les conditions de fonctionnement étudiées, la caractéristique $Q(P)$ utilisée ne fournit qu'une compensation réactive limitée et n'apporte donc pas d'amélioration significative du profil de tension.

En revanche, dans le troisième scénario basé sur le contrôleur intelligent ELM, la puissance réactive injectée est déterminée à partir de plusieurs variables décrivant l'état global du réseau. Cette approche permet d'adapter dynamiquement la compensation réactive en fonction des conditions de fonctionnement du système électrique. Les résultats obtenus montrent que l'utilisation du contrôleur ELM permet de maintenir la tension du PCC légèrement plus élevée et plus stable, notamment durant les périodes de forte charge du réseau. La chute de tension observée en soirée est ainsi atténuée, ce qui contribue à améliorer la qualité de la tension dans le réseau étudié.

Ces résultats montrent que la stratégie basée sur l'apprentissage automatique permet une meilleure régulation de la tension par rapport aux méthodes de contrôle classiques, grâce à sa capacité à prendre en compte simultanément plusieurs paramètres du système électrique.

4.3.3 Analyse technique des courbes de *Line Loading*

Les figures suivantes représentent l'évolution du taux de chargement de la ligne Makala–Campus (3.6 km) sur une période de 24 heures pour les trois scénarios étudiés.

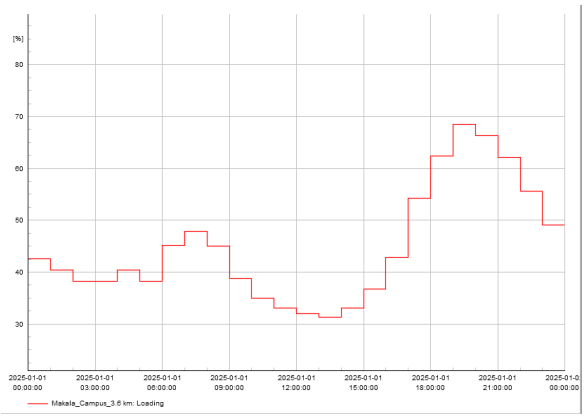

(a) Évolution du chargement de la ligne Makala–Campus sur 24 h sans contrôle de la puissance réactive.

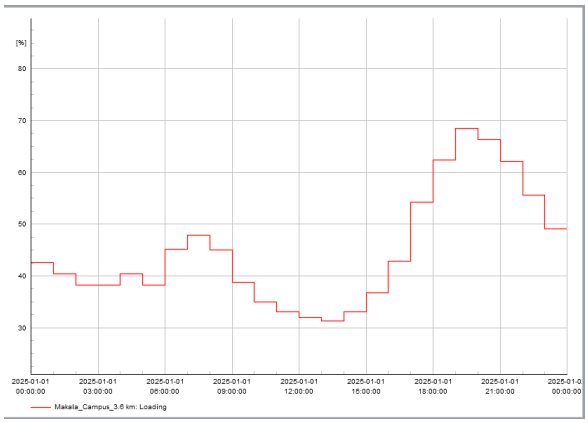

(b) Évolution du chargement de la ligne Makala–Campus sur 24 h avec contrôle classique basé sur la loi $Q(P)$.

FIGURE 4.4. Comparaison de l'évolution du taux de chargement de la ligne Makala–Campus pour les scénarios sans contrôle et avec contrôle classique $Q(P)$.

Les figures 4.4a et 4.4b présentent l'évolution du taux de chargement de la ligne Makala–

Campus sur une période de 24 heures pour les deux premiers scénarios étudiés.

On observe que les profils de chargement obtenus dans les deux cas sont pratiquement identiques. Cela s'explique par le fait que la stratégie de contrôle classique basée sur la loi $Q(P)$ n'introduit qu'une compensation réactive très limitée dans les conditions de fonctionnement considérées. Par conséquent, le transit de puissance dans la ligne reste pratiquement inchangé par rapport au fonctionnement sans contrôle de la puissance réactive.

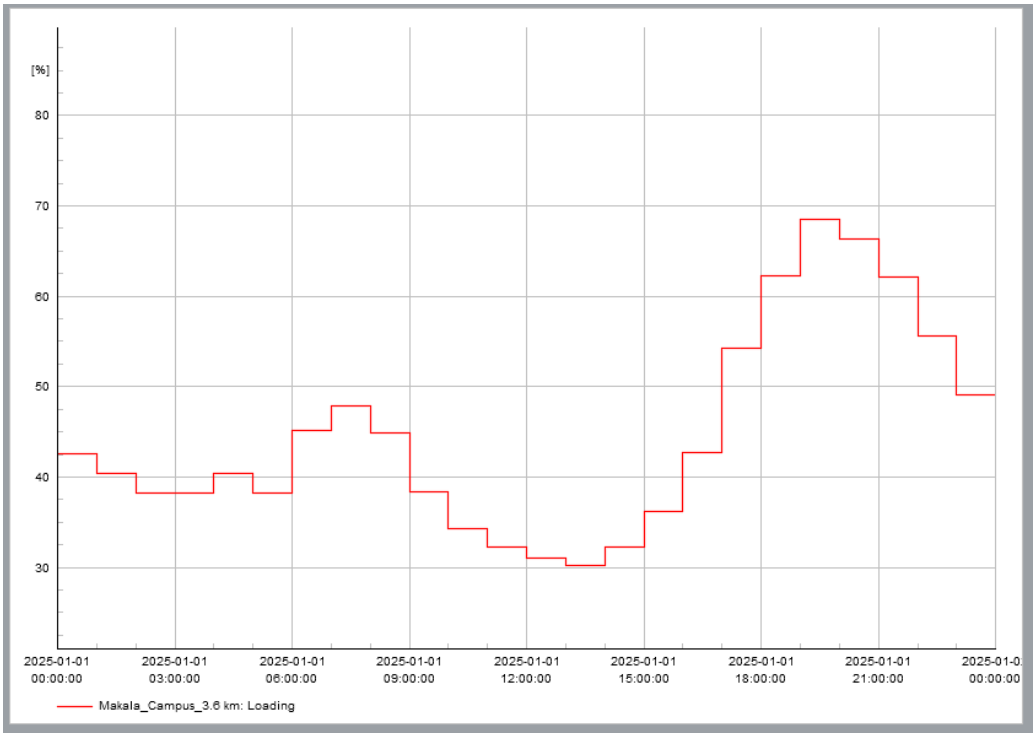

FIGURE 4.5. Évolution du taux de chargement de la ligne Makala–Campus sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM).

La figure 4.5 présente l'évolution du taux de chargement de la ligne Makala–Campus sur une période de 24 heures lorsque la stratégie de contrôle basée sur le modèle Extreme Learning Machine est utilisée.

On observe que le profil de chargement de la ligne est globalement réduit par rapport aux deux scénarios précédents. En particulier, durant les périodes de forte demande, notamment en soirée, le niveau maximal de chargement de la ligne est légèrement inférieur.

Cette amélioration s'explique par le fait que le contrôleur ELM ajuste dynamiquement la puissance réactive injectée par la centrale photovoltaïque en fonction de l'état du réseau. En réduisant le transit de puissance réactive dans la ligne, le modèle contribue à diminuer le flux total de puissance circulant dans le réseau de distribution.

Ainsi, le contrôleur basé sur le modèle ELM permet d'améliorer l'exploitation du réseau électrique en réduisant la sollicitation de la ligne critique et en contribuant à une meilleure gestion

des flux de puissance.

4.3.4 Analyse comparative du chargement de la ligne

La figure 4.4 présente l'évolution du taux de chargement de la ligne Makala–Campus sur une période de 24 heures pour les trois scénarios étudiés.

Dans le premier scénario, correspondant à l'absence de contrôle de la puissance réactive, le chargement de la ligne dépend uniquement des flux naturels de puissance active et réactive dans le réseau. Les résultats montrent que le taux de chargement varie approximativement entre 31% et 68% au cours de la journée. Les valeurs les plus élevées sont observées en soirée, notamment entre 18 h et 21 h, période correspondant à une forte demande de charge alors que la production photovoltaïque diminue progressivement.

Dans le deuxième scénario, utilisant la stratégie classique de contrôle $Q(P)$, le profil du chargement de la ligne reste très proche de celui observé dans le premier scénario. Cette observation indique que la stratégie $Q(P)$ appliquée dans ce réseau n'apporte pas de modification significative de la répartition des flux de puissance dans la ligne étudiée.

En revanche, dans le troisième scénario utilisant le contrôleur intelligent basé sur le modèle *Extreme Learning Machine* (ELM), une légère amélioration du profil de chargement de la ligne est observée. En adaptant dynamiquement la puissance réactive injectée par la centrale photovoltaïque en fonction de l'état global du réseau, le modèle ELM contribue à une meilleure répartition des flux de puissance dans le réseau. Cette optimisation permet de réduire légèrement le courant circulant dans la ligne et donc de diminuer le taux de chargement dans certaines périodes de la journée.

Ces résultats montrent que la stratégie de contrôle basée sur l'apprentissage automatique permet d'améliorer l'exploitation du réseau électrique en limitant le chargement des lignes critiques et en augmentant ainsi la marge de sécurité du système.

4.3.5 Évolution des pertes actives du réseau

Les figures suivantes représentent l'évolution des pertes actives du réseau Kinshasa 30 kV sur une période de 24 heures pour les trois scénarios étudiés :

— Cas 1 : fonctionnement sans contrôle de la puissance réactive ;

— Cas 2 : contrôle classique basé sur la loi $Q(P)$;

— Cas 3 : contrôle intelligent basé sur le modèle ELM.

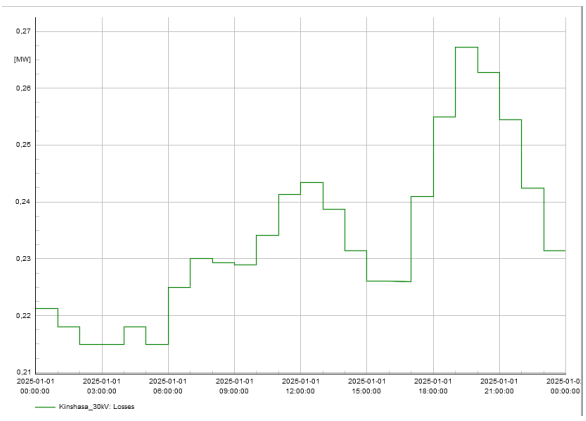

FIGURE 4.6. Évolution des pertes actives du réseau sur 24 h sans contrôle de la puissance réactive.

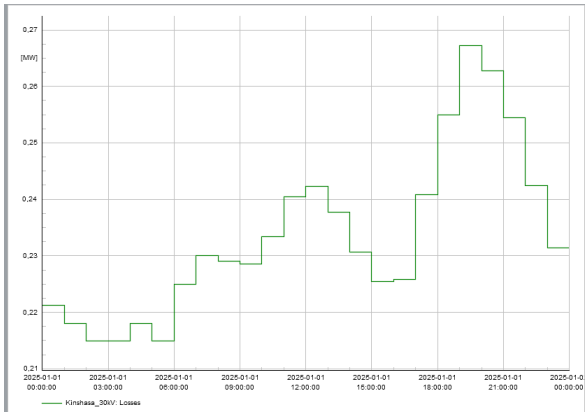

FIGURE 4.7. Évolution des pertes actives du réseau sur 24 h avec contrôle classique Q(P).

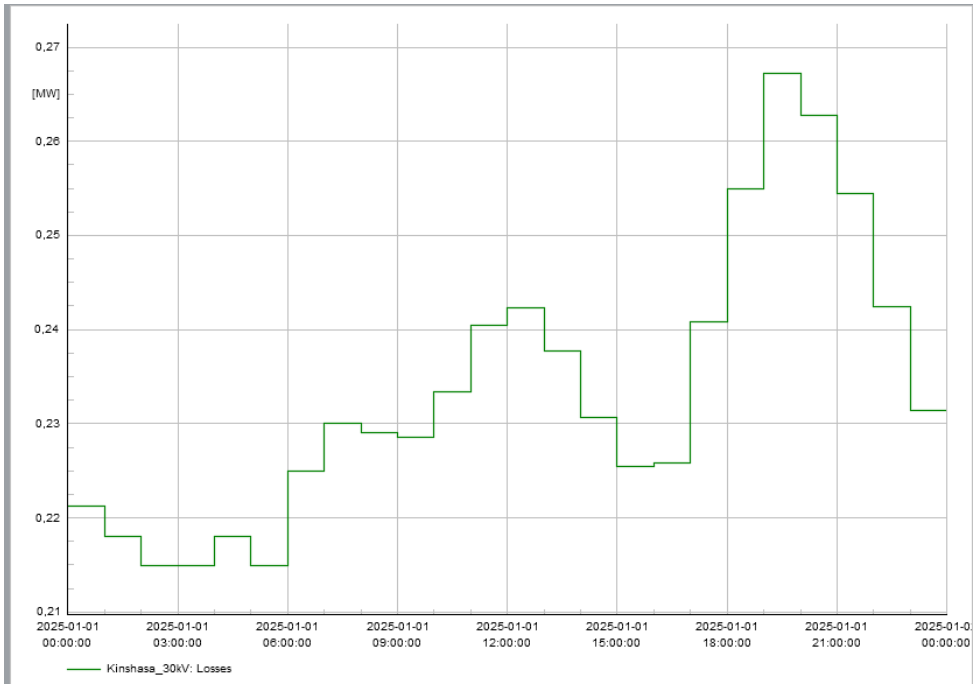

FIGURE 4.8. Évolution des pertes actives du réseau Kinshasa 30 kV sur 24 heures avec le contrôleur basé sur le modèle Extreme Learning Machine (ELM).

4.3.6 Analyse comparative des pertes actives

Dans le premier scénario, correspondant à l'absence de stratégie de compensation réactive, les pertes actives varient approximativement entre 0.215 MW et 0.267 MW au cours de la journée. Les pertes les plus élevées sont observées durant les périodes de forte demande électrique, notamment en soirée, lorsque les flux de puissance dans le réseau augmentent.

Dans le deuxième scénario utilisant la stratégie classique de contrôle $Q(P)$, l'évolution des

pertes reste très similaire à celle observée dans le premier scénario. Cela indique que la stratégie $Q(P)$ appliquée dans ce réseau n'apporte pas d'amélioration significative en termes de réduction des pertes électriques.

En revanche, dans le troisième scénario utilisant le contrôleur intelligent basé sur le modèle *Extreme Learning Machine* (ELM), une légère diminution des pertes actives est observée. En optimisant dynamiquement la puissance réactive injectée par la centrale photovoltaïque, le modèle ELM permet d'améliorer la circulation des flux de puissance dans le réseau et de réduire le courant circulant dans les lignes.

Les résultats obtenus montrent qu'avec le contrôleur ELM, les pertes actives peuvent être réduites d'environ 1.05 kW, soit 0.43 % par rapport au fonctionnement sans optimisation. Cette réduction, bien que modeste à l'échelle d'un instant de fonctionnement, devient significative lorsqu'elle est considérée sur de longues périodes d'exploitation du réseau.

Ces résultats montrent que l'utilisation d'une stratégie de contrôle basée sur l'apprentissage automatique peut contribuer à améliorer l'efficacité énergétique du réseau électrique.

4.4 Impact global sur les performances du réseau

L'analyse comparative des trois scénarios étudiés permet d'évaluer l'impact global des différentes stratégies de contrôle de la puissance réactive sur le fonctionnement du réseau de distribution étudié. Les performances du réseau ont été analysées en considérant trois indicateurs principaux :

— La tension au point de couplage commun (PCC),
— Le taux de chargement de la ligne Makala–Campus,
— Les pertes actives du réseau.

Les résultats obtenus pour les trois stratégies étudiées sont résumés dans le tableau suivant.

Indicateur	Cas 1 : Sans contrôle	Cas 2 Q(P)	Cas 3 : ELM
Tension Pcc	Variation plus importante	Comportement similare	Tension plus stable
Chargement ligne	Jusqu'à ≈ 68 %	Similaire au cas 1	Légère réduction
Pertes réseau	≈243 MW	Similaire	≈242 MW

FIGURE 4.9. Comparaison des performances du réseau pour les trois stratégies de contrôle de la puissance réactive.

Réduction des pertes avec le contrôleur ELM

La réduction des pertes obtenue grâce au contrôleur ELM est estimée à :

$$\Delta P_{loss} = 1.05\,\text{kW}$$

soit environ :

$$0.43\%$$

4.4.1 Analyse globale des résultats

L'étude réalisée montre que les différentes stratégies de contrôle de la puissance réactive ont un impact direct sur le comportement global du réseau électrique.

Dans le premier scénario, correspondant à l'absence de contrôle de la puissance réactive, la centrale photovoltaïque injecte uniquement de la puissance active dans le réseau. Dans ces conditions, la tension au PCC dépend exclusivement des flux naturels de puissance dans le réseau. Les variations de charge et de production photovoltaïque entraînent alors des fluctuations de tension et une augmentation du chargement des lignes durant certaines périodes de la journée.

Dans le deuxième scénario, la stratégie classique de contrôle $Q(P)$ permet d'introduire une relation entre la puissance active produite et la puissance réactive injectée. Cependant, les résultats montrent que cette stratégie n'apporte qu'une amélioration limitée dans le réseau étudié. Les profils de tension, de chargement des lignes et de pertes restent très proches de ceux observés dans le scénario sans contrôle.

En revanche, dans le troisième scénario, l'utilisation du contrôleur intelligent basé sur le modèle *Extreme Learning Machine* (ELM) permet d'améliorer le fonctionnement global du réseau. En prenant en compte simultanément plusieurs variables du système électrique, le modèle ELM est capable d'estimer la puissance réactive optimale à injecter par la centrale photovoltaïque à chaque instant.

Cette optimisation permet :

— d'améliorer la régulation de la tension au PCC,
— de réduire légèrement le chargement de la ligne critique,
— de diminuer les pertes actives dans le réseau.

La réduction des pertes observée dans les simulations atteint environ 1.05 kW, soit 0.43% par rapport au fonctionnement sans optimisation. Bien que cette amélioration puisse paraître modeste à l'échelle instantanée, elle devient significative sur de longues périodes d'exploitation du réseau.

Ainsi, l'intégration d'un contrôleur basé sur l'apprentissage automatique constitue une solution prometteuse pour améliorer l'efficacité et la flexibilité des réseaux de distribution intégrant des sources d'énergie renouvelables.

4.5 Discussion des résultats

Les résultats obtenus dans cette étude montrent que la stratégie de contrôle basée sur le modèle d'apprentissage automatique *Extreme Learning Machine* (ELM) permet d'améliorer le fonctionnement global du réseau de distribution étudié. La comparaison des trois scénarios analysés met en évidence l'intérêt de l'utilisation d'une approche intelligente pour la gestion de la puissance réactive dans les réseaux intégrant des sources d'énergie renouvelables.

Dans le scénario sans contrôle de la puissance réactive, la centrale photovoltaïque fonctionne avec un facteur de puissance unitaire, ce qui signifie que seule la puissance active est injectée dans le réseau. Dans cette configuration, le système ne bénéficie d'aucune compensation réactive provenant de la centrale photovoltaïque. Les variations de tension, le chargement des lignes et les pertes électriques dépendent alors uniquement des flux naturels de puissance dans le réseau.

L'introduction d'une stratégie classique de contrôle basée sur la loi $Q(P)$ permet d'établir une relation simple entre la puissance active produite et la puissance réactive injectée. Toutefois, les résultats obtenus montrent que cette stratégie reste limitée dans le réseau étudié. En effet, la loi $Q(P)$ ne prend en compte qu'une seule variable du système, à savoir la puissance active de la centrale photovoltaïque. Elle ne tient pas compte des autres paramètres du réseau tels que la tension, les pertes ou le niveau de chargement des lignes. Par conséquent, son impact sur les performances globales du réseau reste relativement faible.

En revanche, le contrôleur basé sur le modèle ELM présente une approche plus avancée, reposant sur l'exploitation simultanée de plusieurs variables caractérisant l'état du réseau électrique. En utilisant comme entrées la puissance photovoltaïque, la puissance active et réactive de la charge, la tension au PCC, le chargement de la ligne et les pertes du réseau, le modèle ELM est capable d'estimer la puissance réactive optimale à injecter afin d'améliorer le fonctionnement du système.

Cette capacité d'apprentissage permet au modèle de capturer les relations non linéaires existant entre les variables du réseau et la puissance réactive optimale. Contrairement aux stratégies classiques reposant sur des lois fixes, le contrôleur ELM peut adapter dynamiquement la puissance réactive injectée en fonction des conditions réelles du réseau.

Les simulations quasi-dynamiques réalisées sur une période de 24 heures montrent que cette approche permet d'obtenir :

— une meilleure stabilité de la tension au point de couplage commun,
— une réduction du chargement de la ligne critique,
— une diminution des pertes actives dans le réseau.

La réduction des pertes obtenue, bien que modérée à l'échelle instantanée, confirme la capacité du modèle ELM à améliorer l'efficacité énergétique du réseau. À l'échelle d'un réseau réel et sur de longues périodes d'exploitation, ce type d'optimisation peut conduire à des gains énergétiques significatifs.

Cependant, il convient de noter que les performances du modèle ELM dépendent fortement de la qualité du jeu de données utilisé pour son apprentissage. Un ensemble de données représentatif des différentes conditions de fonctionnement du réseau est nécessaire afin d'obtenir un modèle capable de généraliser correctement.

Malgré cette limitation, les résultats obtenus dans cette étude montrent que l'intégration des techniques d'apprentissage automatique dans la gestion de la puissance réactive constitue une approche prometteuse pour les réseaux de distribution modernes, en particulier dans un contexte d'intégration croissante des sources d'énergie renouvelables.

Conclusion générale et perspectives

L'intégration croissante des sources d'énergie renouvelables dans les réseaux électriques de distribution représente aujourd'hui un défi majeur pour les gestionnaires de réseaux. Les centrales photovoltaïques, en particulier, introduisent une variabilité importante de la production électrique qui peut influencer le profil de tension, les flux de puissance et les pertes dans le réseau. Dans ce contexte, la gestion optimale de la puissance réactive constitue un élément essentiel pour garantir un fonctionnement sûr et efficace des réseaux électriques modernes.

Le présent travail avait pour objectif principal de proposer et d'évaluer une stratégie intelligente de contrôle de la puissance réactive basée sur l'apprentissage automatique afin d'améliorer l'intégration d'une centrale photovoltaïque dans un réseau de distribution. Pour atteindre cet objectif, un modèle du réseau Kinshasa 30 kV intégrant une centrale photovoltaïque a été développé dans l'environnement de simulation *DIgSILENT PowerFactory*.

Dans un premier temps, une analyse du comportement du réseau a été réalisée afin d'identifier les variables influençant les performances du système. Sur cette base, un ensemble de données a été généré à partir de simulations du réseau afin d'entraîner un modèle d'apprentissage automatique basé sur l'algorithme *Extreme Learning Machine* (ELM). Ce modèle a été utilisé pour estimer la puissance réactive optimale à injecter par la centrale photovoltaïque en fonction de plusieurs variables du réseau, notamment la puissance photovoltaïque produite, la charge du réseau, la tension au point de couplage commun, le chargement des lignes et les pertes électriques.

Les performances de cette stratégie de contrôle ont été évaluées à travers des simulations statiques et quasi-dynamiques réalisées sur une période de 24 heures. Trois scénarios de fonctionnement ont été étudiés : un fonctionnement sans contrôle de la puissance réactive, un contrôle classique basé sur la loi $Q(P)$ et un contrôle intelligent basé sur le modèle ELM.

Les résultats obtenus montrent que la stratégie proposée permet d'améliorer le fonctionnement global du réseau. En particulier, l'utilisation du modèle ELM contribue à une meilleure régulation de la tension au point de couplage commun, à une réduction du chargement de la ligne critique et à une diminution des pertes actives dans le réseau. Les simulations ont notamment montré une réduction des pertes électriques d'environ 1.05 kW, soit 0.43%, par rapport au

fonctionnement sans optimisation.

Ces résultats démontrent l'intérêt de l'utilisation des techniques d'apprentissage automatique pour l'optimisation de la gestion de la puissance réactive dans les réseaux de distribution intégrant des sources d'énergie renouvelables. Contrairement aux stratégies de contrôle classiques reposant sur des lois fixes, l'approche basée sur l'apprentissage automatique permet d'exploiter simultanément plusieurs variables du réseau afin d'identifier la puissance réactive optimale à injecter.

Cependant, les performances du modèle dépendent fortement de la qualité et de la représentativité du jeu de données utilisé pour l'apprentissage. Une base de données plus large couvrant un plus grand nombre de conditions de fonctionnement pourrait permettre d'améliorer encore la précision et la robustesse du modèle.

Dans la perspective de travaux futurs, plusieurs pistes d'amélioration peuvent être envisagées.

Tout d'abord, il serait pertinent d'enrichir le jeu de données utilisé pour l'apprentissage du modèle en intégrant un plus grand nombre de scénarios de fonctionnement du réseau, incluant différentes conditions de charge et de production photovoltaïque. Cela permettrait d'améliorer la précision et la capacité de généralisation du modèle.

Ensuite, une perspective importante consisterait à mettre en œuvre une commande en temps réel dans laquelle le modèle ELM serait directement intégré dans un système de supervision ou de contrôle du réseau afin de calculer automatiquement la consigne optimale de puissance réactive en fonction de l'état instantané du système.

Par ailleurs, il serait également intéressant de comparer les performances du modèle ELM avec d'autres méthodes d'intelligence artificielle ou d'optimisation, telles que les réseaux de neurones profonds, les machines à vecteurs de support ou encore les algorithmes évolutionnaires.

Enfin, l'approche développée pourrait être étendue à des réseaux électriques plus complexes intégrant plusieurs sources d'énergie renouvelables, des systèmes de stockage d'énergie ou des architectures de *smart grids*, afin d'évaluer son efficacité dans des environnements énergétiques plus larges et plus dynamiques.

En conclusion, les résultats obtenus dans ce travail montrent que l'utilisation de techniques d'intelligence artificielle telles que l'*Extreme Learning Machine* constitue une solution prometteuse pour améliorer l'exploitation des réseaux de distribution modernes et faciliter l'intégration des sources d'énergie renouvelables.

Bibliographie

[1] ResearchGate, "Schéma équivalent d'une cellule photovoltaïque." https://www.researchgate.net/figure/Schema-equivalent-dune-cellule-photovoltaique_fig53_278768476. Consulté le 15 mars 2026.

[2] S. Floucat, "Photovoltaïque : la protection bypass," juin 2023. Article de formation sur la protection bypass des modules photovoltaïques, consulté le 16 mars 2026.

[3] S. Vighetti, *Systèmes photovoltaïques raccordés au réseau : choix et dimensionnement des étages de conversion*. PhD thesis, Institut National Polytechnique de Grenoble, France, 2010.

[4] Energie Facteur 4, "Ensoleillement et production photovoltaïque." https://www.ef4.be/fr/pv/composants-dun-systeme/ensoleillement-belgique.html. Consulté le 15 mars 2026.

[5] S. Djeriou, "Simulation d'un système photovoltaïque alimentant une machine asynchrone," Master's thesis, Université Ferhat Abbas Sétif, Algérie, 2011.

[6] M. A. Green, "Grid-connected photovoltaic systems." https://www.pveducation.org, 2019. PV Education, consulté le 16 mars 2026.

[7] Egyptian Electric Utility and Consumer Protection Regulatory Agency, "Solar energy plants grid connection code," 2017. Grid code for connecting solar power plants to the Egyptian transmission and distribution network.

[8] K. Luzolo, "Intégration d'une centrale photovoltaïque dans un réseau de distribution : cas de la sous-station campus," Master's thesis, Université de Kinshasa, Kinshasa, 2025.

[9] Klein, "La puissance du concept d'énergie," *Clefs CEA*, no. 61, pp. 4–6, 2013.

[10] Wikipedia contributors, "Effet photovoltaïque," 2026. Consulté le 16 mars 2026.

[11] A. Zerdoudi and R. Chenn, "Étude de l'influence des différents paramètres sur un module photovoltaïque," 2015.

[12] S. Ntwali Mutaona, "Détection et localisation des défauts dans un système photovoltaïque à l'aide de l'extreme learning machine (elm) : cas des courts-circuits et des ombrages partiels," mémoire d'ingénieur civil Électricien, Université de Kinshasa, Faculté Polytechnique, Kinshasa, République Démocratique du Congo, 2025.

[13] P. Kundur, *Power System Stability and Control*. McGraw-Hill, 1994.

[14] K. Turitsyn, P. Sulc, S. Backhaus, and M. Chertkov, "Options for control of reactive power by distributed photovoltaic generators," *Proceedings of the IEEE*, vol. 99, no. 6, pp. 1063–1073, 2011.

[15] G. M. Masters, *Renewable and Efficient Electric Power Systems*. Wiley, 2 ed., 2013.

[16] J.-M. Beya Kamba, "Cours de statique et dynamique des réseaux Électriques."

[17] J. D. Glover, M. Sarma, and T. Overbye, *Power System Analysis and Design*. Cengage Learning, 2012.

[18] T. Short, *Electric Power Distribution Handbook*. CRC Press.

[19] DIgSILENT GmbH, *DIgSILENT PowerFactory User Manual*. Germany, 2023.

[20] J. J. Grainger and W. D. Stevenson, *Power System Analysis*. McGraw-Hill, 1994.

[21] M. H. J. Bollen and F. Hassan, *Integration of Distributed Generation in the Power System*. Wiley-IEEE Press, 2011.

[22] G.-B. Huang, Q.-Y. Zhu, and C.-K. Siew, "Extreme learning machine : Theory and applications," *Neurocomputing*, vol. 70, pp. 489–501, 2006.

[23] K. Turitsyn, P. Sulc, S. Backhaus, and M. Chertkov, "Options for control of reactive power by distributed photovoltaic generators," *Proceedings of the IEEE*, vol. 99, no. 6, pp. 1063–1073, 2011.

[24] T. Mitchell, *Machine Learning*. McGraw-Hill, 1997.

[25] A. J. Conejo, *Decomposition Techniques in Mathematical Programming*. Springer, 2006.

[26] C. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

[27] S. Al-Dahidi, O. Ayadi, J. Adeeb, M. Alrbai, and B. Qawasmeh, "Extreme learning machines for solar photovoltaic power predictions," *Energies*, 2018.

[28] S. Haykin, *Neural Networks and Learning Machines*. Pearson, 2009.

[29] National Cancer Institute SEER Program, "Neuron diagram." `https://commons.wikimedia.org/wiki/File:Neuron.svg`, 2020. Source utilisée pour illustration du neurone artificiel.

[30] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

Annexe A

Dataset utilisé pour l'entraînement

Le tableau suivant présente un extrait du dataset utilisé pour l'entraînement du modèle Extreme Learning Machine (ELM). Les données ont été générées à partir de simulations réalisées dans le logiciel DIgSILENT PowerFactory en faisant varier les conditions de production photovoltaïque et de charge du réseau.

Les variables d'entrée comprennent la puissance photovoltaïque totale (P_{pv}), la puissance active de la charge (P_{load}), la puissance réactive de la charge (Q_{load}), la tension au point de couplage commun (V_{pcc}) et le taux de chargement de la ligne. La variable cible correspond à la puissance réactive optimale injectée par l'onduleur photovoltaïque (Q_{opt}).

TABLE A.1. Extrait du dataset généré pour l'entraînement du modèle ELM

P_{pv} (MW)	P_{load} (MW)	Q_{load} (MVAr)	V_{pcc} (p.u)	Line loading (%)	P_{loss} (MW)	Q_{opt} (MVAr)
0.0	2.03	0.668	0.995	36.11	0.211	0.00
0.31	1.90	0.624	0.996	31.49	0.206	0.21
0.92	2.30	0.757	0.997	28.94	0.205	0.62
2.15	2.57	0.848	0.998	20.33	0.204	0.91
3.69	2.71	0.894	0.998	12.90	0.212	0.66

Annexe B

Scripts Python pour l'entraînement du modèle ELM

```
# -*- coding: utf-8 -*-
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_absolute_error,
    mean_squared_error, r2_score

# =========================
# CONFIG
# =========================
FILE_PATH = Path(r"C:\Users\Public\Documents\
    DATASET_TFE_MBUSU_new_essai.csv")
FILE_TYPE = "csv"
CSV_SEP = ";"

INPUT_COLS = [
    "P_pv_tot_MW",
    "P_load_MW",
    "Q_load_MVAr",
    "V_pcc_pu",
    "line_loading_pct",
    "P_loss_MW",
]
```

```
25
26 TARGET_COL = "Q_opt_actual_tot_MVAr"
27
28 TEST_SIZE = 0.2
29 RANDOM_STATE = 42
30
31 # ========================
32 # LECTURE DU FICHIER
33 # ========================
34 if FILE_TYPE == "csv":
35     df = pd.read_csv(FILE_PATH, sep=CSV_SEP)
36 else:
37     df = pd.read_excel(FILE_PATH)
38
39 df.columns = [str(c).strip() for c in df.columns]
40
41 missing = [c for c in INPUT_COLS + [TARGET_COL] if c not in df.
    columns]
42 if missing:
43     raise ValueError(f"Colonnes manquantes : {missing}")
44
45 for c in INPUT_COLS + [TARGET_COL]:
46     df[c] = pd.to_numeric(df[c], errors="coerce")
47
48 df = df.dropna(subset=INPUT_COLS + [TARGET_COL]).reset_index(drop=
    True)
49
50 print("Nombre de lignes valides :", len(df))
51
52 X = df[INPUT_COLS].to_numpy(dtype=np.float64)
53 y = df[TARGET_COL].to_numpy(dtype=np.float64)
54
55 # ========================
56 # SPLIT TRAIN / TEST
57 # ========================
58 Xtr, Xte, ytr, yte = train_test_split(
59     X, y, test_size=TEST_SIZE, random_state=RANDOM_STATE, shuffle=
        True
60 )
61
```

```
# ========================
# NORMALISATION
# ========================
sc_X = StandardScaler()
XtrN = sc_X.fit_transform(Xtr)
XteN = sc_X.transform(Xte)

sc_y = StandardScaler()
ytrN = sc_y.fit_transform(ytr.reshape(-1, 1)).ravel()

# ========================
# MODELE ELM
# ========================
class ExtremeLearningMachine:
    def __init__(self, num_hidden_neurons=50, activation_function=
        "tanh", seed=0):
        self.num_hidden_neurons = int(num_hidden_neurons)
        self.activation_function = activation_function
        self.seed = int(seed)
        self.input_weights = None
        self.biases = None
        self.output_weights = None

    def _activation(self, x):
        if self.activation_function == "sigmoid":
            x = np.clip(x, -500, 500)
            return 1.0 / (1.0 + np.exp(-x))
        elif self.activation_function == "tanh":
            return np.tanh(x)
        elif self.activation_function == "relu":
            return np.maximum(0.0, x)
        else:
            raise ValueError("Activation non support e")

    def fit(self, X, y):
        rng = np.random.default_rng(self.seed)
        n_features = X.shape[1]

        self.input_weights = rng.standard_normal(
            (self.num_hidden_neurons, n_features)
```

```
        )
        self.biases = rng.standard_normal(self.num_hidden_neurons)

        H = self._activation(X @ self.input_weights.T + self.
            biases[None, :])
        self.output_weights = np.linalg.pinv(H) @ y

    def predict(self, X):
        H = self._activation(X @ self.input_weights.T + self.
            biases[None, :])
        return H @ self.output_weights

# ========================
# ENTRAINEMENT
# ========================
elm = ExtremeLearningMachine(
    num_hidden_neurons=80,
    activation_function="tanh",
    seed=42
)
elm.fit(XtrN, ytrN)
```

Listing B.1 – Script Python pour l'entraînement du modèle Extreme Learning Machine (ELM)

Annexe C

Caractéristiques des transformateurs Kinshasa 30 kV

TABLE C.1. Caractéristiques des cabines et transformateurs du réseau étudié

N°	Cabines	Transfos	Caractéristiques	Charges BT alimentées
1	Sous-station	Transfo 1 et 2	$U_n = 30/6.6$ kV $S_n = 15$ MVA	—
2	CUK 1-2	Transfo 1	$U_n = 6.6/0.4$ kV $S_n = 630$ kVA	Bloc technique ; École de santé publique ; Centre hospitalier ; Couvent des sœurs ; Unité d'oxygène
3	CUK 3	Transfo 1	$S_n = 100$ kVA	Les deux morgues ; Petit marché ; Auditoire
4	Médecine	Transfo 1	$U_n = 6.6/0.4$ kV	Faculté de médecine ; Faculté de pharmacie
5	Agronomie	Transfo 1	Dyn11 $S_n = 400$ kVA	Faculté d'agronomie
6	Polytechnique	Transfo 1	$S_n = 630$ kVA	Faculté polytechnique
7	Sciences 1	Transfo 1	$U_n = 6.6/0.4$ kV	Bâtiment administratif ; Antenne
8	Sciences 2	Transfo 1	$S_n = 630$ kVA	Faculté de sciences
9	Économie	Transfo 1	$S_n = 630$ kVA	Faculté d'économie ; Faculté de lettres ; Petits commerces extérieurs
10	CREN-K	—	$S_n = 150$ kVA	CREN-K (E12)

N°	Cabines	Transfos	Caractéristiques	Charges BT alimentées
11	Home plateau 5	—	$S_n = 630$ kVA	Homes 1 à 8 et maisons des professeurs
12	Home 20	—	$S_n = 315$ kVA	Home 20 et église PPUKIN
13	Home 10	—	$S_n = 315$ kVA	Home 10 et marché Kinduku
14	Home 80	—	—	Home 80
15	Home 150	—	$S_n = 250$ kVA	Home 150
16	Home GPE	—	—	Home GPE
17	IG	—	$S_n = 500$ kVA	Ateliers de l'IG